**UNIVERSIDADE DO VALE DO ITAJAÍ**

**ESCOLA POLITÉCNICA**
**CURSO DE CIÊNCIA DA COMPUTAÇÃO**

**MATHEUS BARON LAURITZEN**

# DESENVOLVIMENTO DE UM PIPELINE GNUPLOT PARA ANÁLISE DE EVENTOS EM RADIAÇÃO DE FUNDO DA INTERNET

Itajaí
2026

MATHEUS BARON LAURITZEN

# DESENVOLVIMENTO DE UM PIPELINE GNUPLOT PARA ANÁLISE DE EVENTOS EM RADIAÇÃO DE FUNDO DA INTERNET

Trabalho de Conclusão de Curso apresentado ao Curso de Ciência da Computação – UNIVALI, como parte dos requisitos para obtenção do título de Bacharel em Ciência da Computação.

Linha de Pesquisa: Redes de Computadores

Orientador: Dr. Fabricio Bortoluzzi

Itajaí

2026

## RESUMO

A Radiação de Fundo da Internet (*Internet Background Radiation* - IBR) consiste no tráfego de rede não solicitado que atinge endereços IP públicos, sendo composta majoritariamente por varreduras automatizadas, tentativas de propagação de *malware* e retroespalhamento de ataques de negação de serviço. O Telescópio de Nuvem (*Cloud Telescope*) é uma arquitetura distribuída e nativa da nuvem que supera as limitações dos telescópios de rede tradicionais, permitindo a captura simultânea de IBR em dezenas de regiões geográficas. No entanto, a escala dos *datasets* gerados por essa arquitetura, dezenas de gigabytes por ciclo de coleta, impõe um gargalo analítico: a ausência de uma etapa de visualização automatizada no *pipeline* de processamento dificulta a identificação rápida de padrões de tráfego. Este trabalho propõe desenvolver um *pipeline* baseado no Gnuplot para a geração automatizada de visualizações de IBR capturada pelo Cloud Telescope. Para isso, o *pipeline* existente é adaptado por meio da modificação do *script* de sumarização já existente, que passa a exportar os dados sumarizados também no formato JSON, e da adição de dois novos módulos: um *script* que converte esses dados em arquivos `.dat` compatíveis com o Gnuplot; e um *script* de geração de gráficos que executa automaticamente todos os *scripts* de plotagem `.plt`, produzindo o conjunto completo de visualizações com um único comando. Os gráficos implementados incluem histogramas de distribuição de portas TCP e UDP, distribuição de tipos ICMP, distribuição geográfica dos países de origem e distribuição por região AWS. Os resultados obtidos são discutidos segundo critérios de clareza visual, relevância analítica e integração ao *pipeline*, contribuindo para transformar dados brutos de IBR em inteligência acionável para o grupo de pesquisa.



**Palavras-chave:** Radiação de Fundo da Internet. Telescópio de Nuvem. Gnuplot. Visualização de Dados. Redes de Computadores..

**ABSTRACT**

Internet Background Radiation (IBR) consists of unsolicited network traffic directed at public IP addresses, composed primarily of automated port scans, malware propagation attempts, and denial-of-service attack backscatter. The Cloud Telescope is a distributed, cloud-native architecture that overcomes the limitations of traditional network telescopes, enabling simultaneous IBR capture across dozens of geographic regions. However, the scale of datasets generated by this architecture, tens of gigabytes per collection cycle, creates an analytical bottleneck: the absence of an automated visualization stage in the processing pipeline hinders the rapid identification of traffic patterns. This work proposes the development of a Gnuplot-based pipeline for the automated generation of IBR visualizations captured by the Cloud Telescope. To this end, the existing pipeline is adapted through the modification of the existing summarization script, which is extended to also export the summarized data in JSON format, and the addition of two new modules: a script that converts this data into Gnuplot-compatible .dat files; and a graph generation script that automatically executes all .plt plotting scripts, producing the complete set of visualizations with a single command. The implemented charts include histograms of TCP and UDP port distributions, ICMP type distributions, geographic distribution of source countries, and distribution by AWS region. The results obtained are discussed according to criteria of visual clarity, analytical relevance, and pipeline integration, contributing to transforming raw IBR data into actionable intelligence for the research group.

**Keywords:** Internet Background Radiation. Cloud Telescope. Gnuplot. Data Visualization. Computer Networks..

## LISTA DE FIGURAS


Figura 1 – Adaptação proposta ao *pipeline* do Cloud Telescope: a etapa de sumarização (laranja) passa a exportar dados em JSON para as novas etapas de geração automatizada de gráficos (verde). . . . . 15

Figura 2 – Mecanismo de retroespalhamento (*DoS backscatter*): pacotes SYN com IP forjado redirecionam respostas das vítimas ao endereço falsificado, gerando IBR secundário visível ao telescópio. **Fonte**: Moore *et al.* (2006). . . . . 22

Figura 3 – Estrutura típica de uma *botnet*: dispositivos comprometidos coordenados pelo atacante para varreduras massivas, principal fonte de IBR capturado por telescópios de rede. **Fonte**: Beiler (2023). . . . . 23

Figura 4 – Arquitetura genérica de um Telescópio de Rede: bloco de IPs ociosos exposto à internet captura passivamente toda IBR recebida em formato PCAP. **Fonte**: Irwin (2011). . . . . 23

Figura 5 – Sensor do Cloud Telescope em região AWS: a IBR é capturada por sensores em VPC(*Virtual Private Cloud* - Rede Privada na Nuvem) com grupo de segurança aberto e os arquivos PCAP são exportados para *bucket* global na nuvem. **Fonte**: Bortoluzzi (2025). . . . . 25

Figura 6 – Distribuição geográfica dos sensores do Cloud Telescope (*Dataset 3*) em regiões AWS da América, Europa, Oriente Médio, Ásia e Oceania, eliminando o viés geopolítico dos telescópios tradicionais. **Fonte**: Bortoluzzi (2025). . 26

Figura 7 – Fluxo conceitual de um processo ETL: sistemas de origem são extraídos, transformados e carregados em um destino consolidado. **Fonte**: Babu e B. (2022). . . . . 27

Figura 8 – O mesmo conjunto de dados de vendas representado como tabela e como gráfico de linha: a tendência de alta das vendas domésticas e a queda isolada das vendas internacionais em agosto só se tornam evidentes na forma gráfica. **Fonte**: Few (2013). . . . . 29

Figura 9 – Histograma de barras no Gnuplot com o estilo `histograms`: cada barra representa a frequência de um valor discreto. **Fonte**: Williams *et al.* (2025). . 31

Figura 10 – Série temporal no Gnuplot com `set xdata time` e estilo `linespoints`, conectando observações cronológicas com marcadores. **Fonte**: Williams *et al.* (2025). . . . . 32

Figura 11 – Mapa de calor 4D no Gnuplot: superfície 3D com cor mapeada a partir de uma variável independente do eixo z, gerada com `splot` e `with pm3d`. **Fonte**: Williams *et al.* (2025). . . . . 33

Figura 12 – Figura 30 da tese de Bortoluzzi (2025): distribuição diária de tráfego TCP nas portas 10000, 10001 e 10002, produzida manualmente via planilhas eletrônicas. . . . . 34
Figura 13 – Reprodução automatizada da Figura 30 de Bortoluzzi (2025), gerada pelo *pipeline* Python + Gnuplot a partir dos mesmos dados do Dataset 3. . . . . 34
Figura 14 – Tabela 28 da tese de Bortoluzzi (2025) (p. 114): ranking dos 20 países mais ativos como origens de radiação no Dataset 3, apresentado em formato tabular. 35
Figura 15 – Reprodução automatizada da Tabela 28 de Bortoluzzi (2025) como gráfico de barras gerado pelo Gnuplot, evidenciando visualmente a hierarquia entre os países de origem de IBR. . . . . 35
Figura 16 – Tabela 34 da tese de Bortoluzzi (2025) (p. 122): ranking das 20 portas UDP mais visadas no Dataset 3, apresentado em formato tabular. . . . . 36
Figura 17 – Reprodução automatizada da Tabela 34 de Bortoluzzi (2025) como gráfico de barras gerado pelo Gnuplot, destacando a concentração atípica de tráfego na porta 5100 em relação às demais. . . . . 37
Figura 18 – Distribuição das 25 portas TCP mais visadas pelo telescópio de rede espanhol em outubro de 2023, em escala logarítmica. **Fonte**: García-Peñas, Rodríguez-Gómez e Maciá-Fernández (2025), Fig. 8, p. 10. . . . . 39
Figura 19 – Tendências longitudinais e picos de tráfego no *darknet* do ORION entre 2006 e 2024. **Fonte**: Ismail *et al.* (2025), Fig. 4, p. 5. . . . . 40
Figura 20 – Distribuição dos tipos de escaneador nas 15 portas TCP mais visadas. **Fonte**: Griffioen *et al.* (2024), Fig. 5, p. 159. . . . . 41
Figura 21 – Fluxo completo do Cloud Telescope nas três fases de operação. **Fonte**: Bortoluzzi (2025), Fig. 17, p. 82. . . . . 42
Figura 22 – *Pipeline* original de análise de IBR do Cloud Telescope. . . . . 46
Figura 23 – *Pipeline* modificado proposto por este trabalho. . . . . 47
Figura 24 – Total diário de pacotes de radiação IBR ao longo do Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 53
Figura 25 – Série temporal completa de pacotes de radiação IBR por dia nas portas TCP 10000/10001/10002 (Dataset 3 integral). Fonte: Elaborado pelo autor. . . . 54
Figura 26 – Total diário de pacotes de radiação IBR em outubro de 2023, elaborado manualmente pelo grupo de pesquisa a partir de planilha Excel (gráfico de referência fornecido pelo orientador). Fonte: Grupo de pesquisa, dados não publicados. . . . . 55
Figura 27 – Total diário de pacotes de radiação IBR em outubro de 2023, gerado automaticamente pelo *pipeline* modificado, no mesmo estilo do gráfico de referência manual. Fonte: Elaborado pelo autor. . . . . 55

Figura 28 – Tabela 31 da tese de Bortoluzzi (2025) (p. 118): ranking dos 20 países mais ativos como origens de radiação ICMP no Dataset 3, apresentado em formato tabular. Fonte: Bortoluzzi (2025). . . . . 56
Figura 29 – Reprodução automatizada da Tabela 31 de Bortoluzzi (2025) como gráfico de barras gerado pelo *pipeline* modificado: Top 20 países de origem da radiação IBR por volume de pacotes ICMP no Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 57
Figura 30 – Comparação entre o número de IPs de origem únicos e de IPs de destino únicos no Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 58
Figura 31 – Distribuição percentual do tráfego de radiação IBR por protocolo de transporte no Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 59
Figura 32 – Distribuição dos pacotes ICMP de radiação IBR por tipo de mensagem no Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 60
Figura 33 – Top 20 portas TCP de destino mais visadas pela radiação IBR no Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 61
Figura 34 – Top 20 portas UDP de destino mais visadas pela radiação IBR no Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 62
Figura 35 – Top 20 combinações de *flags* TCP no tráfego de radiação IBR do Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 63
Figura 36 – Mapa de calor geográfico da origem da radiação IBR no Dataset 3 completo, com pontos sobre massas terrestres coloridos pela contagem aproximada de pacotes. Fonte: Elaborado pelo autor. . . . . 64
Figura 37 – Top 10 países de origem da radiação IBR por volume total de pacotes, com a porta TCP de maior incidência rotulada sobre cada barra. Fonte: Elaborado pelo autor. . . . . 65
Figura 38 – Distribuição de protocolos de transporte por país de origem da radiação IBR (Top 20) no Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 66
Figura 39 – Mapa de calor da contagem de pacotes de radiação IBR por país de origem e protocolo de transporte no Dataset 3 completo. Fonte: Elaborado pelo autor. 67
Figura 40 – Top 20 países de origem da radiação IBR por volume total de pacotes, em bolhas dimensionadas pela contagem, no Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 68
Figura 41 – Composição de protocolo de transporte dos 20 principais países de origem da radiação IBR em eixos paralelos no Dataset 3 completo; cada linha conecta os valores de TCP, UDP e ICMP de um mesmo país, com Estados Unidos, China e Singapura destacados em cor e os demais 17 países em cinza, como contexto. Fonte: Elaborado pelo autor. . . . . 68
Figura 42 – Top 20 cidades de origem da radiação IBR no Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 69

Figura 43 – Mapa de calor da contagem de pacotes de radiação IBR por região AWS alvo e protocolo de transporte no Dataset 3 completo. Fonte: Elaborado pelo autor. 70
Figura 44 – Distribuição do volume total de radiação IBR por região AWS em rosa dos ventos adaptada no Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 71
Figura 45 – Distribuição de protocolos de transporte por país de destino AWS (Top 20) em barras agrupadas no Dataset 3 completo. Fonte: Elaborado pelo autor. . 72
Figura 46 – Top 20 países de destino AWS da radiação IBR por volume total de pacotes, em bolhas dimensionadas pela contagem, no Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 72
Figura 47 – Distribuição de protocolos de transporte por país de destino AWS (Top 20) em barras empilhadas no Dataset 3 completo. Fonte: Elaborado pelo autor. . 73
Figura 48 – Top 20 cidades de destino da radiação IBR na infraestrutura AWS no Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 74
Figura 49 – Distribuição do número de pacotes enviados por IP de origem, em escala log-log, no Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 75
Figura 50 – Distribuição do número de pacotes recebidos por porta TCP de destino, em escala log-log, no Dataset 3 completo. Fonte: Elaborado pelo autor. . . . . 76

## LISTA DE QUADROS

Quadro 1 – Cronograma de execução do TCC II . . . . . 18
Quadro 2 – Cronograma de execução do TCC III . . . . . 18
Quadro 3 – Análise de riscos . . . . . 19
Quadro 4 – Comparação dos principais trabalhos relacionados . . . . . 44

## LISTA DE CÓDIGOS-FONTE


1 Exemplo de script Gnuplot . . . . . 29
2 Rotina de exportação dos dicionários de contagem para JSON (trecho simplificado de `3_summarize_radiation.py`). . . . . 48
3 Geração de um arquivo `.dat` de *ranking* a partir de um dicionário de contagens (`4_generate_gnuplot_dat.py`). . . . . 48
4 Execução automatizada de todos os *scripts* Gnuplot do diretório de trabalho (trecho simplificado de `5_generate_graphics.py`). . . . . 49
5 *Script* Gnuplot completo de geração da série temporal de pacotes por porta TCP monitorada (`gerar_grafico_serie_temporal_portas.plt`). . . . . 50
6 *Script* Gnuplot completo de geração do mapa de calor de região AWS por protocolo de transporte (`gerar_grafico_heatmap_regiao_aws.plt`). . . . . 51

## LISTA DE ABREVIATURAS E SIGLAS

**Siglas**

| | |
|---|---|
| AWS | Amazon Web Services |
| C2 | Comando e Controle (Command and Control) |
| CAIDA | Center for Applied Internet Data Analysis |
| CSP | Cloud Service Provider (Provedor de Serviços em Nuvem) |
| DDoS | Distributed Denial of Service (Negação de Serviço Distribuída) |
| DNS | Domain Name System (Sistema de Nomes de Domínio) |
| DoS | Denial of Service (Negação de Serviço) |
| ELK | Elasticsearch, Logstash e Kibana |
| IaC | Infrastructure-as-Code (Infraestrutura-como-Código) |
| IBR | Internet Background Radiation (Radiação de Fundo da Internet) |
| ICMP | Internet Control Message Protocol |
| IoT | Internet of Things (Internet das Coisas) |
| IP | Internet Protocol |
| IPv4 | Internet Protocol versão 4 |
| IPv6 | Internet Protocol versão 6 |
| JSON | JavaScript Object Notation |
| NTP | Network Time Protocol (Protocolo de Tempo de Rede) |
| PCAP | Packet CAPture (Captura de Pacotes) |
| RAM | Random Access Memory (Memória de Acesso Aleatório) |
| SSH | Secure Shell |
| TCC | Trabalho Técnico-Científico de Conclusão de Curso |
| TCP | Transmission Control Protocol |
| UCSD-NT | UCSD Network Telescope |
| UDP | User Datagram Protocol |
| VPC | Virtual Private Cloud (Rede Virtual Privada na Nuvem) |
| WSL | Windows Subsystem for Linux (Subsistema do Windows para Linux) |

**SUMÁRIO**


**1 INTRODUÇÃO . . . . . 13**
**1.1 Problematização . . . . . 14**
**1.2 Formulação do Problema . . . . . 14**
1.2.1 Solução Proposta . . . . . 14
**1.3 Objetivos . . . . . 15**
1.3.1 Objetivo Geral . . . . . 16
1.3.2 Objetivos Específicos . . . . . 16
**1.4 Metodologia . . . . . 16**
**1.5 Plano de Trabalho . . . . . 17**
**1.6 Cronograma . . . . . 18**
**1.7 Análise de Riscos . . . . . 19**

**2 FUNDAMENTAÇÃO TEÓRICA . . . . . 20**
**2.1 Análise de Tráfego de Rede . . . . . 20**
**2.2 Radiação de Fundo da Internet . . . . . 21**
**2.3 Telescópio de Rede . . . . . 23**
**2.4 Telescópio de Nuvem . . . . . 24**
**2.5 Pipeline ETL . . . . . 26**
**2.6 Importância da Estatística e da Visualização de Dados . . . . . 28**
**2.7 Gnuplot . . . . . 29**
2.7.1 Repertório de Estilos de Plotagem . . . . . 30
*2.7.1.1 Histogramas e gráficos de barras . . . . . 30*
*2.7.1.2 Séries temporais . . . . . 31*
*2.7.1.3 Mapas de calor . . . . . 32*
2.7.2 Ensaio: Reprodução de Visualizações com Gnuplot . . . . . 33
*2.7.2.1 Ensaio 1: Série Temporal de Portas TCP . . . . . 33*
*2.7.2.2 Ensaio 2: Top 20 Origens de Radiação por País . . . . . 34*
*2.7.2.3 Ensaio 3: Top 20 Portas UDP de Destino . . . . . 35*

**3 TRABALHOS RELACIONADOS . . . . . 38**
**3.1 Caracterização de IBR por Telescópio de Rede Sediado na Espanha . . 38**
**3.2 Análise Longitudinal de Vinte Anos de Dados de Telescópio de Rede . . 39**
**3.3 Caracterização Longitudinal de Dez Anos de Escaneamento na Internet 40**
**3.4 Implementação do Cloud Telescope com Captura Distribuída de IBR . 42**
**3.5 Avaliação da Pilha ELK para Visualização de IBR . . . . . 43**
**3.6 Modelagem de Tráfego IBR com Grafos e Neo4j . . . . . 43**

**3.7 Quadro de Trabalhos Relacionados . . . . . 44**

**4 DESENVOLVIMENTO . . . . . 46**
**4.1 Descrição do Pipeline Modificado . . . . . 48**
4.1.1 Critério de Seleção dos Gráficos . . . . . 50

**5 RESULTADOS E DISCUSSÃO . . . . . 53**
**5.1 Padrões Temporais . . . . . 53**
5.1.1 Validação frente ao Processo Manual do Grupo de Pesquisa . . . . . 55
**5.2 Origens e Destinos Únicos de Radiação . . . . . 57**
**5.3 Distribuição por Protocolo de Transporte . . . . . 58**
5.3.1 Tipos de Mensagem ICMP . . . . . 59
**5.4 Portas de Destino Mais Visadas . . . . . 60**
5.4.1 Portas UDP . . . . . 61
5.4.2 Combinações de Flags TCP . . . . . 62
**5.5 Origem Geográfica da Radiação . . . . . 63**
5.5.1 Países de Origem e Portas Visadas . . . . . 65
5.5.2 Composição de Protocolo por País de Origem . . . . . 66
5.5.3 Cidades de Origem . . . . . 69
**5.6 Alvos na Infraestrutura AWS . . . . . 70**
5.6.1 Países e Cidades de Destino na Infraestrutura AWS . . . . . 71
**5.7 Concentração de Tráfego por Lei de Potência . . . . . 74**

**6 CONSIDERAÇÕES FINAIS . . . . . 77**

**REFERÊNCIAS . . . . . 80**

# 1 INTRODUÇÃO

A Internet contemporânea é uma infraestrutura global indispensável, mas também uma superfície de ataque permanentemente exposta a ameaças cibernéticas. Compreender a natureza e a escala dessas ameaças motiva pesquisadores a buscarem métodos para mensurar a atividade maliciosa em escala global (Bortoluzzi, 2025).

Nesse contexto, surge a Radiação de Fundo da Internet (*Internet Background Radiation* - IBR), também conhecida como tráfego *darknet*: o conjunto de pacotes não solicitados que atingem qualquer endereço IP público, composto majoritariamente por varreduras automatizadas, tentativas de propagação de *malware* e reflexos de ataques de negação de serviço (Irwin, 2011). Por ser um fenômeno incessante e independente de interação legítima, a IBR se consolidou como uma das principais fontes de inteligência sobre ameaças cibernéticas.

O método tradicional de coleta de IBR é o Telescópio de Rede (*Network Telescope*), fundamental para a pesquisa em segurança há duas décadas. Contudo, essa abordagem sofre de limitações estruturais, escassez de endereços IPv4, localização geográfica estática e viés geopolítico, que restringem sua representatividade global. Para superá-las, Bortoluzzi (2025) propôs o Telescópio de Nuvem (*Cloud Telescope*): uma arquitetura efêmera e nativa da nuvem, baseada em Infraestrutura-como-Código (IaC), capaz de distribuir sensores de captura por dezenas de regiões geográficas simultaneamente.

Essa abordagem elimina o limite geopolítico e amplia a cobertura da coleta, mas gera um novo desafio: os *datasets* produzidos acumulam dezenas de gigabytes por ciclo de captura. A análise puramente tabular desses volumes é insuficiente para revelar padrões visuais, correlações entre variáveis e tendências temporais, onde representações gráficas tornam essas informações interpretáveis (Thakare; Pund, 2018).

Embora o Cloud Telescope tenha avançado significativamente a fronteira da captura distribuída de IBR, o tratamento analítico dos dados gerados permanece um desafio em aberto. O volume expressivo produzido por cada ciclo de captura torna necessária uma camada de geração de visualizações integrada diretamente ao *pipeline* de análise, capaz de operar de forma automatizada sobre os dados sumarizados sem intervenção humana. Estudos que examinam capturas em telescópios consolidados, como o Merit Network Telescope (Ismail *et al.*, 2025) e o UCSD-NT (Männel *et al.*, 2025), dispõem de visualizações, mas estas são geradas por meio de infraestruturas de *dashboard* interativas, como o Grafana, ou de ferramentas de plotagem acionadas manualmente a cada ciclo de análise, sem integração ao *pipeline* de processamento local. Essa ausência de automação em lote compromete a reprodutibilidade e a continuidade analítica, exigindo intervenção manual sempre que um novo conjunto de dados é disponibilizado. É nessa lacuna que este trabalho se insere.

## 1.1 Problematização

A análise da IBR pode conferir oportunidade única de compreensão das atividades maliciosas que ela contém. No entanto, o volume de dados gerado por uma arquitetura de coleta distribuída em escala global, como o Telescópio de Nuvem, cria um gargalo analítico: a ausência de uma etapa de visualização automatizada no *pipeline* de processamento existente impede a exploração visual e sistemática dos padrões de tráfego capturados.

A lacuna que este trabalho se propõe a investigar reside, portanto, na necessidade de métodos eficientes e automatizados para a geração de visualizações a partir dos *datasets* produzidos pelo Telescópio de Nuvem. O projeto já dispõe de um *pipeline* de processamento de dados que realiza a extração, o enriquecimento e a sumarização do tráfego, gerando tabelas em formato LaTeX para publicações científicas. Contudo, falta uma etapa que traduza esses dados sumarizados em representações gráficas de forma integrada, permitindo uma análise visual de fácil uso dos padrões de IBR capturados.

## 1.2 Formulação do Problema

A quantidade de dados gerada por uma frota global de sensores de IBR distribudos em 26 regiões do provedor AWS é de uma ordem de magnitude que torna a análise manual impraticável. Os *datasets* já existentes do projeto Cloud Telescope acumulam dezenas de gigabytes de tráfego capturado, contendo centenas de milhões de pacotes de rede.

Embora tabelas de sumarização sejam eficazes para apresentar rankings e percentuais, elas não são suficientes para revelar padrões visuais, correlações entre variáveis ou tendências que emergem naturalmente de uma representação gráfica. Essa limitação é especialmente relevante no contexto da IBR, cujo tráfego é gerado por uma variedade de atividades maliciosas com comportamentos distintos: varreduras automatizadas de portas conduzidas por *scanners* e *botnets*, tentativas de propagação de *malware*, e reflexos de ataques de negação de serviço distribuídos (DDoS) na forma de retroespalhamento (Bortoluzzi, 2025). Cada uma dessas origens produz padrões de tráfego característicos em termos de protocolos, portas de destino e distribuição geográfica das origens, padrões esses que apenas representações gráficas adequadas são capazes de tornar visíveis e interpretáveis de forma eficiente.

### 1.2.1 Solução Proposta

A solução proposta consiste em estender a etapa de sumarização de tráfego do *pipeline* para incluir a geração automatizada de gráficos, utilizando a ferramenta Gnuplot. A escolha do Gnuplot é justificada por suas características que o tornam particularmente adequado para o ambiente acadêmico e de pesquisa: é uma ferramenta de visualização versátil e altamente configurável, capaz de lidar com milhões de pontos de dados (Janert, 2016), e opera por linha

de comando sem interface gráfica, o que permite que a geração de gráficos seja completamente automatizada e integrada ao *pipeline* existente.

A contribuição principal deste trabalho consiste na adaptação do *pipeline* original de análise de IBR através da inclusão de três novas etapas encadeadas, como ilustrado na Figura 1. Primeiramente, a etapa de sumarização existente (`3_summarize_radiation.py`) é modificada para exportar os dados em formato JSON, além das tabelas LaTeX. Em seguida, uma nova etapa de processamento (`4_generate_gnuplot_dat.py`) converte esse JSON em arquivos de dados (`.dat`) formatados especificamente para o Gnuplot. Por fim, a etapa de automação (`5_generate_graphics.py`) consome esses arquivos e os *scripts* de plotagem (`.plt`) para gerar o conjunto final de visualizações em formato PNG ou PDF. Essa arquitetura permite que o conjunto completo de gráficos seja gerado de forma automatizada com um único comando, o capítulo 4 contém uma explicação mais detalhada da parte prática. A Figura 1 sintetiza visualmente essa contribuição.

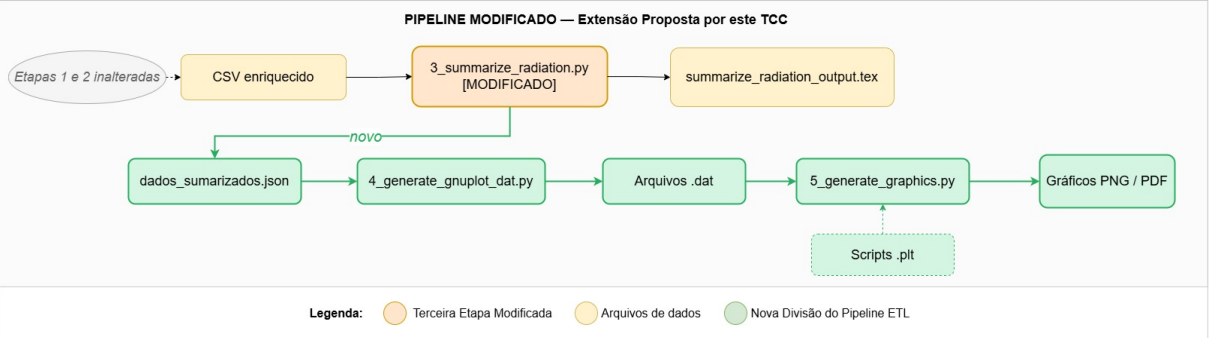



**Figura 1 –** Adaptação proposta ao *pipeline* do Cloud Telescope: a etapa de sumarização (laranja) passa a exportar dados em JSON para as novas etapas de geração automatizada de gráficos (verde).

Este trabalho se insere em uma frente mais ampla do grupo de pesquisa do Cloud Telescope, que especula o uso de diferentes tecnologias para análise e visualização dos dados capturados. Enquanto este trabalho desenvolve um *pipeline* baseado no Gnuplot como instrumento de geração de gráficos em lote, por definição, não interativo, outros trabalhos em andamento no grupo investigam, em paralelo, o uso do Neo4j como *backend* de análise baseado em grafos e da pilha ELK (*Elasticsearch*, *Logstash* e *Kibana*) para indexação e visualização interativa dos dados. A escolha do Gnuplot, portanto, não precisa ser justificada em detrimento das demais, mas cada frente contribui com uma perspectiva complementar.

## 1.3 Objetivos

Este Trabalho Técnico-Científico de Conclusão de Curso (TCC) contém 1 (um) objetivo geral e 4 (quatro) objetivos específicos.

### 1.3.1 Objetivo Geral

Desenvolver um *pipeline* baseado no Gnuplot para geração automatizada de padrões de visualização de Radiação de Fundo da Internet (IBR), conforme capturado pelo telescópio de nuvem.

### 1.3.2 Objetivos Específicos

Este trabalho possui os seguintes objetivos específicos:

- Revisar técnicas atuais para representação de padrões de tráfego de redes de computadores.
- Alterar a etapa de sumarização de tráfego da radiação de fundo da internet do *pipeline*, conforme capturado pelo telescópio de nuvem, de forma a incluir uma etapa de geração automática de gráficos com o Gnuplot.
- Implementar um conjunto de gráficos no Gnuplot que exiba padrões de tráfego de IBR de interesse do grupo de pesquisa.
- Discutir a utilidade dos resultados obtidos.

## 1.4 Metodologia

Este trabalho classifica-se como pesquisa aplicada, pois visa a resolução de um problema prático identificado no *pipeline* de análise do projeto Cloud Telescope (Wazlawick, 2009). A abordagem é de natureza não experimental, uma vez que os autores não interferem sistematicamente no fenômeno observado, utilizando apenas os *datasets* já existentes, conforme é descrito em Bortoluzzi (2025).

Aplica-se revisão da literatura sobre o conceito da IBR, abordando estudos anteriores relacionados ao tema, bem como técnicas de visualização de dados aplicadas à análise de tráfego de rede. Dessa forma, são explorados artigos acadêmicos, periódicos científicos e outras fontes relevantes para obter uma visão abrangente e atualizada sobre o tema. A coleta de bibliografia segue os procedimentos de revisão sistemática propostos por Kitchenham (2004), com buscas em bases de dados acadêmicas e científicas, como IEEE Xplore, ACM Digital Library, Google Scholar e Arxiv, incluindo os anais de conferências especializadas em medição de Internet, como o ACM Internet Measurement Conference (Vallina-Rodríguez *et al.*, 2024; Barford; Balasubramanian; Dainotti, 2025).

O trabalho foi estruturado em quatro etapas principais, detalhadas na Seção 1.5: (1) fundamentação teórica e análise da ferramenta Gnuplot; (2) adaptação do *pipeline* de análise para exportação de dados e automação da geração de gráficos; (3) desenvolvimento dos *scripts* Gnuplot e geração das visualizações; e (4) análise crítica dos resultados e redação da monografia.

## 1.5 Plano de Trabalho

1. Fundamentação Teórica e Análise de Ferramentas: Esta etapa inicial é crucial para embasar o trabalho. Consiste na revisão da literatura para compreender quais formas de visualização utilizar e na análise aprofundada da ferramenta Gnuplot.

    a) Revisão Bibliográfica: Realizar uma busca sistemática por artigos e trabalhos acadêmicos que abordem técnicas de visualização de dados aplicadas a tráfego de rede, segurança cibernética e, especificamente, Internet Background Radiation (IBR).

    b) Estudo do Gnuplot: Analisar a documentação oficial e exemplos práticos do Gnuplot para identificar os tipos de gráficos mais eficazes (histogramas, séries temporais, mapas de calor, etc.) para representar os padrões de IBR e compreender os formatos de dados de entrada necessários.

2. Preparação do Ambiente e Adaptação do Pipeline: Esta etapa foca na configuração do ambiente de desenvolvimento e na modificação do *pipeline* de análise de dados do projeto Cloud Telescope, representando a principal contribuição técnica do trabalho.

    a) Configuração do Ambiente: Preparar o ambiente de desenvolvimento, incluindo a instalação do WSL (Subsistema do Windows para Linux), a configuração de um ambiente virtual Python (*venv*) e a instalação de todas as bibliotecas e ferramentas necessárias (TShark, Gnuplot, etc.).

    b) Adaptação do Módulo de Sumarização: Modificar o *script* (`3_summarize_radiation.py`) do *pipeline* para que, além de gerar os arquivos `.tex`, ele exporte os dicionários de dados sumarizados para um arquivo intermediário no formato JSON.

    c) Desenvolvimento do Módulo de Geração de Dados: Criar um *script* em Python (`4_generate_gnuplot_dat.py`) que lê o arquivo JSON gerado na etapa anterior e produzir os arquivos de dados (`.dat`) formatados especificamente para o Gnuplot.

    d) Desenvolvimento da Etapa de Geração de Gráficos: Criar um *script* em Python (`5_generate_graphics.py`) responsável por automatizar a execução sequencial de todos os *scripts* Gnuplot (`.plt`) disponíveis na pasta de visualizações, garantindo que o pesquisador possa regenerar o conjunto completo de gráficos com a execução de um único comando integrado ao *pipeline*.

3. Implementação das Visualizações e Geração de Gráficos: Com os dados prontos, esta etapa consiste em desenvolver os *scripts* Gnuplot para criar o conjunto padronizado de visualizações.

    a) Desenvolvimento dos Scripts Gnuplot: Escrever os *scripts* (`.plt`) para cada tipo de gráfico definido na primeira etapa. Cada *script* funciona como um *template* que lê um arquivo `.dat` específico e gera uma imagem correspondente.

b) Geração do Conjunto de Gráficos: Executar o *pipeline* completo sobre os *datasets* do Cloud Telescope para gerar o conjunto final de visualizações, como o histograma de portas TCP, a série temporal de volume de pacotes e o mapa de calor de países de origem.

4. Análise de Resultados e Redação da Monografia: A etapa final envolve a interpretação dos resultados obtidos e a documentação de todo o processo na monografia.

   a) Análise dos Gráficos: Avaliar criticamente as visualizações geradas, discutindo a clareza, a relevância e a capacidade dos gráficos em fornecer *insights* sobre os padrões de IBR.

   b) Redação do TCC: Escrever os capítulos da monografia, incluindo a fundamentação teórica, a metodologia (detalhando as modificações no *pipeline*), a apresentação e discussão dos resultados, e a conclusão do trabalho.

   c) Formatação e Revisão Final: Realizar a formatação do documento de acordo com as normas da ABNT e revisar o texto final para a entrega.

## 1.6 Cronograma

O TCC II (2026/1) concentrou a fundamentação teórica e a implementação dos *scripts* centrais da nova ramificação do *pipeline*, junto de um *script* Gnuplot inicial validado por ensaio. O TCC III (2026/2) concentrou o desenvolvimento dos *scripts* Gnuplot restantes para cada tipo de visualização definido, a execução do *pipeline* completo sobre o Dataset 3 do Cloud Telescope e a análise crítica das visualizações produzidas em relação aos objetivos estabelecidos.

O cronograma a seguir apresenta a distribuição das etapas do plano de trabalho ao longo dos semestres de TCC II (2026/1) e TCC III (2026/2).

**Quadro 1 –** Cronograma de execução do TCC II

| **Atividade** | **01/2026** | **02/2026** | **03/2026** | **04/2026** | **05/2026** | **06/2026** |
|---|---|---|---|---|---|---|
| 1.a Revisão Bibliográfica | ● | ● | ● | | | |
| 1.b Estudo do Gnuplot | | | ● | ● | | |
| 2.a Configuração do Ambiente | | | ● | | | |
| 2.b Adaptação da Etapa de Sumarização | | | ● | ● | ● | |
| 2.c Desenvolvimento da Etapa de Geração de Dados | | | | ● | ● | ● |
| 2.d Desenvolvimento da Etapa de Geração de Gráficos | | | | | ● | ● |
| 4.b Redação do TCC | | ● | ● | ● | ● | ● |

**Quadro 2 –** Cronograma de execução do TCC III

| **Atividade** | **07/2026** | **08/2026** | **09/2026** | **10/2026** | **11/2026** | **12/2026** |
|---|---|---|---|---|---|---|
| 3.a Desenvolvimento dos *scripts* Gnuplot | ● | ● | | | | |
| 3.b Geração do Conjunto de Gráficos | | ● | ● | | | |
| 4.a Análise dos Gráficos | | ● | ● | ● | | |
| 4.b Redação do TCC | ● | ● | ● | ● | ● | |
| 4.c Formatação e Revisão Final | | | | | | ● |
| Entrega e Apresentação Final | | | | | | ● |

## 1.7 Análise de Riscos

Esta seção identifica as dependências e os riscos que podem afetar o planejamento original do trabalho, apresentando um plano de contingência para cada um deles.

**Quadro 3 –** Análise de riscos

| **Risco** | **Probabilidade** | **Impacto** | **Gatilho** | **Plano de contingência** |
|---|---|---|---|---|
| 1. Complexidade na integração com o *pipeline* de análise | Média | Alto | A adaptação do *pipeline* para gerar os arquivos `.json` e `.dat` resulta em erros persistentes ou dados inconsistentes, impedindo o avanço do trabalho. | Simplificar a abordagem, focando em gerar apenas um tipo de dado (ex: top 20 portas TCP) em um formato de texto simples. Se o problema persistir, desenvolver e depurar os *scripts* de forma isolada com uma amostra menor dos dados antes de reintegrá-los ao *pipeline* completo. |
| 2. Problemas de desempenho devido ao volume de dados | Alta | Alto | A execução dos *scripts* de processamento consome memória de forma excessiva devido à tentativa de carregar o *dataset* inteiro na memória RAM. | Manter a estratégia de processamento em modo *streaming* já empregada pelo *pipeline* original do Cloud Telescope de Beiler (2023), na qual cada *script* lê o *dataset* linha a linha via `sys.stdin` dentro de uma cadeia de *pipes* Unix, em vez de carregar o arquivo completo em memória. Essa abordagem desacopla o consumo de memória do volume total de pacotes, tornando-o dependente apenas da cardinalidade dos valores agregados (por exemplo, endereços IP de origem distintos). No ensaio com o *dataset3* (~80 GB, 530.914.922 pacotes), essa estratégia resultou em aproximadamente 1,83 milhão de IPs de origem únicos, ocupando cerca de 160 MiB de memória (medição empírica), um padrão de crescimento sub-linear que, extrapolado, sustentaria *datasets* ordens de grandeza maiores dentro de um orçamento de poucos gigabytes de RAM. |

# 2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os conceitos necessários para compreender o problema abordado e a solução proposta. A exposição parte do mais geral para o mais específico: primeiro a análise de tráfego de rede como campo de estudo, depois o fenômeno específico da IBR, em seguida os mecanismos de coleta (telescópios de rede e de nuvem), e por fim a ferramenta de visualização utilizada no desenvolvimento proposto por este trabalho.

## 2.1 Análise de Tráfego de Rede

A Análise de Tráfego de Rede (*Network Traffic Analysis*) consiste no processo de capturar, registrar e inspecionar os pacotes que trafegam em uma rede de computadores com o objetivo de extrair informações sobre o comportamento, a composição e as anomalias presentes nesse tráfego (Thakare; Pund, 2018). Ao examinar atributos como endereços de origem e destino, protocolos utilizados, portas acessadas e volume de dados transmitidos, é possível obter uma visão detalhada sobre quem se comunica com quem, de que forma e com que frequência.

A relevância da análise de tráfego de rede para a segurança cibernética decorre do fato de que a maior parte das atividades maliciosas na internet deixa rastros observáveis no nível do tráfego. Varreduras de portas, propagação de *malware*, ataques de negação de serviço e comunicação com servidores de comando e controle (*Command and Control* - C&C) de *botnets* produzem padrões de pacotes identificáveis, que divergem do comportamento esperado do tráfego legítimo (Männel *et al.*, 2025).

A análise de tráfego de rede moderna apoia-se em três técnicas complementares: estatística, mineração de dados e visualização. A abordagem estatística extrai métricas quantitativas, como médias, distribuições de frequência e percentuais por protocolo, que permitem caracterizar o tráfego de forma objetiva. A mineração de dados aplica algoritmos de aprendizado de máquina e agrupamento (*clustering*) para identificar padrões não óbvios em grandes volumes de dados. Por fim, de acordo com García-Peñas, Rodríguez-Gómez e Maciá-Fernández (2025), as técnicas de visualização traduzem esses dados numéricos em representações gráficas que permitem ao analista identificar tendências, anomalias e distribuições de forma intuitiva, tornando o tráfego de rede interpretável mesmo quando os volumes de dados são da ordem de centenas de milhões de pacotes. É nessa terceira vertente que o presente trabalho se insere.

Do ponto de vista técnico, a captura de tráfego de rede é realizada por ferramentas que operam em modo promíscuo na interface de rede, registrando todos os pacotes observados independentemente de seu destinatário legítimo. O formato binário predominante para o armazenamento dessas capturas é o PCAP (*Packet CAPture*), que preserva o conteúdo integral de cada pacote juntamente de metadados temporais com resolução de microssegundos. Ferramen-

tas como o TShark, a versão em linha de comando do Wireshark, permitem extrair e filtrar campos específicos dos cabeçalhos IP, TCP, UDP e ICMP de arquivos PCAP, convertendo-os em formatos tabulares adequados para análise estatística subsequente (Bortoluzzi, 2025).

A escala dos volumes de tráfego produzidos por sistemas de monitoramento em operação contínua impõe desafios consideráveis ao processo analítico. Arquivos de captura individuais podem acumular dezenas de gigabytes em períodos de horas, e o acervo histórico de uma infraestrutura de monitoramento ativa ao longo de anos pode superar facilmente a faixa dos terabytes. Nesse cenário, a inspeção manual dos dados torna-se impraticável, e a automação das etapas de processamento, incluindo a extração de métricas, a geração de sumários estatísticos e a produção de visualizações, converte-se em um requisito operacional para que o analista possa extrair inteligência de forma contínua e sistemática a partir do fluxo de dados capturado (Ismail *et al.*, 2025).

## 2.2 Radiação de Fundo da Internet

A Radiação de Fundo da Internet (IBR), também denominada tráfego *darknet*, compreende o conjunto de pacotes de rede não solicitados que alcançam qualquer endereço IP público e roteável na internet. Diferentemente do tráfego legítimo, que pressupõe uma interação prévia entre remetente e destinatário, os pacotes de IBR chegam sem que o *host* receptor os tenha requisitado (Irwin, 2011).

As origens da IBR podem ser agrupadas em três categorias principais. A primeira compreende as varreduras automatizadas de portas (*port scans*), conduzidas por *scanners* e *botnets* que percorrem sistematicamente faixas de endereços IP em busca de serviços vulneráveis ou dispositivos expostos. A segunda engloba as tentativas de propagação de *malware* e *worms*, que exploram falhas conhecidas para se disseminar autonomamente pela rede. A terceira corresponde ao retroespalhamento de ataques de negação de serviço (*DoS backscatter*): quando um atacante forja o endereço de origem de seus pacotes durante um ataque de inundação, as respostas das vítimas são redirecionadas para o endereço falsificado, gerando um fluxo secundário de tráfego não solicitado(García-Peñas; Rodríguez-Gómez; Maciá-Fernández, 2025).

A análise da IBR se consolidou como uma das principais fontes de inteligência sobre ameaças cibernéticas (*Cyber Threat Intelligence*). Por ser um fenômeno incessante e gerado de forma independente por agentes maliciosos ao redor do globo, os dados de IBR fornecem uma visão privilegiada sobre o estado atual das atividades hostis na internet: quais portas e protocolos são mais visados, de quais regiões geográficas partem as varreduras e como esses padrões evoluem ao longo do tempo (Munteanu *et al.*, 2025).

O retroespalhamento de ataques de negação de serviço (*DoS backscatter*) merece atenção especial dentre as categorias de IBR, pois representa um fenômeno de natureza distinta das varreduras ativas. Quando um atacante lança um ataque de inundação forjando o endereço IP

de origem dos pacotes, as respostas automáticas enviadas pelas vítimas fluem para o endereço falsificado. Caso esse endereço pertença ao espaço monitorado por um telescópio de rede, o sistema registra esse tráfego secundário sem ser o alvo real do ataque. A análise do *backscatter* constitui, assim, uma técnica consolidada para estimar a prevalência e a intensidade de ataques DDoS em andamento na internet, mesmo sem acesso direto aos sistemas atacados (García-Peñas; Rodríguez-Gómez; Maciá-Fernández, 2025).

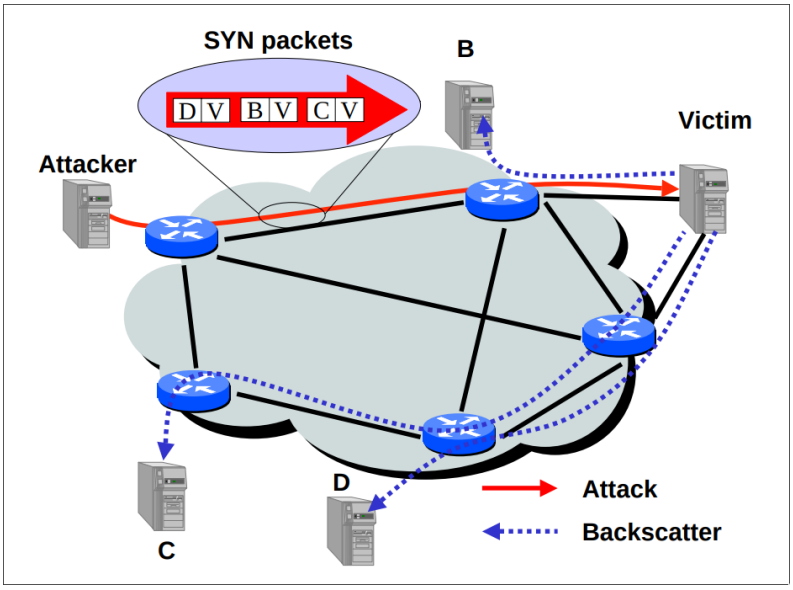



**Figura 2 –** Mecanismo de retroespalhamento (*DoS backscatter*): pacotes SYN com IP forjado redirecionam respostas das vítimas ao endereço falsificado, gerando IBR secundário visível ao telescópio. **Fonte**: Moore *et al.* (2006).

A composição da IBR sofreu transformações substanciais ao longo das últimas duas décadas, refletindo a evolução do panorama de ameaças cibernéticas. Nos anos 2000, o tráfego *darknet* era dominado por *worms* autorreplicantes, como o Slammer e o Blaster, que se propagavam explorando vulnerabilidades amplamente presentes nos sistemas da época sem qualquer intervenção humana. A partir da segunda metade da década de 2010, a proliferação de dispositivos da Internet das Coisas (*Internet of Things* - IoT) com configurações padrão inseguras trouxe uma nova categoria de ameaça dominante: as *botnets* de IoT. O expoente mais emblemático desse fenômeno é a *botnet* Mirai e suas variantes, responsáveis por varreduras massivas dirigidas às portas de gerenciamento remoto como Telnet (porta 23) e SSH (porta 22), padrão que se mantém como o de maior frequência absoluta nos dados de telescópios de rede contemporâneos (Griffioen *et al.*, 2024).

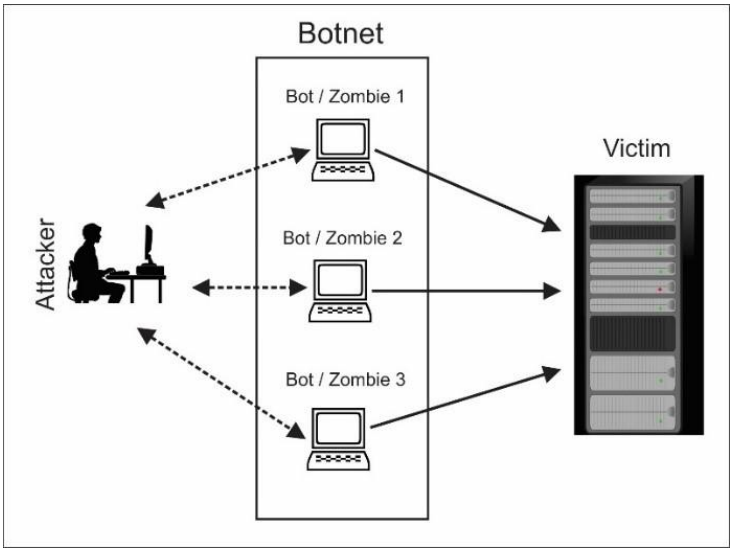



**Figura 3 –** Estrutura típica de uma *botnet*: dispositivos comprometidos coordenados pelo atacante para varreduras massivas, principal fonte de IBR capturado por telescópios de rede. **Fonte**: Beiler (2023).

## 2.3 Telescópio de Rede

O Telescópio de Rede (*Network Telescope*) é um sistema computacional configurado para receber e registrar passivamente o tráfego direcionado a um bloco de endereços IP públicos não utilizados ou ociosos (Irwin, 2011). A premissa é direta: como esses endereços não hospedam nenhum serviço legítimo, qualquer pacote que os alcance é, por definição, tráfego não solicitado (IBR). O telescópio opera de forma completamente passiva, sem responder aos pacotes recebidos, garantindo que sua presença não interfira no fenômeno observado.

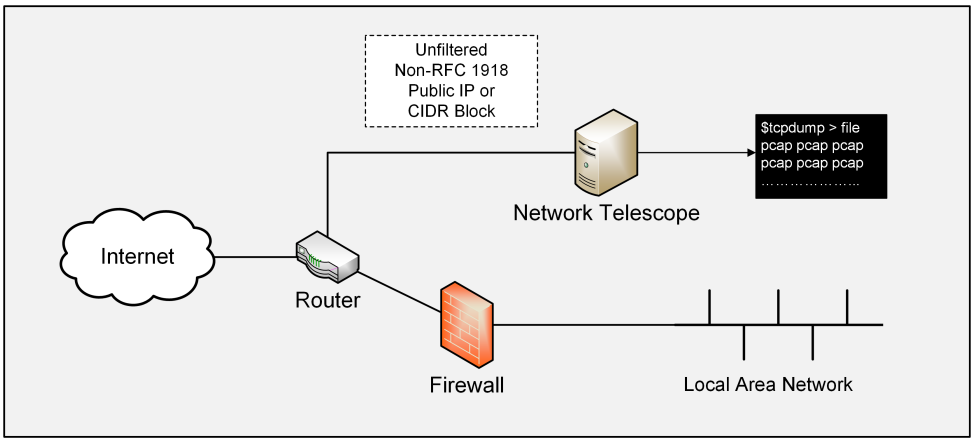



**Figura 4 –** Arquitetura genérica de um Telescópio de Rede: bloco de IPs ociosos exposto à internet captura passivamente toda IBR recebida em formato PCAP. **Fonte**: Irwin (2011).

A técnica se mostrou eficaz para capturar varreduras de larga escala e atividade de *botnets*, mas apresenta limitações intrínsecas que se tornaram progressivamente mais críticas. A principal delas é a escassez de endereços IPv4: com o esgotamento do espaço de endereçamento, torna-se inviável alocar novos blocos extensos exclusivamente para monitoramento passivo. Além disso, um telescópio de rede tradicional está vinculado a uma única localização

geográfica, o que impõe um viés geopolítico à coleta: apenas o tráfego direcionado àquele bloco específico é capturado, limitando a representatividade global dos dados (Bortoluzzi, 2025).

Na prática, um telescópio de rede captura e armazena em formato PCAP (*Packet CAPture*) os pacotes recebidos nos endereços monitorados, preservando o conteúdo integral de cada datagrama com metadados de alta resolução temporal. O volume de dados gerado por essa captura passiva é expressivo mesmo em blocos de endereços relativamente pequenos: um telescópio operando com 1.024 endereços IPv4 ao longo de um ano pode registrar mais de 4,7 bilhões de pacotes, totalizando centenas de gigabytes de dados brutos. Esse volume impõe a necessidade de um *pipeline* de processamento estruturado para transformar os arquivos PCAP brutos em informação analítica utilizável (García-Peñas; Rodríguez-Gómez; Maciá-Fernández, 2025).

Entre as implementações mais relevantes de telescópios de rede, destacam-se o UCSD Network Telescope (UCSD-NT), mantido pelo CAIDA (*Center for Applied Internet Data Analysis*) da Universidade da Califórnia em San Diego, e o Merit Network Telescope, operado pela organização Merit Network. O UCSD-NT, historicamente derivado de um bloco /8 da rede AMPRNet, monitora tráfego de rede há mais de duas décadas e seus dados sustentam parcela significativa da literatura acadêmica em segurança de redes. O Merit Network Telescope, por sua vez, acumula capturas contínuas desde 2005, compondo um arquivo histórico de quase vinte anos que viabiliza estudos longitudinais sobre a evolução das ameaças cibernéticas e a transformação dos padrões de tráfego *darknet* ao longo do tempo (Männel *et al.*, 2025).

## 2.4 Telescópio de Nuvem

O Telescópio de Nuvem (*Cloud Telescope*) foi proposto como resposta direta às limitações dos telescópios de rede tradicionais. Trata-se de uma arquitetura efêmera, distribuída e nativa da nuvem, descrita como Infraestrutura-como-Código (*Infrastructure-as-Code* - IaC), que utiliza a infraestrutura global dos Provedores de Serviços em Nuvem (*Cloud Service Providers* - CSPs) para provisionar, de forma automatizada, uma frota de sensores de captura em múltiplas regiões geográficas simultaneamente (Bortoluzzi, 2025).

A implementação do Cloud Telescope sobre a infraestrutura da Amazon Web Services (AWS) permite a operação de sensores em até 26 regiões distintas ao redor do mundo, cobrindo América do Norte, América do Sul, Europa, Ásia, Oceania e África. A natureza efêmera da arquitetura, em que os recursos computacionais são provisionados, utilizados para captura e depois descartados, elimina a necessidade de manter infraestrutura física permanente e contorna a escassez de endereços IPv4, aproveitando os endereços alocados pelos próprios CSPs (Beiler, 2023).

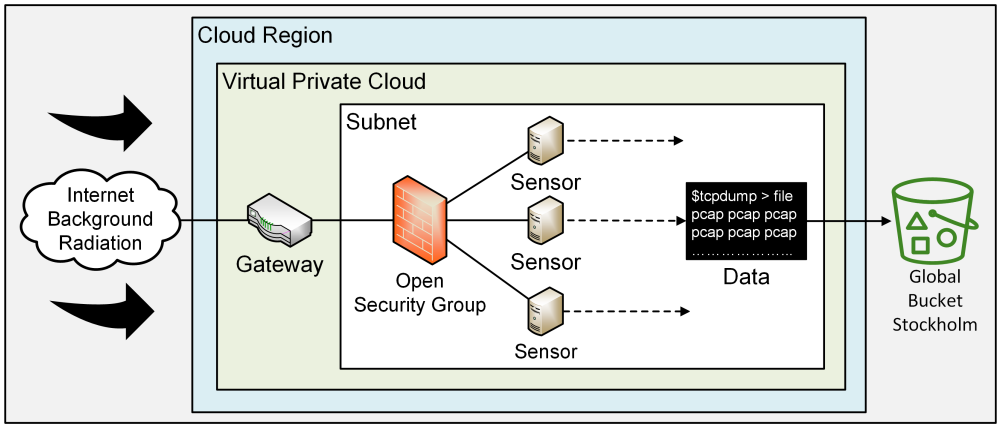



**Figura 5 –** Sensor do Cloud Telescope em região AWS: a IBR é capturada por sensores em VPC(*Virtual Private Cloud* - Rede Privada na Nuvem) com grupo de segurança aberto e os arquivos PCAP são exportados para *bucket* global na nuvem. **Fonte**: Bortoluzzi (2025).

O resultado é uma visão distribuída e sem limite geopolítico da IBR: em vez de observar o tráfego malicioso a partir de um único ponto da rede, o Cloud Telescope o captura simultaneamente de dezenas de perspectivas geográficas, produzindo *datasets* que refletem o estado real da atividade hostil em escala mundial. É precisamente o volume e a diversidade desses *datasets* que motivam a necessidade de visualizações automatizadas, objeto deste trabalho (Shyamkumar *et al.*, 2025).

Do ponto de vista da inteligência sobre ameaças, a vantagem mais expressiva do Telescópio de Nuvem em relação às arquiteturas tradicionais reside na capacidade de observar simultaneamente como uma mesma campanha de ataque se manifesta em diferentes regiões do planeta. Uma varredura de alcance global conduzida por uma *botnet*, por exemplo, é registrada pelo Cloud Telescope a partir de perspectivas geográficas simultâneas, o que permite inferir se determinados países ou regiões da AWS são alvos preferenciais ou se a atividade hostil é verdadeiramente distribuída sem viés geográfico detectável, análise impraticável com um telescópio estático restrito a um único ponto de observação (Bortoluzzi, 2025).




**Figura 6 –** Distribuição geográfica dos sensores do Cloud Telescope (*Dataset 3*) em regiões AWS da América, Europa, Oriente Médio, Ásia e Oceania, eliminando o viés geopolítico dos telescópios tradicionais. **Fonte**: Bortoluzzi (2025).

O volume de dados produzido por uma campanha de captura com o Cloud Telescope distribuída em 26 regiões da AWS exemplifica concretamente o gargalo analítico identificado na Problematização. Uma única campanha pode gerar centenas de gigabytes de arquivos PCAP brutos que, após o processamento pelo *pipeline* de análise e enriquecimento com dados de geolocalização, resultam em conjuntos estruturados contendo centenas de milhões de registros de pacotes. A amplitude e a granularidade desse volume de dados confirmam que a sumarização tabular, por si só, é insuficiente para revelar os padrões visuais, as correlações entre variáveis e as tendências temporais que as representações gráficas são capazes de evidenciar de forma direta e intuitiva (Bortoluzzi, 2025).

## 2.5 Pipeline ETL

*Extract, Transform, Load* (ETL) é o padrão canônico de processo pelo qual dados oriundos de uma ou mais fontes heterogêneas são extraídos, convertidos para um formato ou esquema comum e, por fim, carregados em um sistema de destino onde podem ser consultados, analisados ou utilizados por outras aplicações. O termo tem origem no contexto de *data warehousing*, em que sistemas operacionais distintos, cada um com sua própria estrutura de dados, precisam ser consolidados em uma base única e consistente; é justamente essa necessidade de conciliar heterogeneidade de origem com uniformidade de destino que torna o ETL um dos processos de *software* mais estudados na área de integração de dados (Vassiliadis, 2009).

O processo é tradicionalmente decomposto nas três etapas que lhe dão nome. A extração (*extract*) consiste em coletar os dados brutos das fontes originais, que podem ser bancos de dados relacionais, arquivos de log, APIs ou qualquer outro sistema produtor de dados; a transformação

(*transform*) aplica as operações necessárias para limpar, validar, reestruturar e converter esses dados ao formato exigido pelo destino, etapa em que inconsistências, duplicidades e erros das fontes originais são tipicamente tratados; e a carga (*load*) grava o resultado já transformado no sistema de destino, seja ele um *data warehouse*, um banco de dados analítico ou qualquer outro repositório estruturado (Babu; B., 2022).

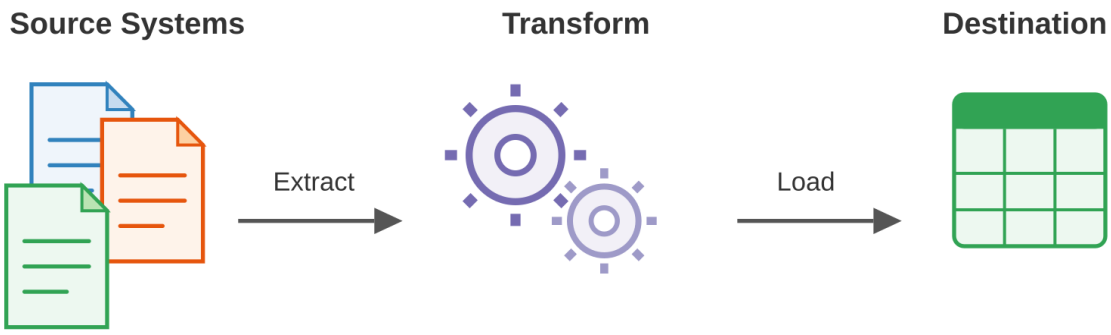



**Figura 7 –** Fluxo conceitual de um processo ETL: sistemas de origem são extraídos, transformados e carregados em um destino consolidado. **Fonte**: Babu e B. (2022).

Embora as três etapas sejam conceitualmente sequenciais, a literatura destaca que os desafios de um processo ETL não se restringem a cada etapa isolada: problemas como a frequência de atualização da base de destino, a garantia de qualidade e consistência dos dados ao longo de execuções sucessivas e a necessidade de modelar o processo inteiro de forma que seja compreensível, documentável e passível de manutenção perpassam o *pipeline* como um todo, e não apenas uma de suas fases (Vassiliadis, 2009).

Esse modelo de três etapas não é exclusivo de sistemas de *data warehousing* corporativos: ele descreve, em termos gerais, qualquer fluxo de processamento de dados em que informação bruta precisa ser coletada, reorganizada e disponibilizada em uma forma final utilizável, independentemente da escala ou do domínio de aplicação. É exatamente esse padrão de extração, transformação e carga que estrutura o *pipeline* de análise de IBR do Cloud Telescope detalhado no Capítulo 4, tanto em sua versão original quanto na versão modificada proposta por este trabalho: pacotes brutos capturados pelos sensores distribuídos na infraestrutura AWS são extraídos no formato PCAP, transformados pelas etapas de enriquecimento geográfico, sumarização e exportação para JSON, e carregados em uma forma final utilizável, tabelas em LaTeX no *pipeline* original, e, na versão modificada, o Gnuplot gerando, de forma automatizada, o conjunto de visualizações. O capítulo de desenvolvimento aplica, portanto, o mesmo padrão genérico aqui descrito ao domínio específico da radiação de fundo da internet.

## 2.6 Importância da Estatística e da Visualização de Dados

Antes de qualquer representação gráfica, a extração de sentido a partir de um conjunto de dados depende do raciocínio estatístico: a capacidade de reconhecer variação, identificar padrões e formular e testar explicações a partir de evidência empírica. Esse raciocínio não se resume à aplicação mecânica de fórmulas, mas envolve um ciclo investigativo completo, da formulação do problema à conclusão, que inclui etapas interrogativas de questionamento constante dos próprios dados; é esse processo, descrito como pensamento estatístico, que serve de base para qualquer investigação empírica que parta de dados brutos em busca de conhecimento (Wild; Pfannkuch, 1999).

Uma vez que os padrões estatisticamente relevantes de um conjunto de dados são identificados, resta o desafio de comunicá-los de forma eficaz, e é nesse ponto que a visualização de dados se torna indispensável. Informação estatística é, por natureza, abstrata, ela não corresponde a nenhum objeto físico diretamente observável, e a visualização de dados é o processo de traduzir essa abstração em atributos visuais concretos, como posição, comprimento, forma e cor, que o sistema perceptivo humano é capaz de processar rapidamente. Essa tradução só é bem-sucedida quando orientada por princípios derivados do entendimento da percepção humana, e não por escolhas puramente estéticas ou arbitrárias (Few, 2013).

O argumento a favor da visualização é especialmente evidente quando contrastado com a alternativa tabular: uma tabela de números é precisa e permite consultar valores pontuais com exatidão, mas falha justamente na tarefa em que a visualização é mais forte, a de revelar padrões, tendências ou exceções que emergem apenas quando o conjunto de dados é observado como um todo. Diante de um volume de dados que torna a inspeção direta impraticável, é a representação gráfica, e não a tabela, que permite ao observador extrair rapidamente o panorama geral que o pensamento estatístico busca caracterizar (Few, 2013).

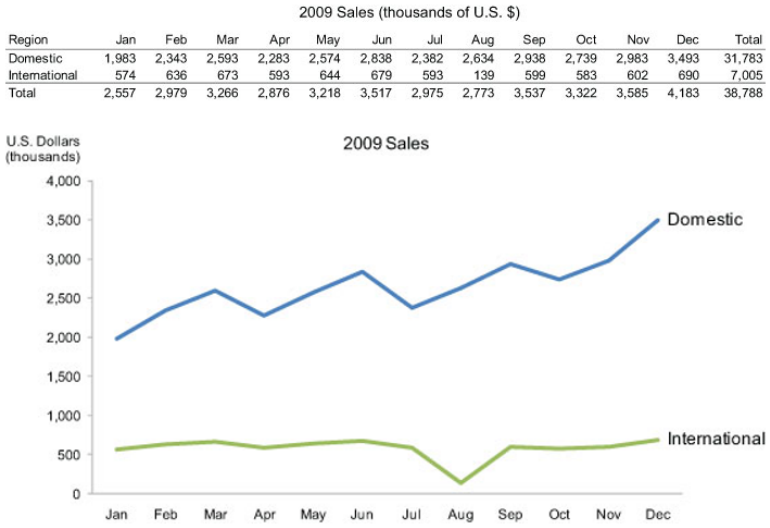



**Figura 8 –** O mesmo conjunto de dados de vendas representado como tabela e como gráfico de linha: a tendência de alta das vendas domésticas e a queda isolada das vendas internacionais em agosto só se tornam evidentes na forma gráfica. **Fonte**: Few (2013).

Estatística e visualização de dados cumprem, portanto, papéis complementares e sequenciais na análise de um conjunto de dados: a primeira fornece o arcabouço conceitual para reconhecer o que, dentro dos dados, é relevante e explicável; a segunda fornece o meio pelo qual esse conhecimento pode ser comunicado de forma rápida e compreensível. É essa complementaridade que justifica, em termos gerais, a automação da geração de representações gráficas como etapa final de qualquer *pipeline* de processamento de dados voltado à análise.

## 2.7 Gnuplot

O Gnuplot é uma ferramenta de visualização de dados orientada a *scripts*, de código aberto, com desenvolvimento ativo desde 1986 (Williams *et al.*, 2025). Ao contrário de bibliotecas modernas como Matplotlib e Seaborn, o Gnuplot não é embutido em uma linguagem de programação de propósito geral: é um programa independente, compilado em C, que recebe instruções por meio de arquivos de *script* (`.plt`) ou diretamente pela linha de comando e produz saídas gráficas em uma ampla variedade de formatos, incluindo PNG, PDF, EPS e SVG.

A sintaxe declarativa do Gnuplot permite especificar, em poucas linhas, a configuração completa de um gráfico: tipo de representação, rótulos, escalas, cores e formato de saída (Janert, 2016). O trecho abaixo ilustra um *script* que gera um histograma de barras a partir de um arquivo de dados tabulares:

```
set terminal pngcairo size 1200,600
set output 'histograma.png'
set title "Top 20 Portas TCP"
set xlabel "Porta de Destino"
set ylabel "Contagem de Pacotes (milhoes)"
```

```
set style fill solid 0.7
set xtics rotate by -45
plot 'dados.dat' using ($2/1e6):xtic(1) with histograms
```

**Código-fonte 1** – Exemplo de script Gnuplot

A característica que torna o Gnuplot particularmente atrativo para *pipelines* de análise automatizados é a sua operação inteiramente por linha de comando, sem interface gráfica. Um *script* `.plt` é executado com o comando `gnuplot script.plt`, produzindo o arquivo de imagem correspondente sem qualquer intervenção do usuário. Esse paradigma de geração em lote (*batch generation*) permite integrar o Gnuplot diretamente a fluxos de automação existentes, como *shell scripts* e *pipelines* de processamento de dados, o que o distingue conceitualmente de ferramentas interativas como Plotly ou ambientes como o Jupyter Notebook (Williams *et al.*, 2025).

A estabilidade e a padronização do formato de *script* do Gnuplot são tais que ferramentas de computação científica passaram a adotá-lo como formato de saída nativo: Melquiond (2021) desenvolveram uma biblioteca de plotagem com correção matemática formalmente verificada, implementada no assistente de provas Coq, cujos resultados são exportados diretamente em *scripts* Gnuplot, aproveitando sua capacidade de renderização reprodutível e sem estado de sessão interativa.

Do ponto de vista de eficiência de memória, o Gnuplot processa arquivos de texto sequencialmente, sem necessidade de carregar o conjunto de dados inteiro na memória principal (RAM - *Random Access Memory*) antes de iniciar a renderização. Isso o diferencia de soluções baseadas em Python, que tipicamente constroem estruturas de dados intermediárias (*DataFrames* ou listas) antes da plotagem, consumindo memória proporcional ao tamanho do *dataset*. Para *datasets* de IBR na ordem de gigabytes, essa característica tem impacto direto na viabilidade de execução em ambientes com recursos limitados (Janert, 2016).

### 2.7.1 Repertório de Estilos de Plotagem

O Gnuplot disponibiliza mais de duas dezenas de estilos de plotagem, organizados por Janert (2016) em categorias que refletem diferentes necessidades analíticas. O estilo é especificado por meio da cláusula `with` no comando `plot`, por exemplo, `plot 'dados.dat' with lines`. Os estilos mais relevantes para a análise de IBR são os histogramas de barras, as séries temporais e os mapas de calor, descritos a seguir.

#### *2.7.1.1 Histogramas e gráficos de barras*

Para a contagem de eventos discretos, categoria em que se enquadra diretamente a distribuição de portas TCP e UDP no tráfego de IBR, o FAQ oficial do Gnuplot confirma o suporte nativo aos estilos `boxes` e `histograms` como os mais adequados para histogramas de frequência

(Gnuplot Development Team, 2023). O estilo `boxes` plota uma barra de largura finita centrada em cada valor do eixo x, estendendo-se do eixo até o valor y correspondente, sendo indicado para *rankings* de portas de destino mais visadas. O estilo `impulses` plota linhas verticais a partir do eixo x até cada ponto de dado, útil para enfatizar valores individuais sem o peso visual de barras largas. A largura das barras pode ser definida globalmente com `set boxwidth` ou fornecida como terceira coluna no arquivo de dados. A Figura 9 ilustra esses estilos conforme a galeria oficial de demonstrações.

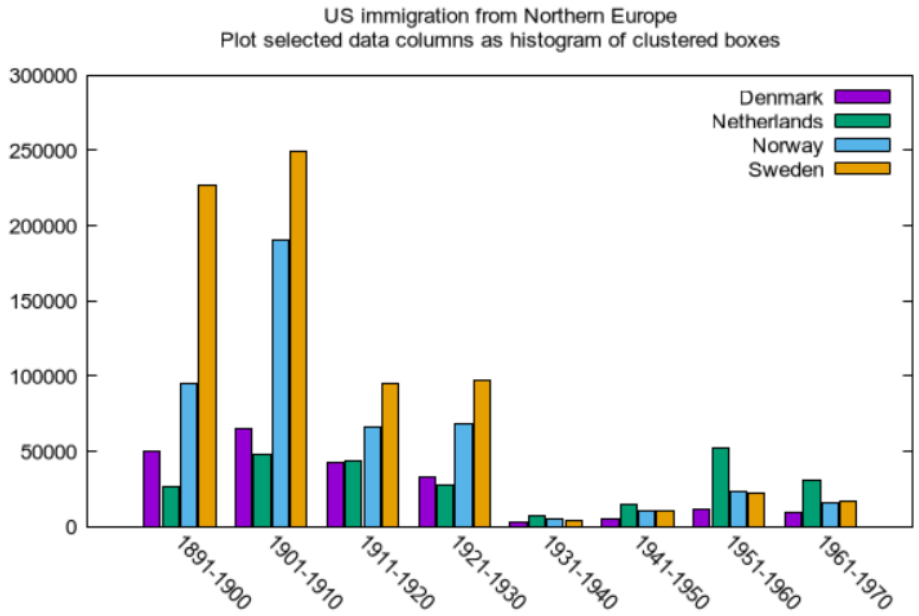



**Figura 9 –** Histograma de barras no Gnuplot com o estilo `histograms`: cada barra representa a frequência de um valor discreto. **Fonte**: Williams *et al.* (2025).

### *2.7.1.2 Séries temporais*

Para a análise da evolução temporal do tráfego de IBR, o Gnuplot oferece suporte nativo a eixos de tempo: com `set xdata time` e `set timefmt` é possível informar o formato da data presente no arquivo de dados, e o eixo x passa a exibir rótulos temporais formatados por `set format x` (Janert, 2016). Os estilos `lines` e `linespoints` são os mais utilizados para séries temporais contínuas, conectando observações em ordem cronológica. Para dados que permanecem constantes entre instantes de medição, como contagens de pacotes por período, o estilo `histeps` é mais preciso visualmente, pois representa o valor como um degrau centrado no intervalo correspondente. A Figura 10 exemplifica uma série temporal gerada com `linespoints` e eixo x temporal, extraída da galeria oficial de demonstrações do Gnuplot.

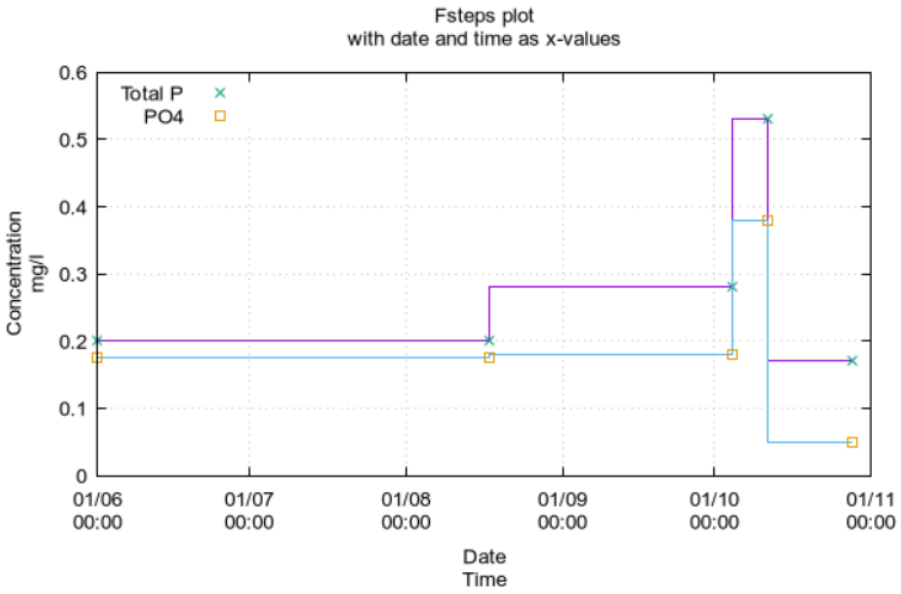



**Figura 10** – Série temporal no Gnuplot com `set xdata time` e estilo `linespoints`, conectando observações cronológicas com marcadores. **Fonte**: Williams *et al.* (2025).

### *2.7.1.3 Mapas de calor*

Para dados que dependem de duas variáveis independentes, o Gnuplot suporta mapas de calor (*heat maps*) por meio do comando `splot` com o modificador `with pm3d` (Janert, 2016). Nesse estilo, uma terceira variável é codificada por gradiente de cor sobre uma superfície tridimensional; quando o arquivo de dados contém uma quarta coluna, é possível mapear uma variável de cor *independente* do eixo z (recurso denominado dado *4D*) por meio da sintaxe `using 1:2:3:4 with pm3d`. No contexto da IBR, essa abordagem permite representar simultaneamente a origem geográfica do tráfego, o volume de pacotes e um atributo adicional, como a proporção de um protocolo ou a entropia das portas de destino. A Figura 11 ilustra esse estilo com um conjunto de dados de demonstração extraído da galeria oficial do Gnuplot.

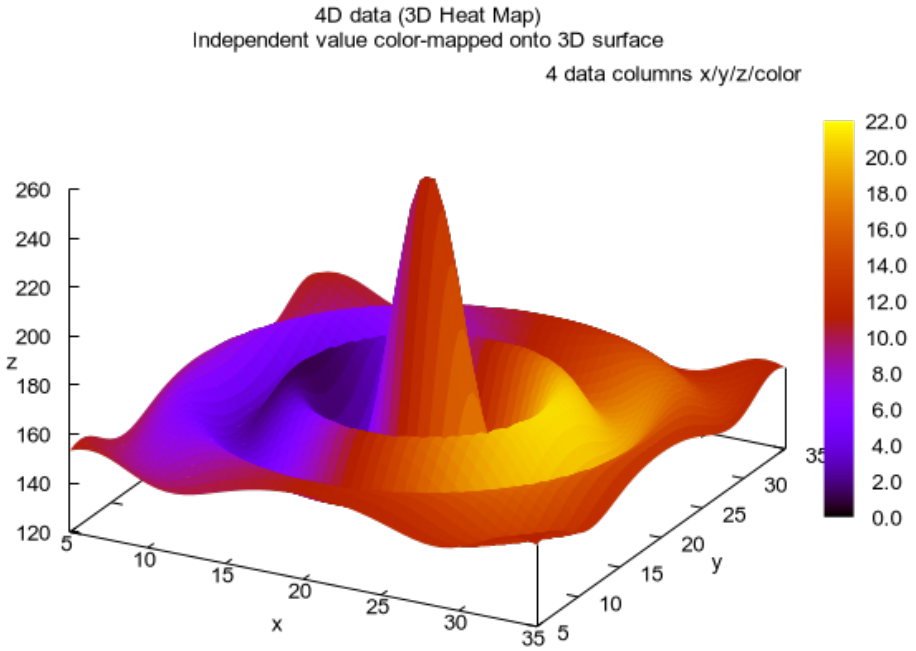



**Figura 11 –** Mapa de calor 4D no Gnuplot: superfície 3D com cor mapeada a partir de uma variável independente do eixo z, gerada com `splot` e `with pm3d`. **Fonte**: Williams *et al.* (2025).

### 2.7.2 Ensaio: Reprodução de Visualizações com Gnuplot

Como encerramento desta fundamentação, apresentam-se três ensaios práticos que demonstram a aplicabilidade do Gnuplot no contexto do Cloud Telescope. Em cada ensaio, uma representação tabular ou gráfica produzida de forma manual na tese de referência (Bortoluzzi, 2025) é confrontada com uma visualização gerada automaticamente pelo *pipeline* Python + Gnuplot desenvolvido neste trabalho.

O objetivo dos ensaios não é apresentar resultados analíticos definitivos, isso caberá ao TCC III, mas demonstrar que a cadeia de ferramentas funciona de ponta a ponta: o *script* de sumarização extrai e agrega os dados do CSV enriquecido, o módulo de geração de arquivos `.dat` estrutura os dados no formato exigido pelo Gnuplot, e o *script* `.plt` renderiza o gráfico com um único comando, sem intervenção manual.

#### *2.7.2.1 Ensaio 1: Série Temporal de Portas TCP*

O primeiro ensaio reproduz a Figura 30 da tese de referência (Bortoluzzi, 2025): a distribuição diária de tráfego TCP dirigido às portas 10000, 10001 e 10002, comportamento atípico identificado exclusivamente no Cloud Telescope. O gráfico original foi produzido manualmente via planilhas eletrônicas a partir dos dados sumarizados. A Figura 12 exibe o original; a Figura 13 apresenta a reprodução automatizada gerada pelo *pipeline* proposto neste trabalho.

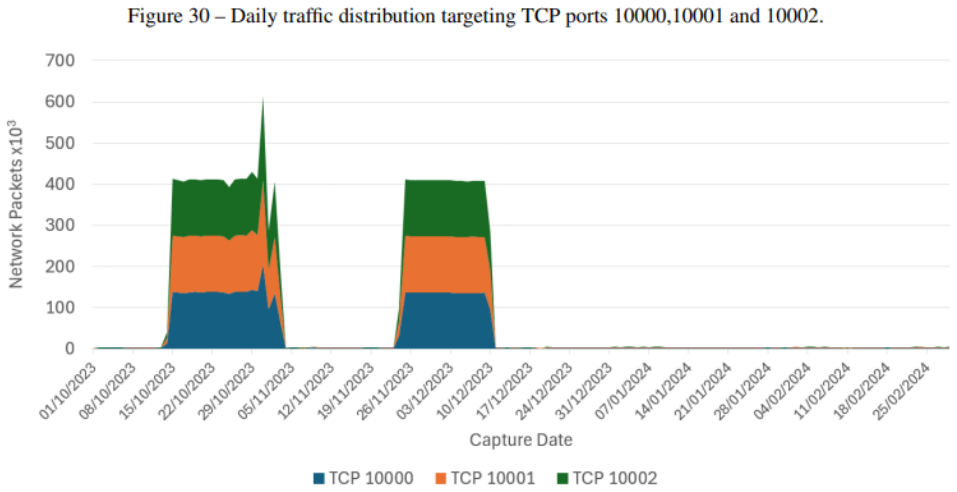



**Figura 12 –** Figura 30 da tese de Bortoluzzi (2025): distribuição diária de tráfego TCP nas portas 10000, 10001 e 10002, produzida manualmente via planilhas eletrônicas.

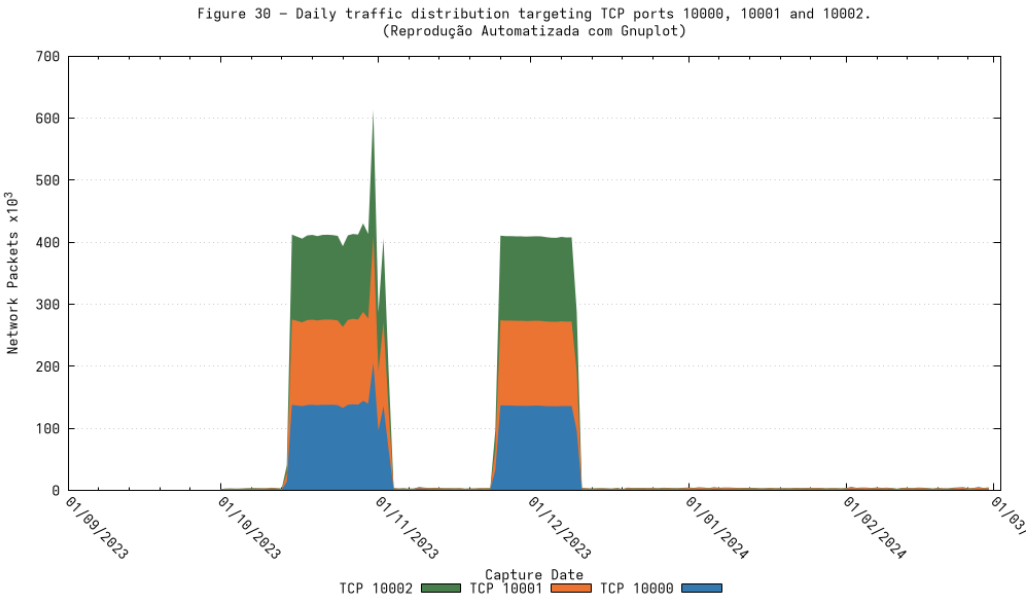



**Figura 13 –** Reprodução automatizada da Figura 30 de Bortoluzzi (2025), gerada pelo *pipeline* Python + Gnuplot a partir dos mesmos dados do Dataset 3.

### *2.7.2.2 Ensaio 2: Top 20 Origens de Radiação por País*

O segundo ensaio parte da Tabela 28 da tese de referência (Bortoluzzi, 2025): o ranking dos 20 países que mais geraram tráfego IBR no Dataset 3. Na forma tabular, os dados permitem identificar os países mais ativos, mas não evidenciam visualmente a disparidade entre os volumes. A Figura 14 exibe a tabela original; a Figura 15 apresenta o gráfico de barras gerado automaticamente pelo Gnuplot, tornando imediata a percepção da dominância dos Estados Unidos responsáveis por quase o dobro do volume do segundo colocado e da queda abrupta a partir da nona posição.

| Rank | Country | Count | % |
|---|---|---|---|
| 1 | United States | 169,249,433 | 31.88 |
| 2 | United Kingdom | 51,570,308 | 9.71 |
| 3 | China | 47,063,884 | 8.86 |
| 4 | Bulgaria | 37,510,860 | 7.07 |
| 5 | The Netherlands | 36,744,264 | 6.92 |
| 6 | Russia | 31,869,718 | 6.00 |
| 7 | Singapore | 29,909,254 | 5.63 |
| 8 | Germany | 29,267,184 | 5.51 |
| 9 | Indonesia | 13,180,679 | 2.48 |
| 10 | Hong Kong | 10,005,851 | 1.88 |
| 11 | Japan | 7,268,133 | 1.37 |
| 12 | South Africa | 6,420,366 | 1.21 |
| 13 | India | 5,623,995 | 1.06 |
| 14 | Ireland | 5,167,944 | 0.97 |
| 15 | Romania | 5,013,302 | 0.94 |
| 16 | France | 4,808,674 | 0.91 |
| 17 | Australia | 4,130,374 | 0.78 |
| 18 | South Korea | 3,699,848 | 0.70 |
| 19 | Brazil | 3,325,202 | 0.63 |
| 20 | Belgium | 2,209,498 | 0.42 |
| | Sub-total | 504,038,771 | 94.94 |
| | Total | 530,914,922 | 100.00 |

**Figura 14 –** Tabela 28 da tese de Bortoluzzi (2025) (p. 114): ranking dos 20 países mais ativos como origens de radiação no Dataset 3, apresentado em formato tabular.

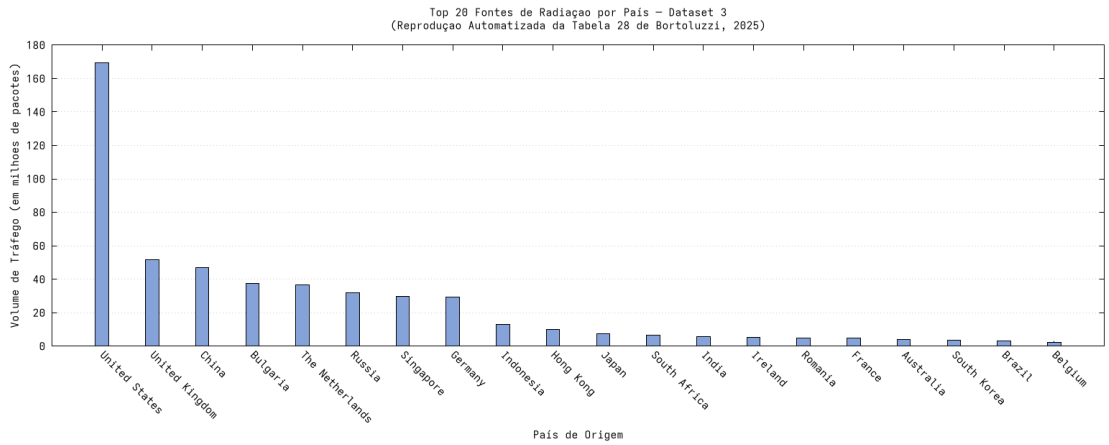



**Figura 15 –** Reprodução automatizada da Tabela 28 de Bortoluzzi (2025) como gráfico de barras gerado pelo Gnuplot, evidenciando visualmente a hierarquia entre os países de origem de IBR.

### *2.7.2.3 Ensaio 3: Top 20 Portas UDP de Destino*

O terceiro ensaio parte da Tabela 34 da tese de referência (Bortoluzzi, 2025): o ranking das 20 portas UDP mais visadas no Dataset 3. À semelhança do ensaio anterior, a representação

tabular lista os valores numericamente, mas a visualização em barras gerada pelo Gnuplot evidencia de forma intuitiva a concentração desproporcional na porta 5100, responsável por quase 6% de todo o tráfego UDP, e a distribuição mais uniforme das portas subsequentes, característica de um tráfego de ataque diversificado. A Figura 16 exibe a tabela original; a Figura 17 apresenta a reprodução automatizada.

| Rank | UDP Port | Count | % |
|---|---|---|---|
| 1 | 5100 | 1,121,200 | 5.91 |
| 2 | 5060 | 551,508 | 2.91 |
| 3 | 53 | 541,760 | 2.85 |
| 4 | 123 | 410,870 | 2.16 |
| 5 | 9993 | 403,120 | 2.12 |
| 6 | 161 | 305,246 | 1.61 |
| 7 | 1900 | 286,660 | 1.51 |
| 8 | 5353 | 237,173 | 1.25 |
| 9 | 1434 | 220,238 | 1.16 |
| 10 | 500 | 196,574 | 1.04 |
| 11 | 54321 | 168,690 | 0.89 |
| 12 | 6881 | 156,758 | 0.83 |
| 13 | 27015 | 152,184 | 0.80 |
| 14 | 11211 | 152,101 | 0.80 |
| 15 | 1194 | 148,808 | 0.78 |
| 16 | 443 | 133,434 | 0.70 |
| 17 | 137 | 133,144 | 0.70 |
| 18 | 5683 | 126,760 | 0.67 |
| 19 | 8080 | 126,714 | 0.67 |
| 20 | 8081 | 124,638 | 0.66 |
| | Sub-total | 5,697,580 | 30.01 |
| | Total | 18,982,971 | 100.00 |

**Figura 16 –** Tabela 34 da tese de Bortoluzzi (2025) (p. 122): ranking das 20 portas UDP mais visadas no Dataset 3, apresentado em formato tabular.

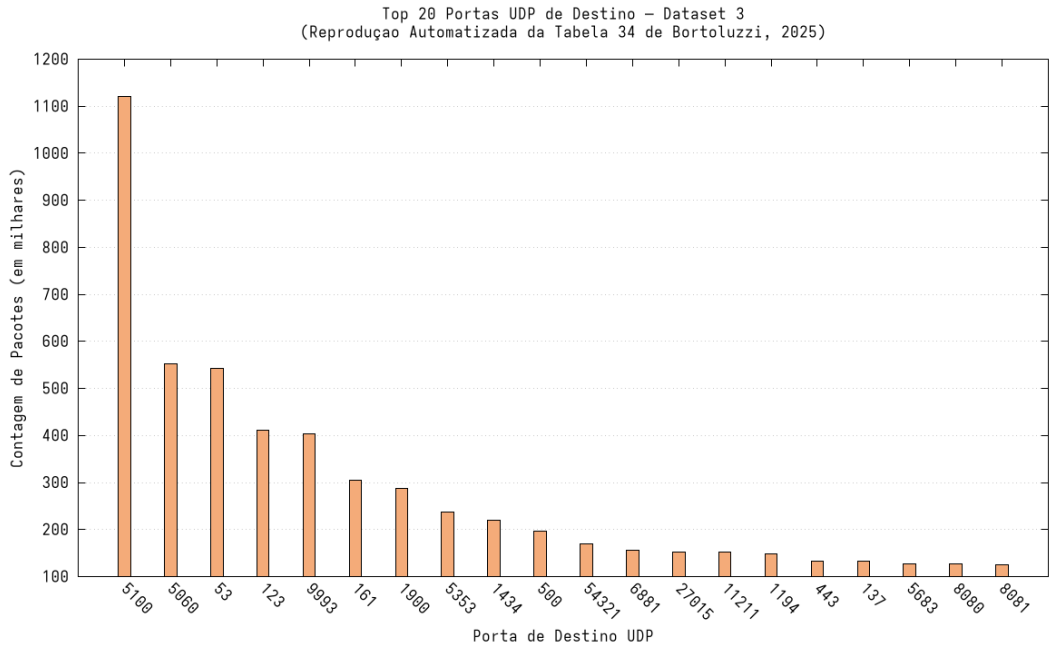



**Figura 17 –** Reprodução automatizada da Tabela 34 de Bortoluzzi (2025) como gráfico de barras gerado pelo Gnuplot, destacando a concentração atípica de tráfego na porta 5100 em relação às demais.

# 3 TRABALHOS RELACIONADOS

Este capítulo apresenta os principais trabalhos relacionados ao tema deste TCC, juntamente com os trabalhos de base do grupo de pesquisa da Univali. A seleção priorizou publicações que empregam técnicas de visualização semelhantes às adotadas neste trabalho, fornecendo referências de estudo e de viabilidade para as escolhas gráficas a implementar com o Gnuplot, os gráficos apresentados não constituem modelos a reproduzir de forma idêntica mas referências que orientam as decisões de representação.

## 3.1 Caracterização de IBR por Telescópio de Rede Sediado na Espanha

O trabalho de García-Peñas, Rodríguez-Gómez e Maciá-Fernández (2025) apresenta uma análise detalhada da Radiação de Fundo da Internet capturada por um telescópio de rede localizado na Espanha durante o ano de 2023, processando 4,7 bilhões de pacotes e aproximadamente 362 GB de tráfego em uma abertura de 1.024 endereços IPv4 (quatro redes /24). Um dos destaques é a decomposição estatística rigorosa dos protocolos: o tráfego TCP domina a IBR com 95,96% do volume, seguido pelo UDP (3,74%) e ICMP (0,51%), sendo que a quase totalidade do TCP (99%) consiste em pacotes de sinalização SYN sem *payload*, enquanto o UDP concentra os principais vetores de amplificação e reflexão, como ataques a serviços NTP e DNS.

O método de análise proposto por García-Peñas, Rodríguez-Gómez e Maciá-Fernández (2025) baseia-se na identificação de ”assinaturas”de ferramentas de escaneamento em massa. Os autores demonstram como distinguir o tráfego gerado por ferramentas como ZMap, MasScan e NMap a partir de campos específicos no cabeçalho IP e TCP, além de identificar padrões característicos da *botnet* Mirai. Do ponto de vista de visualização, o estudo emprega histogramas de barras para ranquear as portas TCP mais visadas e Mapas de Hilbert para representar a densidade dos endereços IP de origem, permitindo visualizar a ocupação do espaço de endereçamento global de forma compacta.

A relação deste estudo com o presente TCC reside na validação dos padrões de tráfego observados e na confirmação dos tipos de representação gráfica mais informativos. Os histogramas de barras com escala logarítmica e as séries temporais de volume diário de pacotes que os autores empregam são precisamente os estilos de plotagem que o Gnuplot implementa nativamente, validando as escolhas de representação gráfica adotadas neste TCC e demonstrando que a automação dessas visualizações, até então produzidas manualmente, constitui uma contribuição prática relevante.

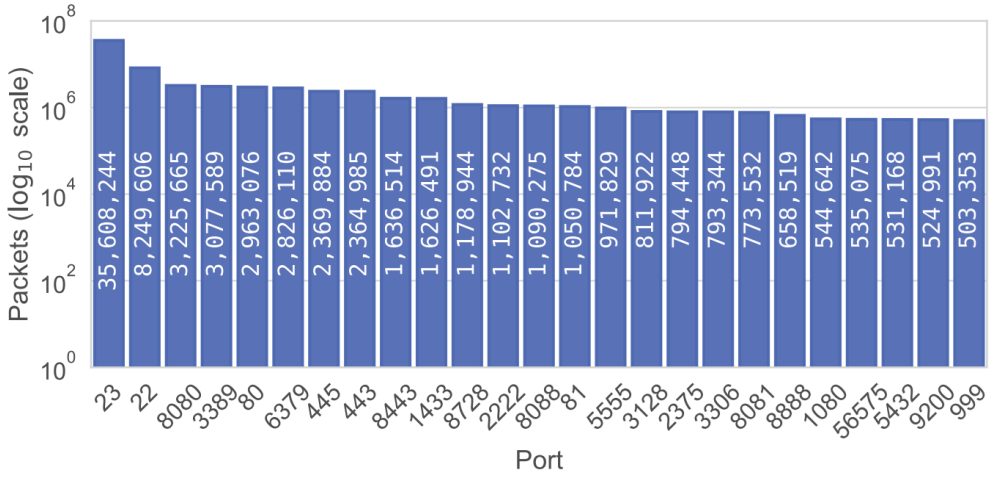



**Figura 18 –** Distribuição das 25 portas TCP mais visadas pelo telescópio de rede espanhol em outubro de 2023, em escala logarítmica. **Fonte**: García-Peñas, Rodríguez-Gómez e Maciá-Fernández (2025), Fig. 8, p. 10.

A dominância das portas 22 (SSH) e 23 (Telnet) no histograma confirma a presença predominante de varreduras associadas a *botnets* IoT como a Mirai, padrão que o *pipeline* proposto neste TCC deve ser capaz de reproduzir automaticamente via histograma no Gnuplot.

## 3.2 Análise Longitudinal de Vinte Anos de Dados de Telescópio de Rede

O trabalho de Ismail *et al.* (2025) apresenta uma análise longitudinal de quase vinte anos de dados de tráfego *darknet* coletados pelo Merit Network Telescope (ORION), cobrindo o período de 2005 a 2025. O estudo descreve uma infraestrutura de processamento robusta, necessária para lidar com um arquivo histórico de quase duas décadas, e propõe uma metodologia denominada *coarse-to-fine* para o tratamento dos dados. Essa abordagem divide o processamento em dois sub-pipelines: um de metadados de alto nível (mais leve, focado em estatísticas gerais como taxas de pacotes e tamanhos de arquivo) e um de cabeçalhos de pacotes (mais pesado, que extrai atributos detalhados como portas e *flags* TCP).

A metodologia *coarse-to-fine* de Ismail *et al.* (2025) é análoga à estratégia de sumarização adotada no *pipeline* do Cloud Telescope utilizado neste TCC. No entanto, uma diferença fundamental reside nas ferramentas de visualização e armazenamento. Enquanto o projeto ORION utiliza uma infraestrutura complexa baseada em bancos de dados de séries temporais (InfluxDB) e relacionais (MariaDB), com visualização via *dashboards* interativos no Grafana, o presente trabalho propõe uma alternativa baseada no Gnuplot. A escolha pelo Gnuplot visa oferecer uma solução de geração de gráficos em lote (*batch generation*) que seja leve, reprodutível e que não dependa da manutenção de servidores de banco de dados ativos para a produção de relatórios analíticos.

As visualizações apresentadas por Ismail *et al.* (2025) validam as escolhas gráficas deste TCC e evidenciam a escala do problema de automação. Os autores utilizam séries temporais para

exibir taxas de pacotes ao longo de décadas e histogramas de barras para identificar as portas de destino mais visadas. O acervo de quase vinte anos de capturas demonstra que a automação da geração de visualizações não é um conforto operacional, mas um requisito para que o ciclo de análise acompanhe o ritmo de geração de dados. A convergência entre os resultados do Merit Telescope e os padrões observados no Cloud Telescope reforça a relevância de gerar automaticamente essas mesmas representações a cada novo ciclo de coleta.

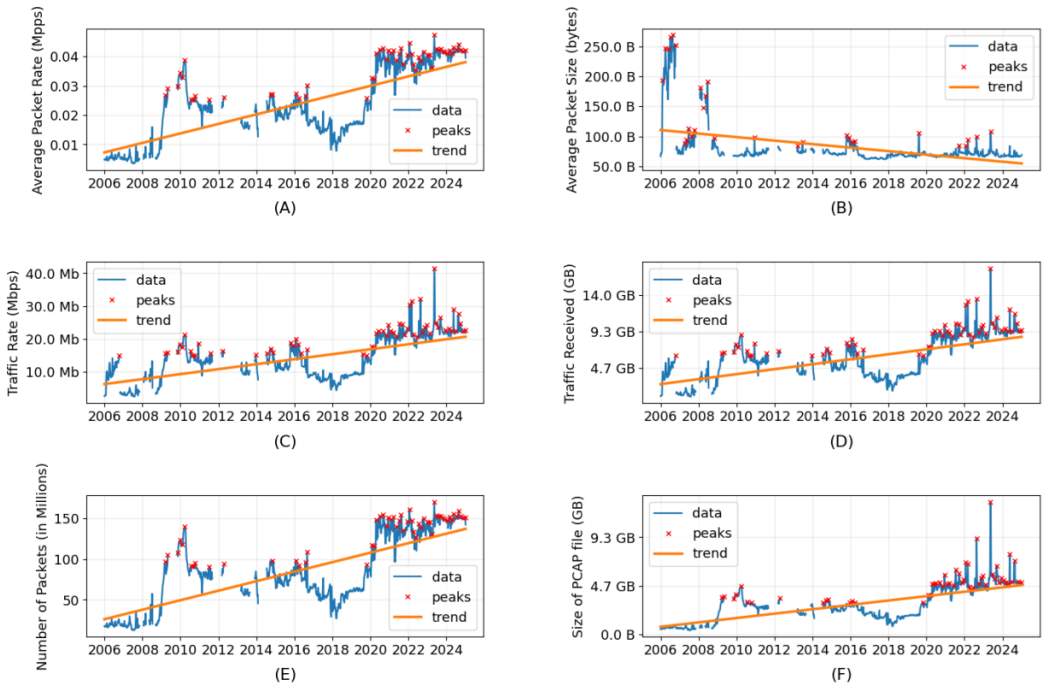



**Figura 19 –** Tendências longitudinais e picos de tráfego no *darknet* do ORION entre 2006 e 2024. **Fonte**: Ismail *et al.* (2025), Fig. 4, p. 5.

O painel exibe seis métricas complementares: taxa de pacotes em Mpps (A), tamanho médio de pacote em *bytes* (B), taxa de tráfego em Mbps (C), volume total mensal em GB (D), número de pacotes em milhões (E) e tamanho do arquivo PCAP em GB (F). O conjunto ilustra o tipo de série temporal de longo prazo, gerada automaticamente via Grafana no ORION, que o *pipeline* proposto neste TCC visa reproduzir com o Gnuplot sobre os dados do Cloud Telescope.

## 3.3 Caracterização Longitudinal de Dez Anos de Escaneamento na Internet

O trabalho de Griffioen *et al.* (2024) apresenta uma análise abrangente da evolução do ecossistema de escaneamento de portas na Internet ao longo de dez anos (2015 - 2024), com base em um *dataset* de mais de 45 bilhões de pacotes SYN coletados por um telescópio de rede composto por três blocos de endereços parcialmente populados de tamanho /16. O estudo agrupa os pacotes individuais em mais de 750 milhões de campanhas de escaneamento e analisa a evolução das ferramentas utilizadas, das portas visadas e das origens geográficas dos escaneadores ao longo da série histórica.

Uma das contribuições centrais do estudo é demonstrar que o ecossistema de escaneamento é extremamente volátil: as portas alvo e as principais campanhas mudam drasticamente na escala de semanas ou meses. Essa volatilidade implica diretamente na necessidade de avaliações longitudinais contínuas, uma vez que os autores concluem que mensurações realizadas em momentos isolados tendem a superestimar ou subestimar significativamente determinadas ferramentas, portas e grupos de atores, comprometendo a validade das análises pontuais. Do ponto de vista de visualização, o trabalho emprega histogramas de barras empilhadas normalizadas que distribuem o tráfego recebido nas portas mais visadas por categoria de escaneador (hospedagem, institucional, residencial, empresarial e desconhecido), revelando padrões distintos de comportamento por protocolo.

A relevância deste trabalho para o presente TCC é dupla. Por um lado, os histogramas de barras empilhadas, que distribuem o tráfego entre as portas mais visadas segmentadas por tipo de escaneador, são precisamente o tipo de gráfico que o Gnuplot reproduz nativamente. Por outro lado, a constatação de que o ecossistema muda na escala de semanas evidencia a necessidade de avaliações visuais contínuas e periódicas do tráfego capturado: é exatamente essa demanda por geração automatizada de visualizações que o *pipeline* proposto neste TCC busca atender sobre os dados do Cloud Telescope.

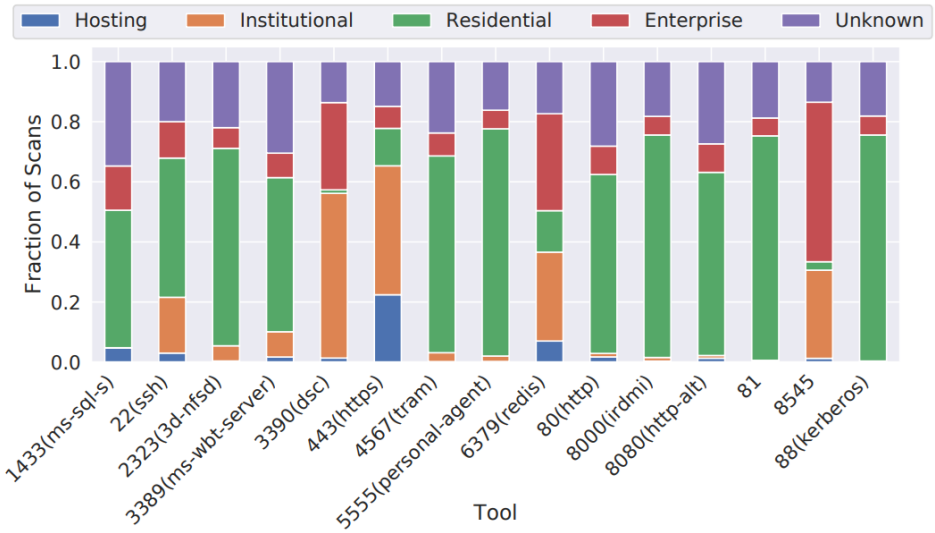



**Figura 20 –** Distribuição dos tipos de escaneador nas 15 portas TCP mais visadas. **Fonte**: Griffioen *et al.* (2024), Fig. 5, p. 159.

O gráfico revela padrões distintos por protocolo: o HTTPS (443/TCP) é predominantemente visado por escaneadores institucionais, enquanto a maioria das demais portas é dominada por origens residenciais. Este histograma de barras empilhadas normalizadas é o tipo de representação que o Gnuplot reproduz nativamente e que o *pipeline* deste TCC propõe-se a gerar automaticamente sobre os dados do Cloud Telescope.

## 3.4 Implementação do Cloud Telescope com Captura Distribuída de IBR

O trabalho de conclusão de curso de Beiler (2023), desenvolvido no mesmo grupo de pesquisa deste TCC na Univali, propõe e implementa a arquitetura do Cloud Telescope: uma infraestrutura de captura de IBR efêmera, distribuída e nativa da nuvem. A principal contribuição é o conjunto de artefatos de Infraestrutura-como-Código (IaC) em Terraform que automatiza a implantação de sensores em mais de 26 regiões da AWS, abrangendo uma distribuição geográfica sem precedentes em relação aos telescópios tradicionais. Além da captura passiva via PCAP, o trabalho implementou respondedores TCP ativos nas portas 23 (Telnet) e 80 (HTTP) como *honeypots*, coletando e identificando comandos de infecção das botnets Mirai, Mozi e Sora, demonstrando que a arquitetura é capaz não apenas de quantificar o volume de varreduras, mas também de caracterizar o comportamento das ameaças em nível de comando.

A relação deste trabalho com o presente TCC é direta: o *dataset* utilizado nesta pesquisa foi capturado pela infraestrutura implementada por Beiler (2023) e descrita em Bortoluzzi (2025). O próprio Beiler utilizou, para a análise dos dados coletados, banco de dados relacional PostgreSQL, consultas em Python e geração de gráficos com Matplotlib, abordagem que encontrou limitações nos períodos de maior volume de captura, quando a indexação completa tornou-se inviável. A ausência de uma camada de visualização automatizada, padronizada e integrada ao *pipeline* é, portanto, a lacuna que o presente TCC visa preencher: enquanto Beiler focou na concepção e validação da arquitetura de coleta, este trabalho concentra-se na etapa seguinte, transformando os volumes massivos de dados capturados em visualizações geradas automaticamente com o Gnuplot.

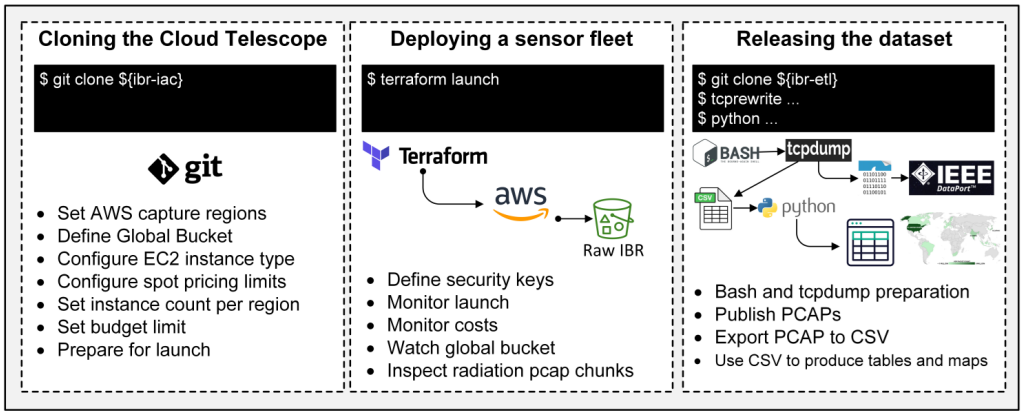



**Figura 21** – Fluxo completo do Cloud Telescope nas três fases de operação. **Fonte**: Bortoluzzi (2025), Fig. 17, p. 82.

O fluxo compreende: (1) clonagem da infraestrutura como código (*ibr-iac*) via *git* e configuração dos parâmetros de captura; (2) implantação da frota de sensores nas regiões AWS via Terraform e monitoramento da captura; (3) liberação do *dataset* via pós-processamento Python e exportação para CSV. O artefato de IaC em Terraform que implementa essas três fases foi

desenvolvido por Beiler (2023).

## 3.5 Avaliação da Pilha ELK para Visualização de IBR

O trabalho de conclusão de curso de Prudêncio (2026), desenvolvido no âmbito do mesmo grupo de pesquisa deste TCC na Univali, avalia a viabilidade da utilização da Pilha ELK (*Elasticsearch, Logstash e Kibana*) para a indexação e a visualização de eventos de Radiação de Fundo da Internet capturados pelo Cloud Telescope. Assim como o presente trabalho, a pesquisa de Prudêncio opera sobre o *dataset* gerado pela infraestrutura de captura distribuída implementada por Beiler (2023), tornando os dois projetos diretamente comparáveis em termos de insumo de dados. A pesquisa busca criar um ecossistema de visualização interativa que permite aos pesquisadores realizarem buscas semânticas, filtros dinâmicos e exploração dos dados em tempo real através do *dashboard* do Kibana, reproduzindo os padrões de tráfego documentados por Beiler sem a necessidade de escrever consultas ou scripts específicos para cada análise.

A principal distinção entre o TCC de Prudêncio e o presente trabalho reside no paradigma de visualização e no modelo operacional de cada proposta. A abordagem com a Pilha ELK é orientada à interatividade: pressupõe a manutenção de servidores Elasticsearch ativos para indexação contínua dos dados, oferecendo em troca a capacidade de exploração *ad hoc* por qualquer pesquisador com acesso ao Kibana. Em contraste, este TCC propõe o uso do Gnuplot para a geração de visualizações em lote (*batch generation*), operando diretamente sobre arquivos CSV sem depender de infraestrutura de indexação ativa. Essa diferença de paradigma torna os dois trabalhos complementares: enquanto a Pilha ELK atende à necessidade de exploração interativa e investigação pontual de eventos específicos, o Gnuplot atende à necessidade de automação contínua e geração padronizada de relatórios periódicos integrados diretamente ao *pipeline* de análise do Cloud Telescope.

## 3.6 Modelagem de Tráfego IBR com Grafos e Neo4j

O trabalho de conclusão de curso de Gubertt (2026), também desenvolvido no âmbito do grupo de pesquisa do Cloud Telescope na Univali, investiga a aplicação da Teoria dos Grafos e do banco de dados Neo4j para a análise e visualização de Radiação de Fundo da Internet através da transformação do *dataset* PCAP/CSV em modelos de grafo de propriedades (*property graph*). Utilizando a linguagem de consulta Cypher, o estudo demonstra como extrair inteligência cibernética por meio de topologias de ataque que representam países e sistemas autônomos como vértices interconectados por arestas ponderadas pelo volume de tráfego. Essa abordagem fundamenta-se na premissa de que padrões relacionais e correlações geopolíticas sutis, muitas vezes absorvidos como ruído estatístico em histogramas convencionais, tornam-se visualmente identificáveis quando os dados são representados como estruturas conectadas, permitindo uma caracterização mais profunda das comunidades de atacantes no tráfego IBR.

A relevância deste trabalho para o presente TCC reside na oferta de um paradigma complementar de visualização. Enquanto Gubertt foca na profundidade relacional e na exploração interativa de topologias via grafos no Neo4j, este trabalho concentra-se na automação da geração de visualizações estatísticas padronizadas (histogramas e séries temporais) via Gnuplot. Ambos os trabalhos utilizam o mesmo insumo de dados, mas atendem a diferentes necessidades analíticas: o trabalho de Gubertt é voltado para a descoberta de padrões estruturais complexos, enquanto a presente proposta visa garantir a observabilidade contínua e automatizada do volume e da distribuição do tráfego através de um *pipeline* leve e sem dependência de bancos de dados ativos.

## 3.7 Quadro de Trabalhos Relacionados

**Quadro 4 –** Comparação dos principais trabalhos relacionados

| **Autor** | **Fonte / Infraestrutura** | **Tamanho da amostra** | **Período de análise** | **Ferramenta de visualização** | **Contribuição principal** |
|---|---|---|---|---|---|
| García-Peñas, Rodríguez-Gómez e Maciá-Fernández (2025) | Telescópio espanhol (4x /24 IPv4) | 4,7 bilhões de pacotes (~362 GB) | 2023 (12 meses) | Histogramas de barras; Mapas de Hilbert | Caracterização de IBR com identificação de assinaturas de ferramentas de escaneamento em massa |
| Ismail *et al.* (2025) | Merit Network Telescope (ORION) | Não informado (~20 anos de arquivo) | 2005–2025 (20 anos) | Grafana (InfluxDB + MariaDB) | Metodologia *coarse-to-fine* para processamento de arquivo histórico longitudinal |
| Griffioen *et al.* (2024) | Telescópio 3x /16 parcialmente populado | +45 bilhões de pacotes SYN; 750 milhões de campanhas | 2015–2024 (10 anos) | Histogramas de barras empilhadas normalizadas | Caracterização da volatilidade do ecossistema de escaneamento ao longo de uma década |
| Beiler (2023) | AWS Cloud Telescope (IaC Terraform, 26+ regiões) | Não informado | 2023 | Matplotlib (Python) | Arquitetura IaC do Cloud Telescope; *honeypots* nas portas 23 e 80; botnets Mirai, Mozi e Sora |
| Prudêncio (2026) | Cloud Telescope (AWS, 26 regiões) | 530 milhões de pacotes | Out. 2023 – Mar. 2024 | Kibana (Pilha ELK) | Dashboard interativo para exploração *ad hoc* de IBR via Elasticsearch |
| Gubertt (2026) | Cloud Telescope (AWS, 26 regiões) | 530 milhões de pacotes | Out. 2023 – Mar. 2024 | Neo4j (grafos de propriedades, Cypher) | Análise relacional e geopolítica de IBR via Teoria dos Grafos com Neo4j |
| Este trabalho | Cloud Telescope (AWS, 26 regiões) | Dataset do Cloud Telescope | Pode ser executado em qualquer dataset gerado pelo Cloud Telescope do grupo de pesquisa | Gnuplot (*pipeline* automatizado em lote) | Automação de visualizações padronizadas integrada ao *pipeline* do Cloud Telescope |

Fonte: Elaborado pelo autor (2026).

Em síntese, os trabalhos examinados neste capítulo cobrem três eixos complementares ao presente TCC. No âmbito da caracterização do IBR, García-Peñas, Rodríguez-Gómez e Maciá-Fernández (2025), Ismail *et al.* (2025) e Griffioen *et al.* (2024) documentam padrões de tráfego que validam as escolhas de representação gráfica adotadas: histogramas de barras e séries temporais são os tipos de visualização mais recorrentes nessas pesquisas. No âmbito da infraestrutura de coleta, Beiler (2023) implementou a arquitetura do Cloud Telescope e revelou a lacuna de automação na camada de análise, ao recorrer ao Matplotlib de forma pontual e sem integração ao *pipeline*. No âmbito das ferramentas de visualização aplicadas ao mesmo *dataset*

do Cloud Telescope, Prudêncio (2026) avaliou a Pilha ELK para exploração interativa, e Gubertt (2026) avaliou o Neo4j para análise relacional por grafos. O presente trabalho completa esse conjunto ao avaliar o Gnuplot como alternativa para a geração automatizada em lote de visualizações padronizadas: mais leve que a Pilha ELK, sem dependência de banco de dados ativo, e integrado diretamente ao *pipeline* de análise do Cloud Telescope.

# 4 DESENVOLVIMENTO

Este capítulo descreve o desenvolvimento do *pipeline* de geração automatizada de visualizações proposto neste trabalho. Inicialmente, apresenta-se a arquitetura do *pipeline* de análise do Cloud Telescope antes e após as modificações realizadas. Em seguida, detalham-se os *scripts* implementados em cada nova etapa, com destaque para os trechos de código centrais da automação. Por fim, expõe-se o critério adotado na seleção dos tipos de gráfico implementados.

Tanto a definição dos padrões de tráfego a serem visualizados quanto a discussão dos resultados obtidos priorizam a consulta a publicações da *Internet Measurement Conference* (IMC), conferência de referência da *Association for Computing Machinery* (ACM) na área de medição de tráfego de Internet e fonte de inspiração direta deste trabalho, incluindo os *proceedings* completos das edições recentes (Vallina-Rodríguez *et al.*, 2024; Barford; Balasubramanian; Dainotti, 2025) e artigos nelas publicados (Griffioen *et al.*, 2024; Munteanu *et al.*, 2025; Shyamkumar *et al.*, 2025).

A fim de contextualizar as contribuições deste trabalho, as Figuras 22 e 23 apresentam a arquitetura do *pipeline* de análise do Cloud Telescope antes e após as modificações propostas.

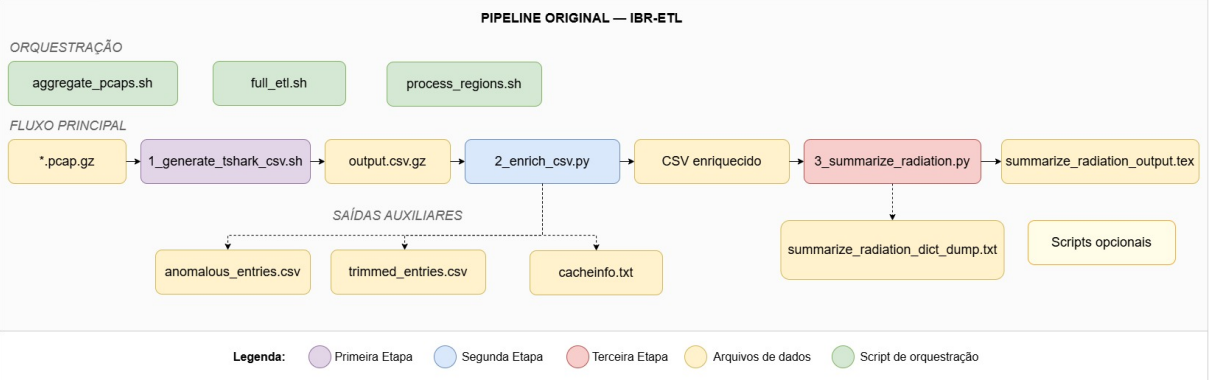



**Figura 22 –** *Pipeline* original de análise de IBR do Cloud Telescope.

O *pipeline* original é composto por quatro etapas sequenciais. A etapa inicial coleta os pacotes capturados pelos sensores implantados nas diversas regiões da AWS, transmitidos ao ambiente de análise no formato PCAP. Em seguida, o TShark realiza o pré-processamento, extraindo os campos relevantes de cada pacote e consolidando-os em arquivos CSV estruturados. A sumarização é então executada pelo *script* `3_summarize_radiation.py`, que agrega as contagens por protocolo, porta, país de origem e demais atributos de interesse, produzindo como produto final tabelas no formato LaTeX.

O ponto crítico identificado nesse fluxo é a ausência de qualquer etapa dedicada à geração de visualizações gráficas. Toda a análise produzida pelo *pipeline* original limita-se a tabelas textuais, o que dificulta a identificação visual de padrões, tendências e anomalias no tráfego

de IBR, especialmente considerando o volume de dados coletados por um telescópio de rede distribuído globalmente. É essa lacuna que o *pipeline* modificado propõe suprir.

O *pipeline* modificado (Figura 23) estende o fluxo original com uma nova ramificação que parte da etapa de sumarização e culmina na geração automatizada de visualizações.

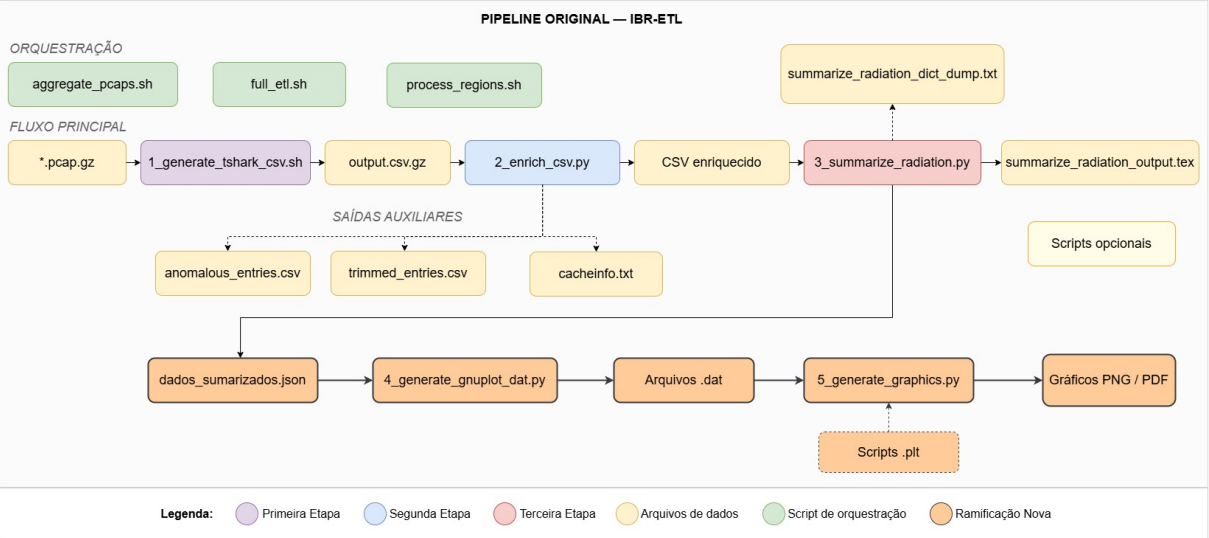



**Figura 23 –** *Pipeline* modificado proposto por este trabalho.

A ramificação introduzida tem início na etapa de sumarização existente, representada pelo nó de cor vermelha na Figura 23: o *script* `3_summarize_radiation.py` é adaptado para exportar, adicionalmente, os dados sumarizados em um arquivo JSON. Essa exportação paralela não interfere nas tabelas LaTeX já produzidas, ela apenas adiciona uma nova saída que serve de ponto de entrada para as etapas seguintes. É a partir desse JSON que a nova ramificação do *pipeline* se desdobra.

A nova ramificação, indicada pelos nós de cor laranja, constitui a contribuição técnica central deste trabalho. O *script* `4_generate_gnuplot_dat.py` lê o JSON e produz os arquivos `.dat` formatados para o Gnuplot, organizando os dados por tipo de gráfico. Em seguida, o *script* `5_generate_graphics.py` automatiza a execução de todos os *scripts* Gnuplot (`.plt`) disponíveis, invocando-os em sequência e coletando as imagens resultantes. Como resultado, a execução do *pipeline* modificado regenera o conjunto completo de visualizações, sem intervenção manual.

Por ser construído sobre o schema CSV padronizado produzido pela IaC do Cloud Telescope, que permanece idêntico entre capturas, o *pipeline* é replicável para qualquer dataset gerado pela infraestrutura. Uma vez concluído com todos os ajustes e gráficos implementados, a execução sobre um novo dataset requer apenas rodar os três scripts em sequência; o tempo de processamento do script de sumarização escala proporcionalmente ao volume de dados capturado, mas nenhuma adaptação de código é necessária.

## 4.1 Descrição do Pipeline Modificado

As três etapas que compõem a nova ramificação do *pipeline*, apresentada anteriormente neste capítulo, foram implementadas pelo autor deste trabalho, sob orientação do professor Fabricio Bortoluzzi. Os parágrafos a seguir detalham, *script* a *script*, o funcionamento de cada componente da nova ramificação.

A adaptação do módulo de sumarização (`3_summarize_radiation.py`) consistiu em incluir, ao final da execução já existente, uma rotina que serializa os dicionários de contagem já calculados, como as contagens por porta TCP e UDP de destino e por país de origem, em um arquivo `summaries.json`. Essa serialização ocorre em paralelo à geração das tabelas LaTeX já produzidas pelo *script* original, sem alterar sua lógica existente: o JSON é apenas uma nova saída, produzida ao final da rotina de sumarização. O Código 2 ilustra, de forma simplificada, essa rotina.

```
def save_summaries_to_json():
    """Salva os principais dicionarios de contagem em um arquivo JSON."""
    all_summaries = {
        "count_tcpdstport": count_tcpdstport,
        "count_udpdstport": count_udpdstport,
        "count_icmptype": count_icmptype,
        "count_source_country_name": count_source_country_name,
        "count_aws_region": count_aws_region,
        # ... demais contadores omitidos por brevidade
    }
    with open('summaries.json', 'w') as f:
        json.dump(all_summaries, f, indent=4)
```

**Código-fonte 2** – Rotina de exportação dos dicionários de contagem para JSON (trecho simplificado de `3_summarize_radiation.py`).

O módulo de geração de arquivos `.dat` (`4_generate_gnuplot_dat.py`) é um novo *script* que lê o `summaries.json` e, para cada tipo de visualização, extrai o dicionário de contagens correspondente, ordena os itens em ordem decrescente e grava um arquivo `.dat` próprio com as vinte maiores ocorrências, no formato de colunas separadas por espaço esperado pelo Gnuplot. Rótulos textuais com espaços, como nomes de países, são delimitados por aspas no arquivo de saída para que o Gnuplot os trate como um único rótulo de eixo. O Código 3 apresenta a função responsável por esse formato de arquivo, reaproveitada por todos os gráficos de *ranking* (portas TCP, portas UDP, países de origem, entre outros).

```
def write_topn_dat(filename, data_dict, n=20, header="# Categoria Contagem"
    ):
    """Escreve as N categorias de maior contagem em ordem decrescente."""
    with open(filename, 'w') as f:
        f.write(header + "\n")
        sorted_items = sorted(data_dict.items(),
```

```
                                key=lambda item: int(item[1]), reverse=True)
        for category, count in sorted_items[:n]:
            f.write(f"{category} {count}\n")
```

**Código-fonte 3** – Geração de um arquivo `.dat` de *ranking* a partir de um dicionário de contagens (`4_generate_gnuplot_dat.py`).

O *script* gera, portanto, um arquivo `.dat` distinto para cada tipo de gráfico, cada um consumido por um *script* `.plt` correspondente que sabe exatamente como interpretar suas colunas: essa separação entre a etapa de preparação dos dados e a etapa de plotagem é o que permite que cada visualização seja regenerada de forma independente, bastando reexecutar o par `.dat`/`.plt` correspondente. Ao todo, o *pipeline* modificado produz 30 arquivos `.dat`, cada um com seu *script* `.plt` dedicado, cobrindo desde *rankings* simples, como as vinte portas TCP e UDP mais visadas e os vinte países mais ativos como fonte e destino de radiação, até cruzamentos mais elaborados, como a série temporal diária de portas monitoradas e o cruzamento entre os países de origem mais ativos e suas portas TCP mais visadas.

A etapa de automação da geração de gráficos (`5_generate_graphics.py`) é responsável por varrer o diretório de trabalho em busca de todos os *scripts* Gnuplot (`.plt`) disponíveis, cada um já configurado para ler o seu arquivo `.dat` correspondente, e executá-los sequencialmente, invocando o interpretador `gnuplot` para cada um deles, registrando o sucesso ou a falha de cada execução e reportando ao final um resumo com o total de gráficos gerados. O Código 4 apresenta o núcleo dessa automação: a função que invoca o Gnuplot sobre um único *script* `.plt` e a rotina principal que a aplica a todos os arquivos encontrados.

```
def run_gnuplot(plt_file):
    """Executa um script Gnuplot. Retorna True se bem-sucedido."""
    result = subprocess.run(["gnuplot", str(plt_file)],
                            cwd=SCRIPT_DIR, capture_output=True, text=True
   )
    return result.returncode == 0

def main():
    plt_files = sorted(SCRIPT_DIR.glob("*.plt"))
    sucesso = sum(run_gnuplot(f) for f in plt_files)
    falhas = len(plt_files) - sucesso
    print(f"Concluido: {sucesso} gerado(s), {falhas} falha(s).")
```

**Código-fonte 4** – Execução automatizada de todos os *scripts* Gnuplot do diretório de trabalho (trecho simplificado de `5_generate_graphics.py`).

É essa etapa que permite ao pesquisador regenerar o conjunto completo de visualizações com um único comando, sem qualquer intervenção manual, contribuição que caracteriza o *pipeline* modificado como um fluxo de geração em lote (*batch generation*).

Com os 25 pares `.dat`/`.plt` implementados, o *pipeline* modificado foi executado de

ponta a ponta sobre a totalidade do Dataset 3 do Cloud Telescope, produzindo o conjunto completo de 25 visualizações discutido no Capítulo 5.

### 4.1.1 Critério de Seleção dos Gráficos

O Gnuplot oferece um repositório amplo de tipos de gráfico: a galeria oficial de demonstrações da versão 6.0 catalogava, em consulta realizada em setembro de 2026, 152 exemplos distintos, cobrindo desde estilos básicos de gráficos 2D até visualizações 3D, estatísticas e aplicações especializadas (Gnuplot Development Team, 2026). Diante dessa amplitude, a seleção dos tipos de gráfico implementados neste trabalho tomou como base três fontes. A primeira são os gráficos elaborados manualmente pelo grupo de pesquisa a partir de planilhas Excel, como o total diário de pacotes por mês de captura: o objetivo foi recriar esses mesmos gráficos de forma automática, eliminando a etapa manual, o que é verificado na Seção 5.1.1. A segunda são os trabalhos relacionados apresentados no Capítulo 3, que empregam séries temporais de volume diário de pacotes e histogramas de barras das portas mais visadas (Ismail *et al.*, 2025). A terceira são as publicações da IMC, como os histogramas de barras empilhadas com que Griffioen *et al.* (2024) segmentam o tráfego das portas mais visadas por tipo de escaneador.

Além desses três critérios, foi realizada uma implementação exploratória das possibilidades de representação oferecidas pelo Gnuplot, na qual os mesmos dados sumarizados pelo *pipeline* ETL foram representados por uma série de estilos de gráfico diferentes, a fim de verificar até onde a ferramenta consegue chegar na visualização desses dados.

Cada tipo de gráfico selecionado corresponde a um *script* `.plt` próprio, responsável por configurar a aparência da visualização e emitir o comando de plotagem sobre o arquivo `.dat` correspondente. O Código 5 apresenta um desses *scripts* na íntegra, responsável pela série temporal de pacotes por dia nas portas TCP monitoradas (10000/10001/10002): configura o terminal de saída e o arquivo PNG gerado, o título e os rótulos dos eixos, o tratamento do eixo X como série temporal e, por fim, o comando `plot`, que lê três colunas do arquivo `.dat` e desenha uma linha para cada porta acompanhada.

```
# Série temporal: pacotes por dia nas portas TCP 10000/10001/10002

set terminal pngcairo size 1600,800 enhanced font "Verdana,12"
set output 'grafico_serie_temporal_portas.png'

set title "Pacotes de Radiação IBR por Dia - Portas TCP 10000/10001/10002"
set xlabel "Data"
set ylabel "Contagem de Pacotes"
set grid ytics
set key top right

set xdata time
set timefmt "%Y-%m-%d"
```

```
set format x "%b/%y"
set xtics rotate by -45
set lmargin 13
set bmargin 6

set format y "%.1t x 10^{%T}"

plot 'daily_tracked_ports.dat' using 1:2 with lines lw 2 lc rgb '#1a9850'
    title 'Porta 10000', \
      '' using 1:3 with lines lw 2 lc rgb '#fee08b' title 'Porta 10001', \
      '' using 1:4 with lines lw 2 lc rgb '#d73027' title 'Porta 10002'

print "Gráfico 'grafico_serie_temporal_portas.png' gerado com sucesso!"
```

**Código-fonte 5** – *Script* Gnuplot completo de geração da série temporal de pacotes por porta TCP monitorada (`gerar_grafico_serie_temporal_portas.plt`).

Para ter mais um exemplo, o Código 6 ilustra um tipo de gráfico distinto: o mapa de calor que cruza região AWS alvo da radiação e protocolo de transporte. Além dos elementos já vistos no primeiro exemplo, o *script* define uma paleta de cores própria para a intensidade do mapa de calor e lê o arquivo `.dat` no formato de matriz, com rótulos de linha e coluna, em vez do formato colunar usado pelo gráfico anterior.

```
# Mapa de Calor: Região AWS x Protocolo de Transporte
set terminal pngcairo size 1400,1000 enhanced font "Verdana,11"
set output 'grafico_heatmap_regiao_aws.png'

set title "Distribuição de Tráfego IBR por Região AWS e Protocolo"
set xlabel "Protocolo"
set ylabel "Região AWS (Alvo da Radiação)"

set palette defined ( 0 '#f7fbff', 0.5 '#6baed6', 1 '#08306b' )
set cblabel "Contagem de Pacotes" offset 2,0
set format cb "%.1t x 10^{%T}"

set lmargin 20
set rmargin 12
set tmargin 3
set bmargin 5

set datafile separator comma
plot 'aws_region_protocol_heatmap.dat' matrix rowheaders columnheaders
    using 1:2:3 with image
set datafile separator

print "Gráfico 'grafico_heatmap_regiao_aws.png' gerado com sucesso!"
```

**Código-fonte 6** – *Script* Gnuplot completo de geração do mapa de calor de região AWS por protocolo de transporte (`gerar_grafico_heatmap_regiao_aws.plt`).

Em suma, este capítulo apresentou o desenvolvimento do *pipeline* modificado em três partes complementares: a arquitetura do fluxo de dados antes e depois das alterações propostas, os *scripts* responsáveis por cada nova etapa, com destaque para os trechos de código centrais da automação, e o critério que orientou a seleção dos tipos de gráfico efetivamente implementados entre o repertório explorado. O resultado é um *pipeline* capaz de transformar, sem intervenção manual, os dados sumarizados do Cloud Telescope em um conjunto amplo de visualizações Gnuplot, cuja apresentação e discussão são o objeto do Capítulo 5. O código-fonte completo do *pipeline* modificado, incluindo as etapas 3 a 5 e os 25 *scripts* Gnuplot documentados no Capítulo 5, está disponível publicamente em Lauritzen (2026).

# 5 RESULTADOS E DISCUSSÃO

Este capítulo apresenta os resultados obtidos com a execução completa do *pipeline* modificado, descrito no Capítulo 4, sobre dados reais de radiação IBR. O conjunto de *scripts* construído, sumarização em JSON, geração dos arquivos `.dat` e automação dos *scripts* Gnuplot, foi executado de ponta a ponta sem intervenção manual, produzindo o conjunto de visualizações discutido a seguir. A execução aqui relatada utilizou o Dataset 3 do Cloud Telescope, mas o *pipeline* não é específico a ele: por depender apenas do formato de saída padrão do *parser* de captura, ele é reproduzível sobre qualquer outro *dataset* do grupo de pesquisa, bastando reexecutar as mesmas etapas sobre os arquivos do dataset correspondentes.

Os subtópicos seguintes apresentam os resultados obtidos, cada um acompanhado da respectiva visualização e de sua explicação, discutida à luz da literatura de telescópios de rede e de estudos correlatos publicados no *Internet Measurement Conference* (IMC).

## 5.1 Padrões Temporais

A Figura 24 apresenta o total diário de pacotes de radiação IBR recebidos ao longo de todo o Dataset 3 (01/10/2023 a 29/02/2024, 153 dias), uma visão agregada que antecede a quebra por porta discutida a seguir.

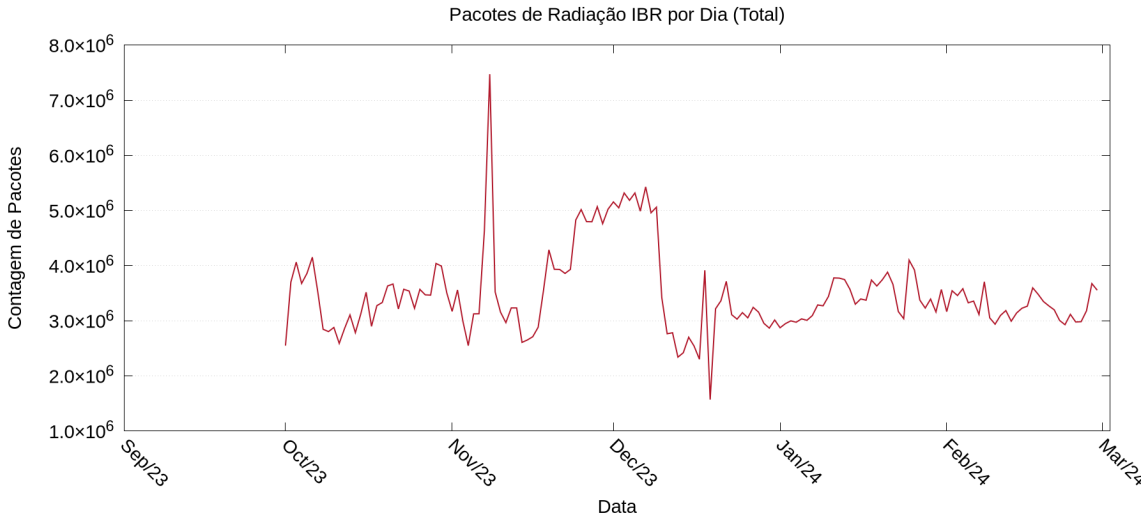



**Figura 24 –** Total diário de pacotes de radiação IBR ao longo do Dataset 3 completo. Fonte: Elaborado pelo autor.

O volume diário oscila, na maior parte do período, entre aproximadamente 2,5 e 5,5 milhões de pacotes, com média de 3.470.030 pacotes/dia. Dois pontos fogem claramente dessa faixa: um pico isolado em 08/11/2023, com 7.472.602 pacotes, mais que o dobro da média do período e precedido por um dia já elevado (07/11/2023, 4.632.691 pacotes); e uma queda isolada

em 19/12/2023, com apenas 1.570.651 pacotes, cercada por dias com volume próximo da média (18/12/2023: 3.916.085; 20/12/2023: 3.217.914). Em ambos os casos, o caráter pontual, um único dia destoante entre vizinhos dentro da faixa esperada, sugere eventos exógenos à operação normal do telescópio, uma campanha de varredura breve e intensa no primeiro caso, uma possível interrupção parcial de captura ou de trânsito de rede no segundo, em vez de uma mudança estrutural no padrão de tráfego.

A Figura 25 reproduz, agora sobre o *dataset* completo (setembro de 2023 a fevereiro de 2024) e não mais sobre a amostra parcial usada no ensaio de validação da Seção 2.7.2, a série diária de pacotes recebidos nas portas TCP 10000, 10001 e 10002.

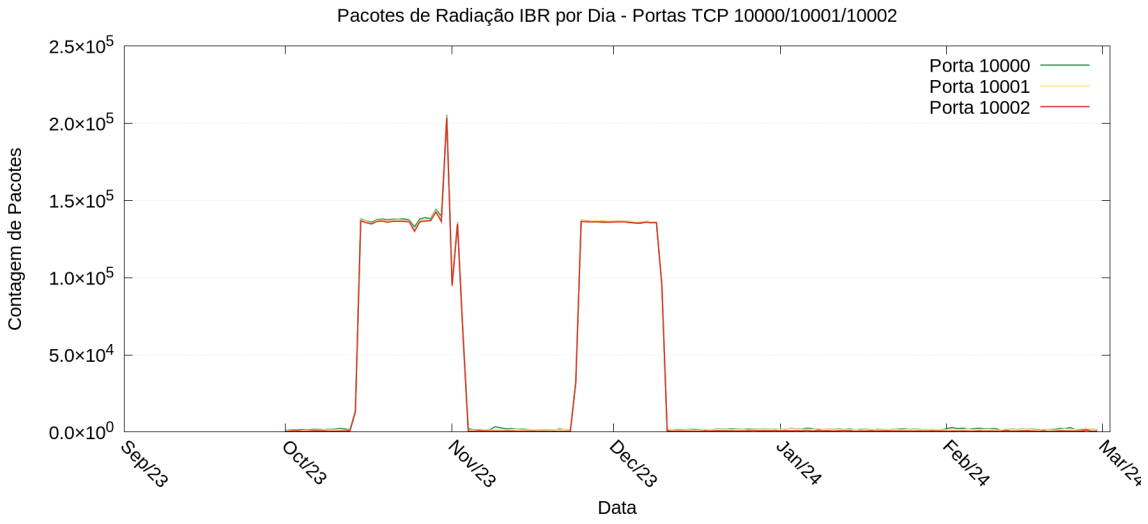



**Figura 25 –** Série temporal completa de pacotes de radiação IBR por dia nas portas TCP 10000/10001/10002 (Dataset 3 integral). Fonte: Elaborado pelo autor.

O padrão revela duas janelas de atividade intensa e bem delimitadas, de 15/10/2023 a 03/11/2023 (20 dias, média de aproximadamente 135 mil pacotes/dia por porta) e de 25/11/2023 a 10/12/2023 (16 dias, média de aproximadamente 134 mil pacotes/dia), separadas por um intervalo de cerca de três semanas em que o volume nas três portas cai para poucas centenas de pacotes por dia, próximo do ruído de fundo observado no restante da série. Dentro da primeira janela ocorre ainda um pico isolado em 31/10/2023, com aproximadamente 205 mil pacotes na porta 10002, cerca de 50% acima da média do próprio período.

O comportamento sincronizado entre as três portas, curvas praticamente sobrepostas tanto na subida quanto na descida, é o traço mais informativo do gráfico: como as portas 10000-10002 não correspondem a um serviço legítimo amplamente implantado, o alinhamento temporal quase perfeito é consistente com uma única campanha de varredura automatizada testando um pequeno intervalo de portas adjacentes, e não com processos independentes. O intervalo de silêncio entre as duas janelas também é relevante: campanhas de varredura em telescópios de rede tendem a aparecer como rajadas que iniciam e cessam abruptamente, e não como uma ati-

vidade que decai gradualmente, conforme observado por Männel *et al.* (2025) na operação de longo prazo do telescópio UCSD-NT e por Griffioen *et al.* (2024) em sua caracterização de dez anos de campanhas de varredura SYN. A retomada da atividade após esse período de silêncio, com magnitude e portas-alvo idênticas às do primeiro período, sugere um reinício de campanha por parte do mesmo operador ou *botnet*, em vez de duas campanhas coincidentes de origens distintas, hipótese que o gráfico por si só não permite confirmar.

### 5.1.1 Validação frente ao Processo Manual do Grupo de Pesquisa

O mesmo tipo de análise, total de pacotes por dia, já era produzido manualmente pelo grupo de pesquisa antes deste trabalho, a partir de planilhas Excel elaboradas individualmente para cada mês de captura, processo demorado e sujeito a erro humano que a automação proposta neste trabalho elimina. A Figura 26 reproduz o gráfico de referência fornecido pelo orientador para o mês de outubro de 2023, período integralmente coberto pelo Dataset 3; a Figura 27 apresenta o resultado gerado pelo *pipeline* modificado para o mesmo mês, sem qualquer intervenção manual.

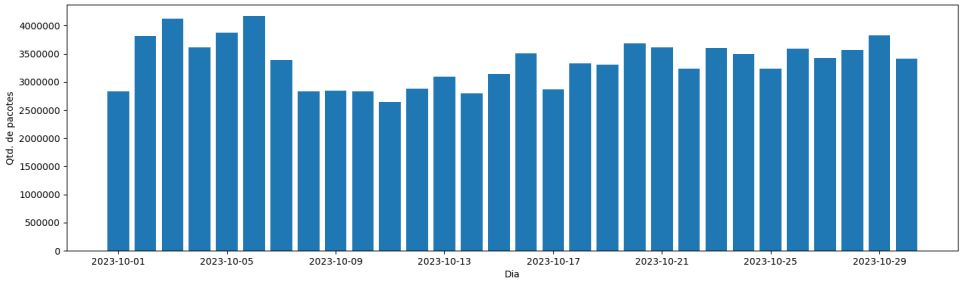



**Figura 26 –** Total diário de pacotes de radiação IBR em outubro de 2023, elaborado manualmente pelo grupo de pesquisa a partir de planilha Excel (gráfico de referência fornecido pelo orientador). Fonte: Grupo de pesquisa, dados não publicados.

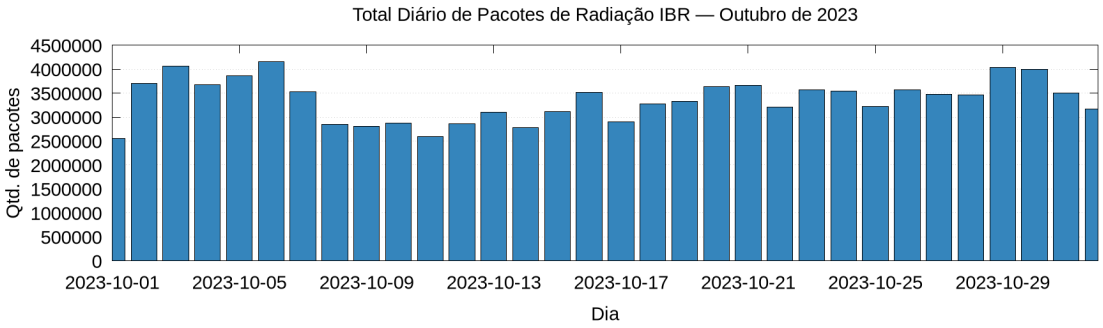



**Figura 27 –** Total diário de pacotes de radiação IBR em outubro de 2023, gerado automaticamente pelo *pipeline* modificado, no mesmo estilo do gráfico de referência manual. Fonte: Elaborado pelo autor.

A comparação entre as duas séries mostra forte concordância: em 06/10/2023, o *pipeline* automatizado contabilizou 4.152.582 pacotes, contra aproximadamente 4,17 milhões no gráfico

de referência; em 08/10/2023, 2.846.177 pacotes automatizados contra aproximadamente 2,8 milhões no processo manual. A maior divergência entre as duas séries ocorre no primeiro dia (01/10/2023: 2.549.808 pacotes automatizados contra aproximadamente 2,83 milhões manuais), possivelmente decorrente de um corte parcial do primeiro dia de captura em um dos dois processos, hipótese que não pôde ser confirmada sem acesso à planilha original do grupo de pesquisa. Fora esse ponto isolado, a correspondência de forma e magnitude entre as duas séries confirma que o Gnuplot, dentro do *pipeline* modificado, reproduz automaticamente o mesmo gráfico que o grupo de pesquisa levava ao Excel para elaborar manualmente, eliminando a necessidade de reelaboração da planilha a cada novo ciclo de captura de dados.

Uma segunda validação, desta vez frente a uma saída do próprio *pipeline* original em vez de uma planilha externa, é possível para o *ranking* de países de origem por volume de pacotes ICMP: a Figura 28 reproduz a Tabela 31 da tese de Bortoluzzi (2025) (p. 118), uma das tabelas em LaTeX que o `3_summarize_radiation.py` original já produzia como produto final sobre o mesmo Dataset 3, antes de qualquer modificação deste trabalho; a Figura 29 apresenta esse mesmo *ranking*, agora gerado automaticamente em formato gráfico pelo *pipeline* modificado.

Table 31 – Most prevalent ICMP radiation sources

| Rank | Country | Count | % |
|---|---|---|---|
| 1 | China | 32,165,142 | 37.34 |
| 2 | Singapore | 16,176,805 | 18.78 |
| 3 | Indonesia | 11,609,410 | 13.48 |
| 4 | United States | 8,006,679 | 9.29 |
| 5 | Hong Kong | 3,065,714 | 3.56 |
| 6 | Japan | 2,711,230 | 3.15 |
| 7 | Malaysia | 1,294,291 | 1.50 |
| 8 | Philippines | 1,225,954 | 1.42 |
| 9 | Thailand | 1,186,495 | 1.38 |
| 10 | United Kingdom | 1,159,757 | 1.35 |
| 11 | India | 1,100,040 | 1.28 |
| 12 | Germany | 1,038,961 | 1.21 |
| 13 | South Korea | 1,005,728 | 1.17 |
| 14 | Australia | 819,998 | 0.95 |
| 15 | United Arab Emirates | 542,462 | 0.63 |
| 16 | Saudi Arabia | 288,877 | 0.34 |
| 17 | Sweden | 191,464 | 0.22 |
| 18 | Vietnam | 173,846 | 0.20 |
| 19 | Taiwan | 159,836 | 0.19 |
| 20 | Ireland | 130,207 | 0.15 |
| | Sub-total | 84,052,896 | 97.58 |
| | Total | 86,139,655 | 100.00 |

**Figura 28 –** Tabela 31 da tese de Bortoluzzi (2025) (p. 118): ranking dos 20 países mais ativos como origens de radiação ICMP no Dataset 3, apresentado em formato tabular. Fonte: Bortoluzzi (2025).

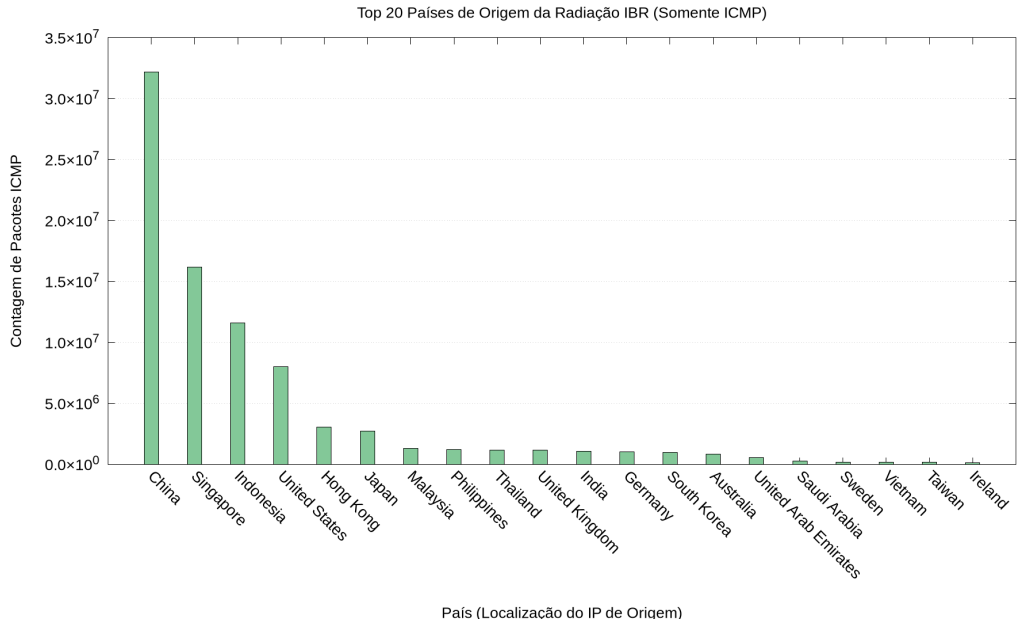



**Figura 29 –** Reprodução automatizada da Tabela 31 de Bortoluzzi (2025) como gráfico de barras gerado pelo *pipeline* modificado: Top 20 países de origem da radiação IBR por volume de pacotes ICMP no Dataset 3 completo. Fonte: Elaborado pelo autor.

Os valores numéricos das duas figuras coincidem exatamente, byte a byte: a China lidera com 32.165.142 pacotes (37,34%), seguida por Singapura (16.176.805, 18,78%) e Indonésia (11.609.410, 13,48%), e os Estados Unidos aparecem apenas na quarta posição com 8.006.679 pacotes (9,29%), confirmando que o *pipeline* modificado reproduz corretamente, em formato gráfico, o mesmo *ranking* que o *pipeline* original já calculava e publicava apenas em formato tabular, sem qualquer alteração aos valores numéricos subjacentes.

## 5.2 Origens e Destinos Únicos de Radiação

A Figura 30 compara a cardinalidade de IPs de origem únicos com a de IPs de destino únicos observados no Dataset 3 completo, uma medida básica da escala da captura antes de qualquer segmentação por protocolo, porta ou geografia.

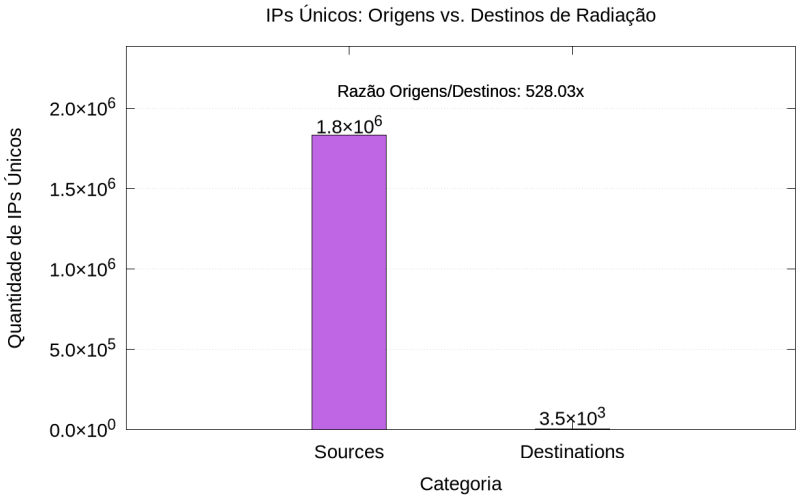



**Figura 30 –** Comparação entre o número de IPs de origem únicos e de IPs de destino únicos no Dataset 3 completo. Fonte: Elaborado pelo autor.

O Dataset 3 registrou 1.834.887 IPs de origem únicos contra apenas 3.475 IPs de destino únicos, uma razão de aproximadamente 528 origens para cada destino. Essa assimetria é esperada dada a própria arquitetura do Cloud Telescope (Bortoluzzi, 2025): o espaço de endereçamento monitorado pelos sensores é fixo e relativamente pequeno, enquanto o número de origens de radiação corresponde à soma de todos os IPs distintos que, em algum momento do período de captura, endereçaram pacotes a esse espaço, prática e teoricamente ilimitado. A magnitude da assimetria reforça a leitura, já adotada nas seções anteriores, de que a radiação do Dataset 3 é predominantemente resultado de varreduras automatizadas de amplo alcance, e não de um pequeno conjunto de atores testando repetidamente os mesmos poucos alvos.

## 5.3 Distribuição por Protocolo de Transporte

A Figura 31 apresenta a distribuição percentual dos pacotes de radiação IBR capturados pelo Cloud Telescope ao longo do Dataset 3 completo, segmentados pelos três protocolos de transporte identificados pelo *pipeline*.

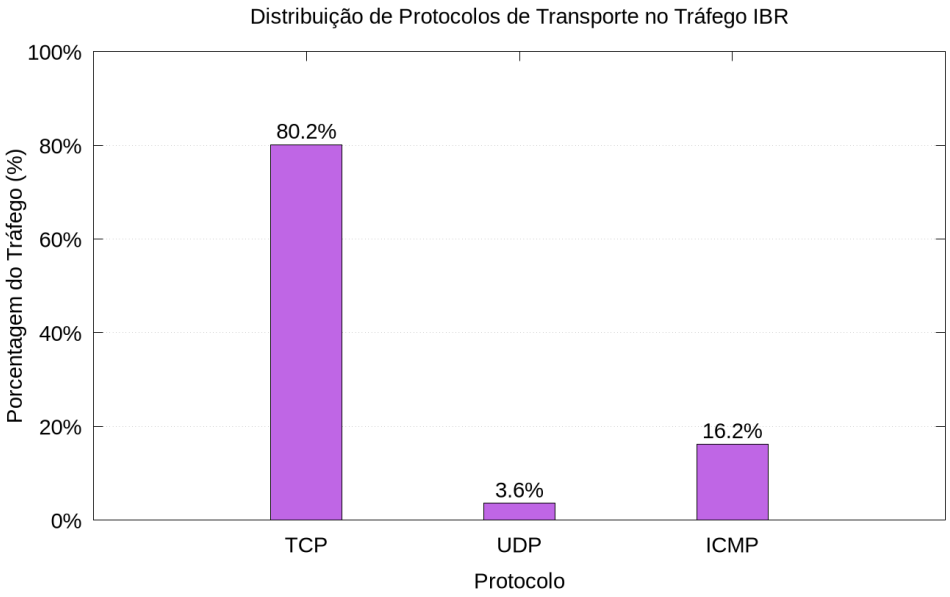



**Figura 31 –** Distribuição percentual do tráfego de radiação IBR por protocolo de transporte no Dataset 3 completo. Fonte: Elaborado pelo autor.

O protocolo TCP domina com folga, respondendo por 80,18% dos pacotes classificados por protocolo (425.674.635 de um total de 530.797.261), seguido por ICMP com 16,22% (86.139.655 pacotes) e, por último, UDP com apenas 3,58% (18.982.971 pacotes). A predominância do TCP é consistente com a caracterização de García-Peñas, Rodríguez-Gómez e Maciá-Fernández (2025), que descreve esse protocolo como majoritário no tráfego de radiação de fundo capturado por telescópios de rede, associado a ferramentas de varredura em massa como ZMap, MassScan e NMap. A participação do ICMP, por sua vez, é maior do que o observado em telescópios cujo tráfego é dominado por varreduras UDP, e decorre, como discutido na Seção 5.6, de uma concentração desproporcional de pacotes ICMP em apenas duas das 26 regiões AWS monitoradas.

### 5.3.1 Tipos de Mensagem ICMP

A Figura 32 detalha o protocolo ICMP por tipo de mensagem, uma camada adicional sobre os 86.139.655 pacotes totalizados na Seção 5.3.

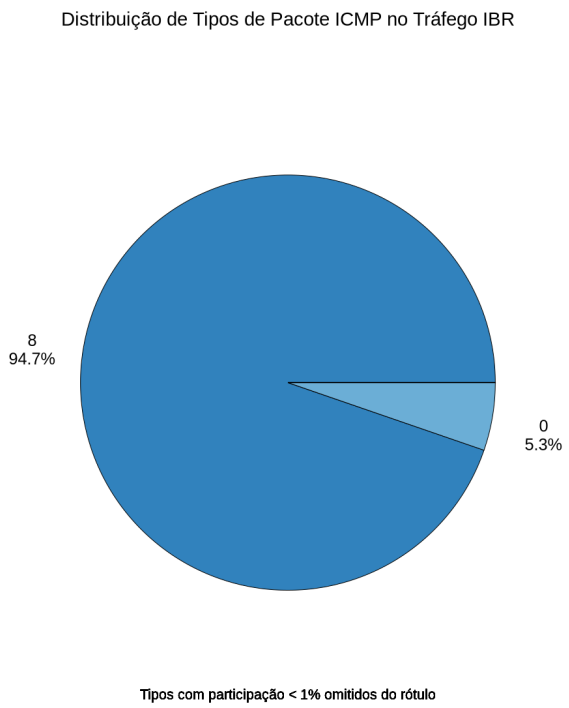



**Figura 32 –** Distribuição dos pacotes ICMP de radiação IBR por tipo de mensagem no Dataset 3 completo. Fonte: Elaborado pelo autor.

Dois tipos concentram praticamente a totalidade do tráfego: o tipo 8 (Echo Request) responde por 94,7% (81.592.126 pacotes) e o tipo 0 (Echo Reply) por 5,3% (4.546.190 pacotes); os seis tipos restantes identificados somam juntos menos de 1.400 pacotes, fração desprezível omitida dos rótulos da figura. A presença expressiva de pacotes do tipo 0 é, à primeira vista, contraintuitiva: como um telescópio de rede passivo não responde a nenhum pacote recebido, essas respostas não podem ter sido geradas pelos próprios sensores do Cloud Telescope. O padrão é consistente com o mecanismo de retroespalhamento (*backscatter*) descrito por Moore *et al.* (2006): um endereço IP de origem forjado em pacotes de varredura ou ataque direcionados a terceiros leva a vítima a responder ao endereço falsificado que, por pertencer ao espaço de endereçamento do Cloud Telescope, é capturado como IBR secundário, sem que o telescópio tenha emitido qualquer requisição original.

## 5.4 Portas de Destino Mais Visadas

A Figura 33 apresenta as 20 portas TCP de destino que mais receberam pacotes de radiação IBR ao longo do Dataset 3 completo.

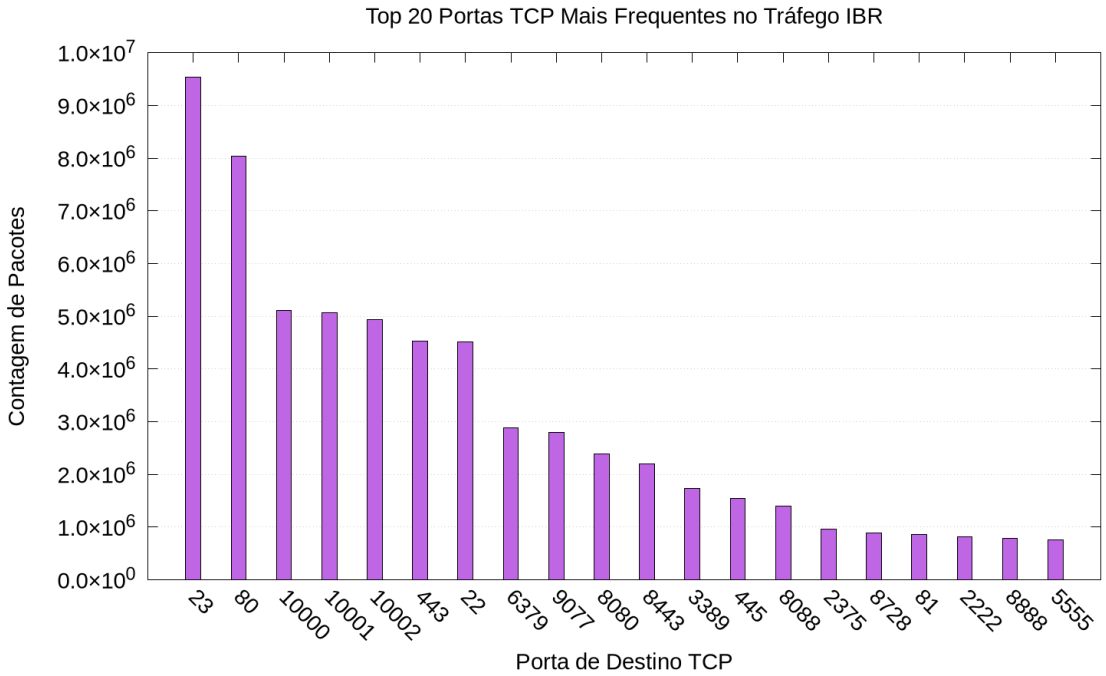



**Figura 33 –** Top 20 portas TCP de destino mais visadas pela radiação IBR no Dataset 3 completo. Fonte: Elaborado pelo autor.

A porta 23 (Telnet) lidera com 9.536.412 pacotes, seguida pela porta 80 (HTTP) com 8.036.707. Logo depois aparecem, na terceira, quarta e quinta posições, as portas 10000, 10001 e 10002, com 5.105.766, 5.064.150 e 4.931.950 pacotes respectivamente, somando juntas 15.101.866 pacotes e confirmando, em uma visão agregada de todo o período, a magnitude da campanha de varredura já identificada na série temporal da Seção 5.1. Completam a lista portas associadas a serviços administrativos e de acesso remoto, como 443 (HTTPS), 22 (SSH) e 3389 (RDP), além de serviços frequentemente expostos sem autenticação adequada, como 6379 (Redis) e 2375 (API do Docker). A combinação das portas 23 e 22 entre as mais visadas reforça a associação, já discutida no Capítulo 3, entre essas portas e campanhas de varredura por *botnets* de dispositivos IoT como a Mirai, conforme caracterizado por García-Peñas, Rodríguez-Gómez e Maciá-Fernández (2025). Já a presença de portas menos convencionais no topo do ranking, como 6379 e 2375, ilustra a volatilidade do ecossistema de varredura apontada por Griffioen *et al.* (2024), que descreve mudança constante nas portas-alvo dominantes conforme novas superfícies de ataque são descobertas por operadores de varredura.

### 5.4.1 Portas UDP

A Figura 34 apresenta o equivalente em UDP da Figura 33: as 20 portas UDP de destino mais visadas pela radiação IBR.

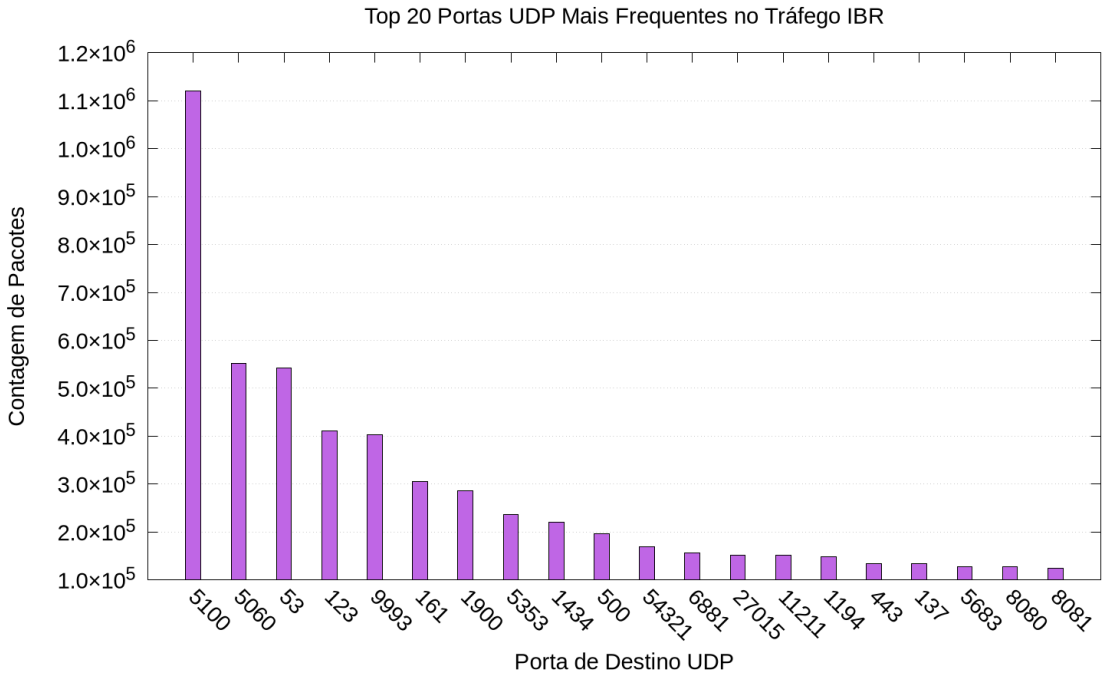



**Figura 34 –** Top 20 portas UDP de destino mais visadas pela radiação IBR no Dataset 3 completo. Fonte: Elaborado pelo autor.

A porta 5100 lidera com 1.121.200 pacotes, seguida por 5060 (SIP, sinalização VoIP) com 551.508 e pela porta 53 (DNS) com 541.760. Diferentemente do ranking TCP, no qual poucas portas concentram a maior parte do volume, a distribuição entre as 20 portas UDP é mais homogênea, sem um salto comparável ao das portas 10000-10002 observado na Seção 5.4. Chama atenção a presença de diversas portas associadas a protocolos historicamente explorados em ataques de amplificação de negação de serviço, como 1900 (SSDP, 286.660 pacotes), 123 (NTP, 410.870 pacotes) e 11211 (Memcached, 152.101 pacotes): nesses protocolos, uma requisição pequena provoca uma resposta desproporcionalmente maior, característica que operadores de ataque exploram para amplificar o volume de tráfego direcionado a uma vítima a partir de poucos pacotes forjados (Moore *et al.*, 2006). Também aparece a porta 1434, associada ao SQL Server da Microsoft e popularizada pelo *worm* Slammer de 2003, cuja presença entre as mais visadas duas décadas depois (220.238 pacotes) ilustra a persistência de varreduras automatizadas por vulnerabilidades antigas muito tempo após sua divulgação original.

### 5.4.2 Combinações de Flags TCP

A Figura 35 apresenta as 20 combinações de *flags* TCP mais frequentes no tráfego capturado, uma camada adicional sobre o protocolo TCP já quantificado na Seção 5.3.

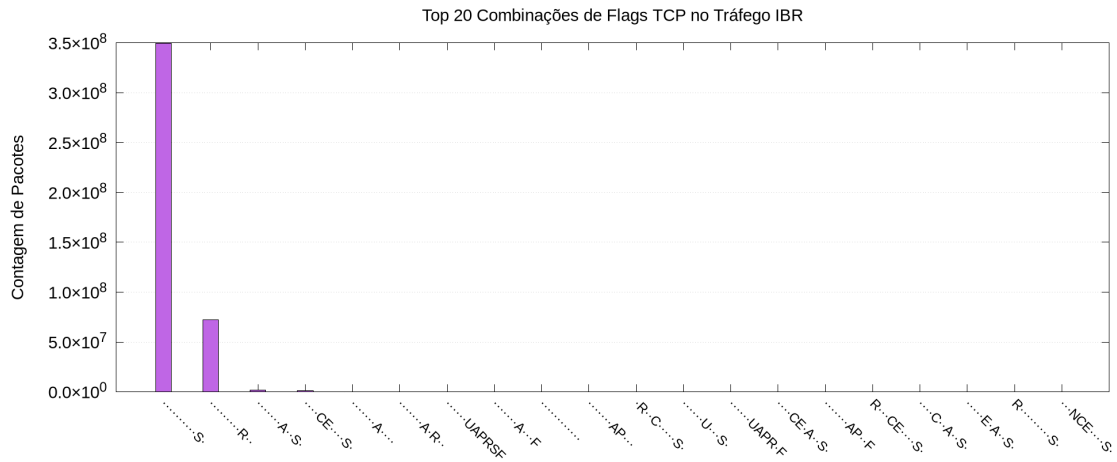



**Figura 35 –** Top 20 combinações de *flags* TCP no tráfego de radiação IBR do Dataset 3 completo. Fonte: Elaborado pelo autor.

Duas combinações dominam de forma esmagadora: pacotes com apenas a *flag* SYN ativa somam 349.778.700 (82,2% dos 425.674.635 pacotes TCP do Dataset 3), e pacotes com apenas a *flag* RST somam 72.511.053 (17,0%); juntas, essas duas combinações respondem por 99,2% de todo o tráfego TCP capturado, e as 20 combinações listadas somam 425.672.688 pacotes, 99,9995% do total de TCP. A predominância de pacotes SYN isolados é a assinatura clássica de varreduras de descoberta de portas abertas (*SYN scanning*), técnica que testa a disponibilidade de uma porta sem completar o estabelecimento da conexão TCP; já o volume expressivo de pacotes RST isolados é consistente com respostas de rejeição a essas mesmas tentativas de conexão, incluindo o retroespalhamento de pacotes RST provenientes de terceiros cujo endereço foi forjado, mecanismo análogo ao já discutido para o ICMP na Seção 5.3.1 (Moore *et al.*, 2006). As demais combinações, como SYN-ACK (1.511.298 pacotes) e SYN com as *flags* de controle de congestionamento CWR e ECE ativas (1.176.120 pacotes), representam uma fração residual do tráfego e refletem variações menos comuns de ferramentas de varredura ou respostas de *handshake* capturadas incidentalmente pelo telescópio.

## 5.5 Origem Geográfica da Radiação

A Figura 36 exibe a distribuição espacial das origens de radiação IBR do Dataset 3 completo, com cada IP de origem geolocalizado e agregado em células de 5°×5° de latitude/-longitude; pontos sobre o oceano foram descartados por não corresponderem a blocos de endereçamento IP válidos.

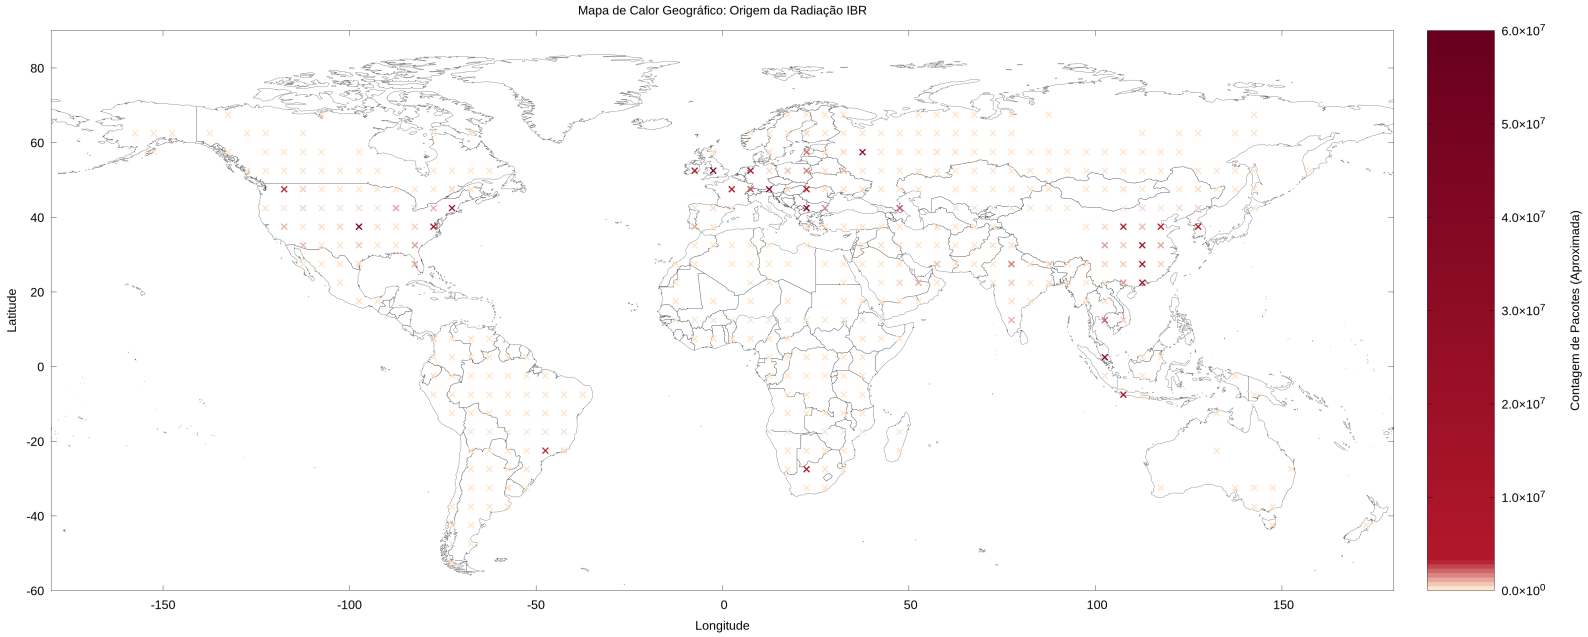



**Figura 36 –** Mapa de calor geográfico da origem da radiação IBR no Dataset 3 completo, com pontos sobre massas terrestres coloridos pela contagem aproximada de pacotes.
Fonte: Elaborado pelo autor.

A maior concentração isolada ocorre na célula que cobre o Reino Unido, com aproximadamente 51,5 milhões de pacotes, seguida de perto por uma célula no centro dos Estados Unidos, com aproximadamente 49,5 milhões. Um terceiro agrupamento de intensidade visível ocorre no leste e sudeste asiático, onde três células somam juntas cerca de 60,8 milhões de pacotes. Essa concentração espacial, mais pronunciada em países geograficamente pequenos e com alta densidade de centros de hospedagem, enquanto países de grande extensão territorial como os Estados Unidos dispersam volume comparável por um número maior de células adjacentes, é consistente com padrões de concentração geográfica de origens de varredura já relatados na literatura de telescópios de rede, como discutido por Ismail *et al.* (2025).

### 5.5.1 Países de Origem e Portas Visadas

A Figura 37 cruza o país de origem com a porta TCP de maior incidência para cada um dos 10 países que mais originaram radiação IBR no Dataset 3 completo.

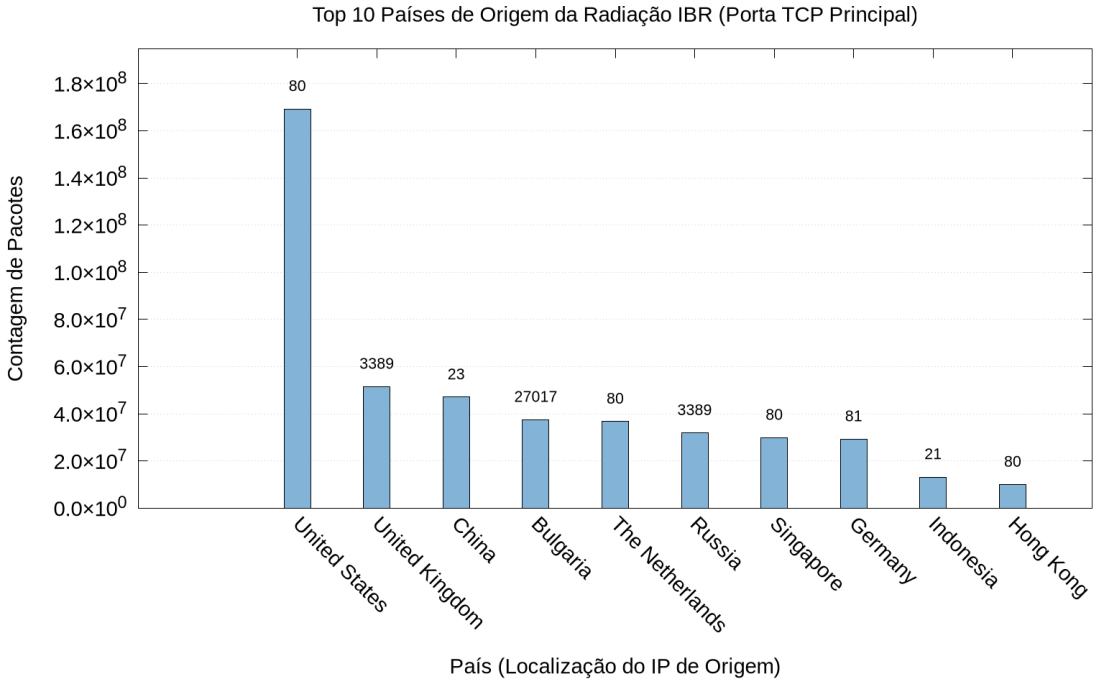



**Figura 37 –** Top 10 países de origem da radiação IBR por volume total de pacotes, com a porta TCP de maior incidência rotulada sobre cada barra. Fonte: Elaborado pelo autor.

Os Estados Unidos lideram isoladamente, com 169.249.433 pacotes, mais de três vezes o volume do segundo colocado, o Reino Unido (51.570.308 pacotes); completam o top 5 China (47.063.884), Bulgária (37.510.860) e Países Baixos (36.744.264). Nos Estados Unidos e em Singapura, três das cinco portas de maior volume coincidem exatamente com as portas 10000, 10001 e 10002 já discutidas na Seção 5.1 e na Seção 5.4: nos Estados Unidos essas três portas somam juntas 5.796.372 pacotes, atrás apenas das portas 80 e 443, e em Singapura 1.827.540 pacotes, na segunda, terceira e quarta posições locais. Isso indica que a campanha de varredura

identificada na série temporal teve origem concentrada principalmente nesses dois países, em vez de distribuída de forma homogênea entre as dez principais origens. Esse tipo de concentração de uma campanha específica em poucos países de origem é um padrão também observado por Männel *et al.* (2025) na operação de longo prazo do telescópio UCSD-NT. Nos demais países do top 10, a porta de maior incidência varia consideravelmente: 27017 (MongoDB) na Bulgária, 3389 (RDP) no Reino Unido e na Rússia, 23 (Telnet) na China e 21 (FTP) na Indonésia, evidenciando que diferentes origens de radiação priorizam diferentes superfícies de ataque. O ranking completo dos 20 principais países de origem, sem a quebra por porta, está disponível no *script* `gerar_grafico_source_country_name.plt`; como os dez primeiros colocados e seus volumes coincidem exatamente com os já discutidos nesta seção, ele não é reproduzido em figura própria. As dez posições adicionais reveladas pelo *ranking* estendido são, em ordem: Japão (7.268.133 pacotes), África do Sul (6.420.366), Índia (5.623.995), Irlanda (5.167.944), Romênia (5.013.302), França (4.808.674), Austrália (4.130.374), Coreia do Sul (3.699.848), Brasil (3.325.202) e Bélgica (2.209.498).

### 5.5.2 Composição de Protocolo por País de Origem

As Figuras 38 e 39 detalham, para os 20 principais países de origem, a mesma segmentação por protocolo de transporte já aplicada às regiões AWS na Seção 5.6, agora do lado da origem da radiação.

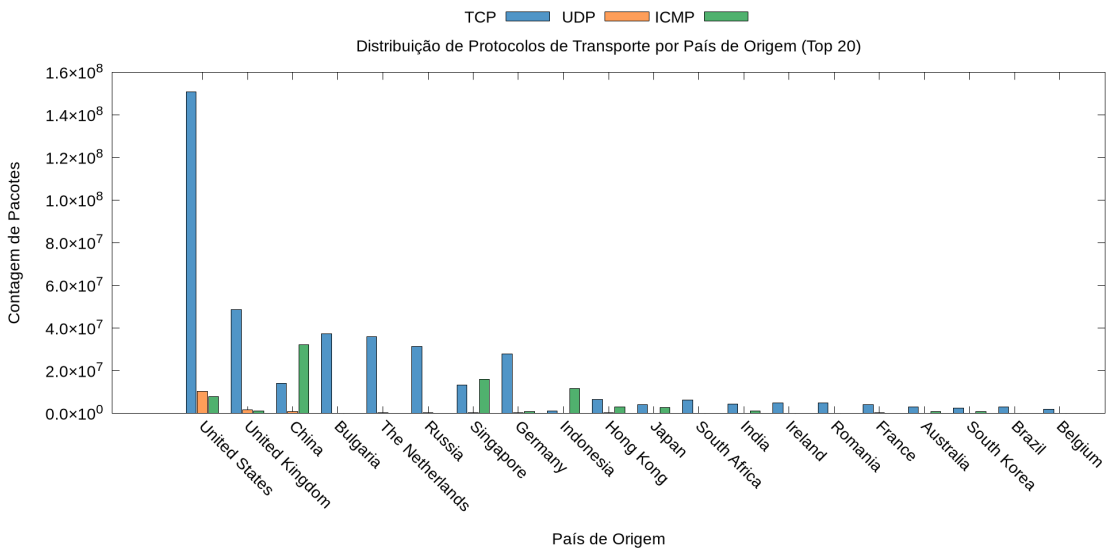



**Figura 38 –** Distribuição de protocolos de transporte por país de origem da radiação IBR (Top 20) no Dataset 3 completo. Fonte: Elaborado pelo autor.

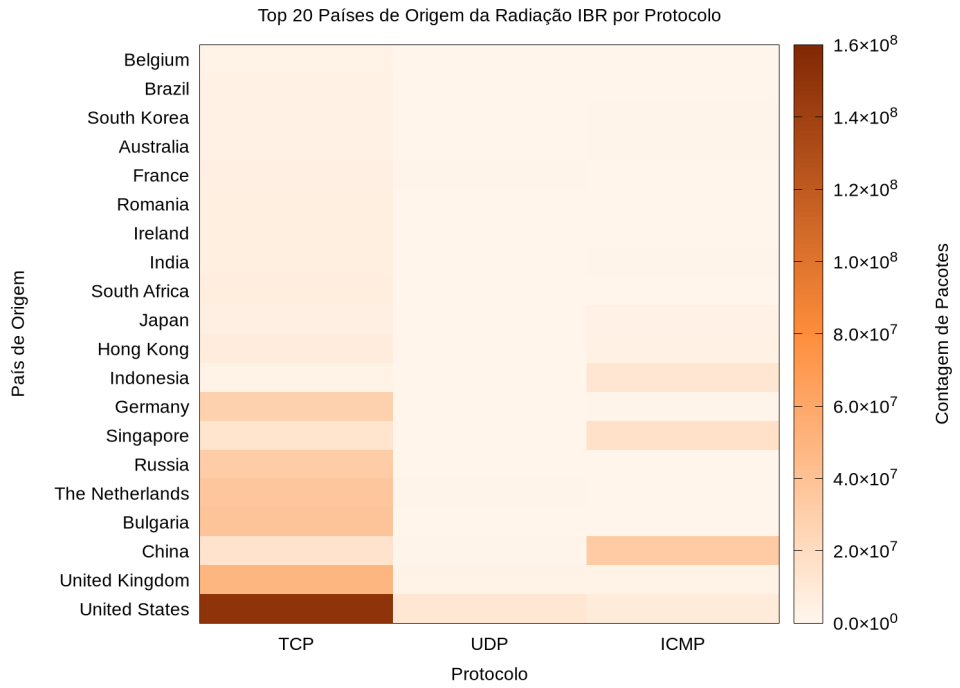



**Figura 39 –** Mapa de calor da contagem de pacotes de radiação IBR por país de origem e protocolo de transporte no Dataset 3 completo. Fonte: Elaborado pelo autor.

A maioria dos países de origem é fortemente dominada por TCP: Bulgária (99,8% TCP), Rússia (98,8%), Países Baixos (98,4%) e Reino Unido (94,4%) concentram quase a totalidade do seu volume nesse protocolo. A China e a Indonésia rompem esse padrão de forma acentuada: a China envia 32.165.142 pacotes ICMP contra 14.079.601 TCP (68,3% ICMP), e a Indonésia é ainda mais extrema, com 11.609.410 pacotes ICMP contra apenas 1.252.352 TCP (88,9% ICMP). Singapura ocupa uma posição intermediária, com ligeira maioria de ICMP (54,1%) sobre TCP (44,9%). A concentração de ICMP na Indonésia como país de origem é um achado que acompanha, sem necessariamente explicar por completo, a concentração de ICMP já observada do lado do destino na região `ap-southeast-3` (Jacarta) na Seção 5.6: ambas as observações, embora medidas em eixos diferentes do mesmo *dataset* (origem e destino), apontam para uma associação entre o Sudeste Asiático e um volume de tráfego ICMP desproporcional ao observado na maior parte das demais origens e regiões, consistente com a concentração atípica de ICMP já associada ao mecanismo de retroespalhamento na Seção 5.3.1 (Moore *et al.*, 2006).

Isolando apenas o protocolo ICMP nesse mesmo ranking de países de origem, o *ranking* muda radicalmente em relação às Figuras 38 e 39, ordenadas pelo volume total: a China assume a liderança isolada, seguida por Singapura e Indonésia, enquanto os Estados Unidos, líderes disparados no volume total, caem para a quarta posição. Essa reordenação, incluindo a validação da reprodução automatizada desse *ranking* frente à Tabela 31 da tese de Bortoluzzi (2025), é apresentada na Seção 5.1.1 (Figura 29).

A Figura 40 estende o ranking original de países de origem ao Top 20, somando os três

protocolos em um único valor por bolha, no mesmo estilo já aplicado aos países de destino AWS na Seção 5.6.1. A Figura 41 apresenta a composição por protocolo dessas mesmas 20 origens em eixos paralelos, uma técnica de visualização multivariada distinta das demais empregadas neste capítulo.

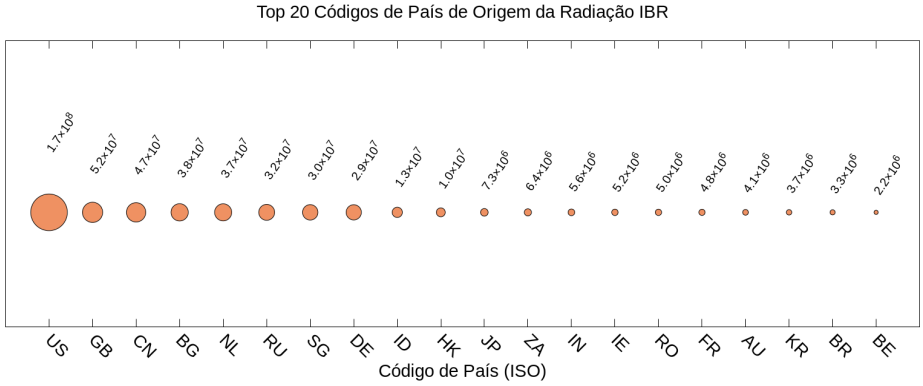



**Figura 40 –** Top 20 países de origem da radiação IBR por volume total de pacotes, em bolhas dimensionadas pela contagem, no Dataset 3 completo. Fonte: Elaborado pelo autor.

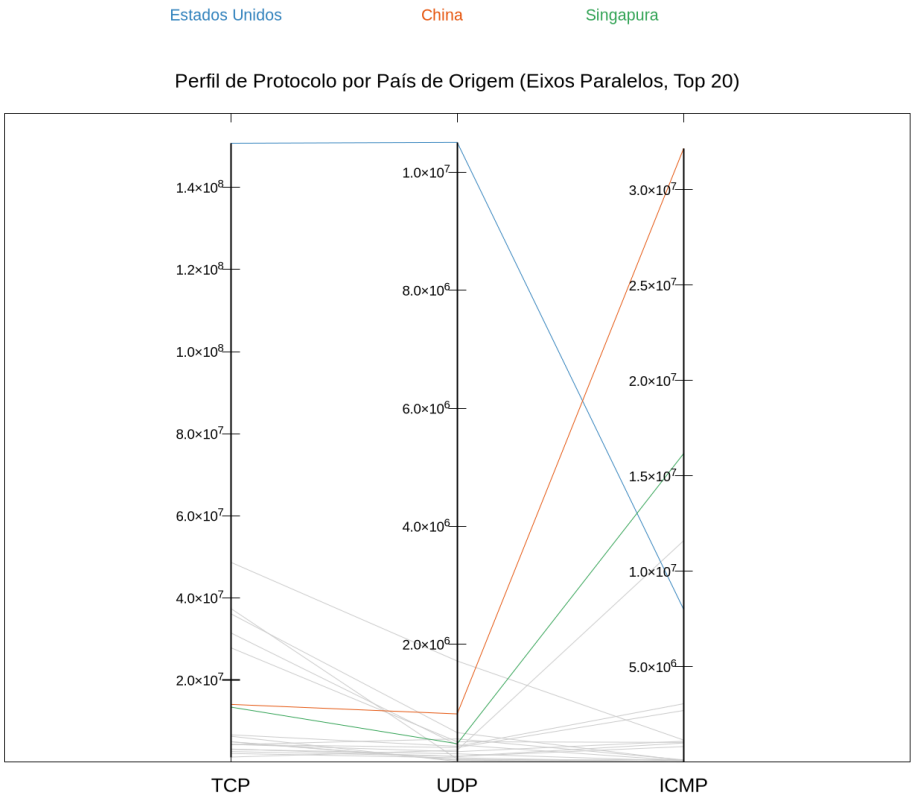



**Figura 41 –** Composição de protocolo de transporte dos 20 principais países de origem da radiação IBR em eixos paralelos no Dataset 3 completo; cada linha conecta os valores de TCP, UDP e ICMP de um mesmo país, com Estados Unidos, China e Singapura destacados em cor e os demais 17 países em cinza, como contexto. Fonte: Elaborado pelo autor.

Na Figura 40, o tamanho decrescente das bolhas do primeiro ao vigésimo colocado acompanha de perto o comportamento de cauda longa que será quantificado por país de origem individual na Seção 5.7, ainda que de forma mais suave, já agregado por país. Na Figura 41, a maior parte das 20 linhas desce de forma quase paralela do eixo TCP para os eixos UDP e ICMP, refletindo a dominância do TCP já discutida nesta seção; três linhas rompem esse padrão de forma visível: a dos Estados Unidos, único país cuja linha atinge o topo do eixo UDP (10.509.012 pacotes) apesar de também liderar o eixo TCP; e as da China e de Singapura, que partem de posições baixas ou intermediárias no eixo TCP para os pontos mais altos do eixo ICMP (32.165.142 e 16.176.805 pacotes, respectivamente), a mesma inversão TCP/ICMP já discutida para esses dois países, agora visível como uma única linha que cruza as demais.

### 5.5.3 Cidades de Origem

A Figura 42 detalha a origem da radiação IBR em granularidade de cidade, complementando a visão por país já apresentada nesta seção.

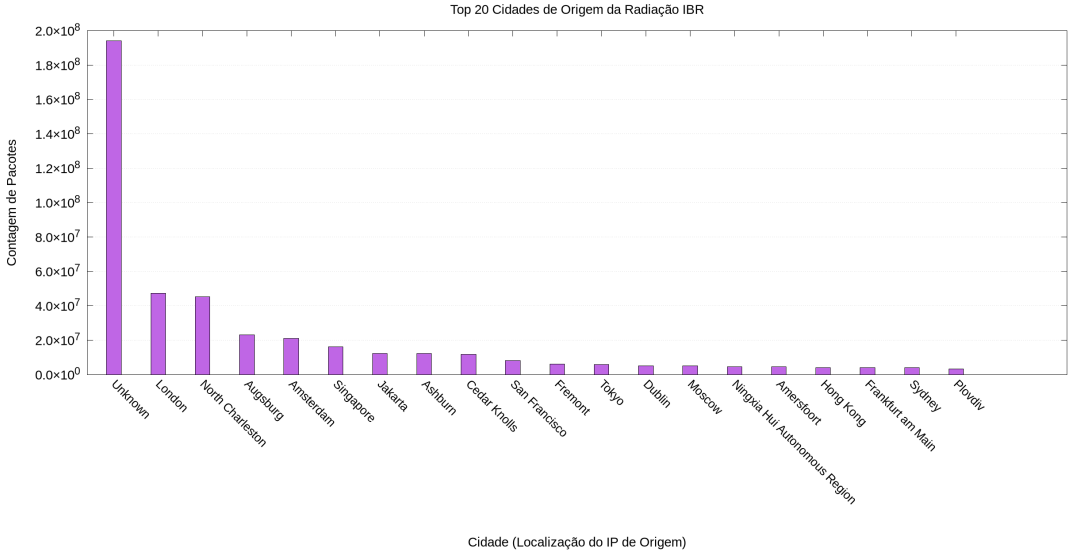



**Figura 42 –** Top 20 cidades de origem da radiação IBR no Dataset 3 completo. Fonte: Elaborado pelo autor.

A categoria ”Unknown”(geolocalização não resolvida pela base de dados do *pipeline*) lidera com 194.068.877 pacotes, volume superior ao de qualquer cidade identificada, e deve ser interpretada como uma lacuna de cobertura da base de geolocalização, não como uma origem real. Entre as cidades identificadas, Londres lidera com 47.255.647 pacotes, seguida por North Charleston, nos Estados Unidos, com 45.169.733, e Augsburgo, na Alemanha, com 23.065.666. A presença de cidades de porte médio como North Charleston e Augsburgo entre as principais origens, à frente de capitais e centros financeiros globais, sugere que a concentração geográfica da radiação está mais associada à localização de datacenters e blocos de endereçamento IP específicos do que ao tamanho populacional ou à relevância econômica da cidade, padrão com-

patível com a categoria de escaneadores de hospedagem (*hosting*) caracterizada por Griffioen *et al.* (2024).

## 5.6 Alvos na Infraestrutura AWS

A Figura 43 cruza as 26 regiões AWS onde o Cloud Telescope mantém sensores com os três protocolos de transporte.

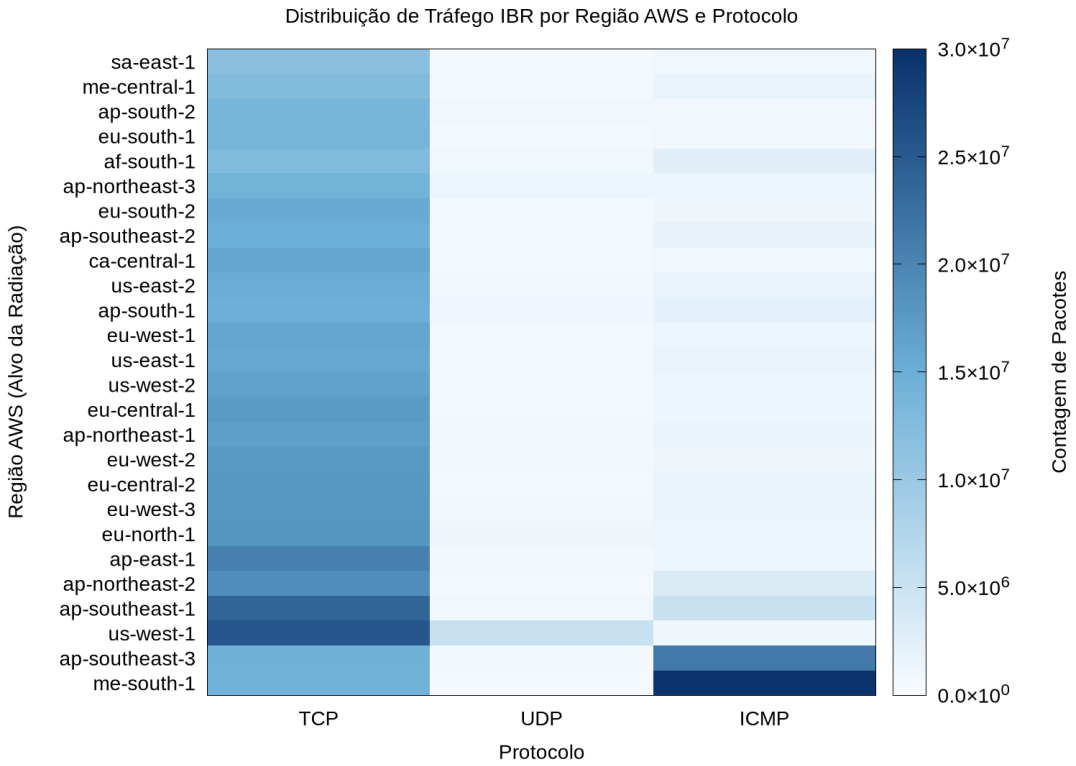



**Figura 43 –** Mapa de calor da contagem de pacotes de radiação IBR por região AWS alvo e protocolo de transporte no Dataset 3 completo. Fonte: Elaborado pelo autor.

O volume de tráfego TCP é relativamente uniforme entre as regiões, variando entre 11.615.472 pacotes (sa-east-1, São Paulo) e 25.408.678 pacotes (us-west-1, Califórnia do Norte), pouco mais de 2 vezes de diferença entre o menor e o maior valor. O protocolo ICMP, por outro lado, concentra-se de forma muito mais desigual: as regiões me-south-1 (Barém) e ap-southeast-3 (Jacarta) recebem, respectivamente, 29.601.063 e 21.268.519 pacotes ICMP, entre aproximadamente 8 e 12 vezes mais do que a região com a terceira maior contagem de ICMP (af-south-1, Cidade do Cabo, com 2.510.510 pacotes). Essa concentração extrema de tráfego ICMP em apenas duas das 26 regiões monitoradas demonstra o valor da arquitetura distribuída do Cloud Telescope descrita por Bortoluzzi (2025): um telescópio de localização única jamais revelaria esse tipo de assimetria geográfica de visada, já que o alvo observado seria sempre o mesmo. Essa assimetria regional também explica a participação do ICMP de 16,22% no tráfego

global observada na Seção 5.3, acima do que seria esperado caso o volume de pacotes ICMP estivesse distribuído de forma proporcionalmente uniforme entre as regiões.

A Figura 44 apresenta a mesma base de dados em uma rosa dos ventos adaptada, estilo que ordena as 26 regiões pelo volume total de pacotes (somando os três protocolos) e codifica essa magnitude tanto no comprimento quanto na intensidade de cor de cada cunha.

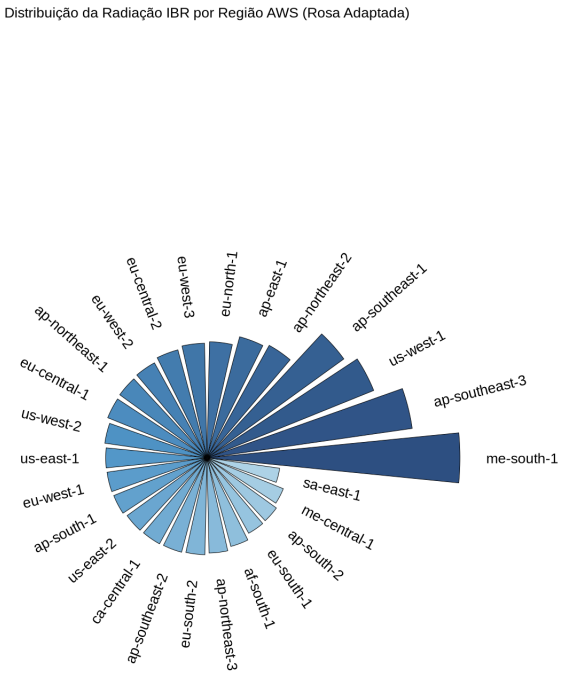



**Figura 44 –** Distribuição do volume total de radiação IBR por região AWS em rosa dos ventos adaptada no Dataset 3 completo. Fonte: Elaborado pelo autor.

A cunha mais longa e mais escura corresponde a me-south-1 (44.167.880 pacotes somando os três protocolos), seguida por ap-southeast-3 (36.191.293) e us-west-1 (31.397.751); a cunha mais curta e clara é sa-east-1, com 12.810.801 pacotes, menos de um terço do volume da região líder. Por somar os protocolos num único valor, a Figura 44 não distingue, sozinha, se esse total é dominado por TCP, como na maioria das regiões, ou por ICMP, como em me-south-1 e ap-southeast-3, distinção que permanece exclusiva da Figura 43, reforçando que as duas visualizações respondem perguntas complementares sobre o mesmo conjunto de dados.

### 5.6.1 Países e Cidades de Destino na Infraestrutura AWS

As Figuras 45 e 46 agregam as 26 regiões AWS por país de localização: a primeira cruza esse agregado com o protocolo de transporte, apresentando a mesma informação da Seção 5.6 em

uma granularidade mais ampla; a segunda apresenta o mesmo ranking em bolhas dimensionadas pelo volume total, sem a quebra por protocolo.

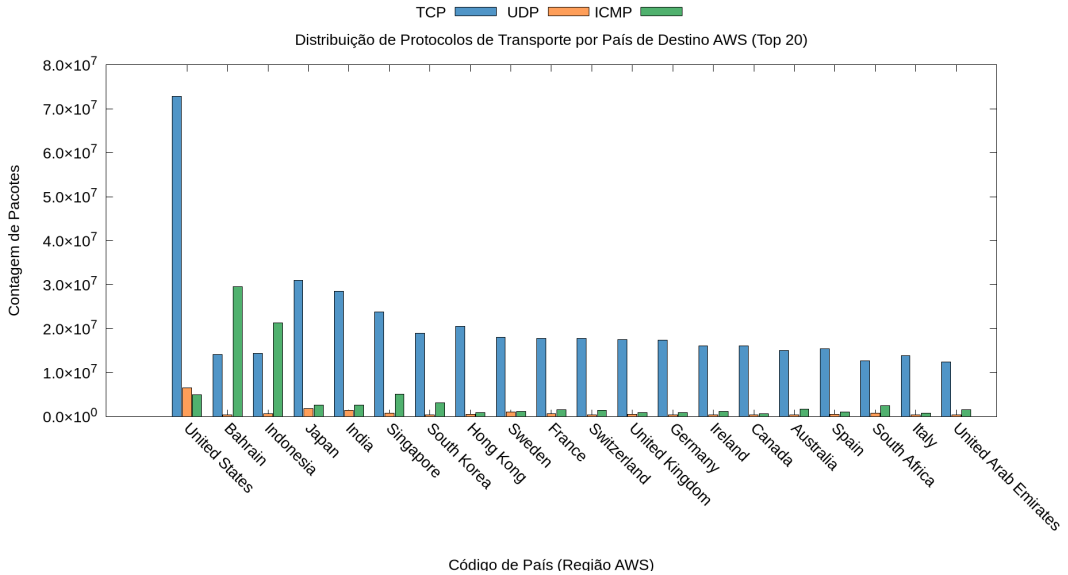



**Figura 45 –** Distribuição de protocolos de transporte por país de destino AWS (Top 20) em barras agrupadas no Dataset 3 completo. Fonte: Elaborado pelo autor.

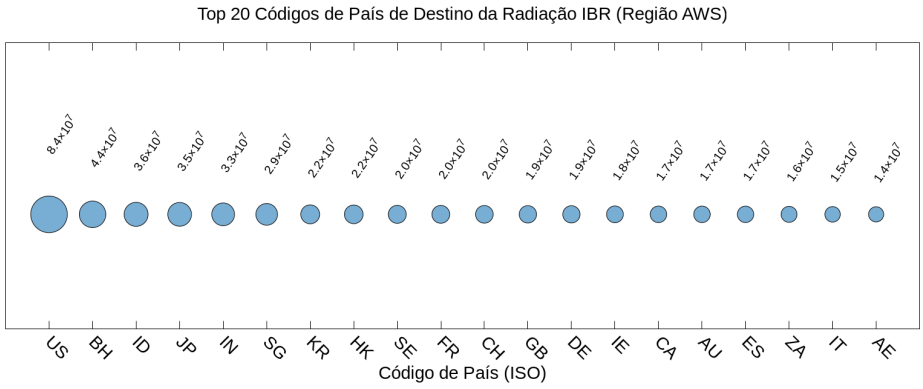



**Figura 46 –** Top 20 países de destino AWS da radiação IBR por volume total de pacotes, em bolhas dimensionadas pela contagem, no Dataset 3 completo. Fonte: Elaborado pelo autor.

Como Barém e Indonésia concentram apenas uma região AWS cada (me-south-1 e ap-southeast-3, respectivamente), a agregação por país não altera a leitura já feita por região: os dois países lideram em pacotes ICMP (29.601.063 e 21.268.519), conforme detalhado na Figura 45. Na Figura 46, no entanto, essa concentração de ICMP não se destaca: por somar os três protocolos num único valor, os Estados Unidos aparecem como a maior bolha (84.327.019 pacotes), seguidos por Barém (44.167.880) e Indonésia (36.191.293), um ranking que reflete o volume total de cada país, não a composição por protocolo, reforçando que as duas figuras respondem perguntas complementares e não substituem uma à outra.

A Figura 47 apresenta essa mesma tabela de país de destino por protocolo em barras empilhadas, um formato distinto do agrupado já utilizado na Figura 45 para os mesmos dados.

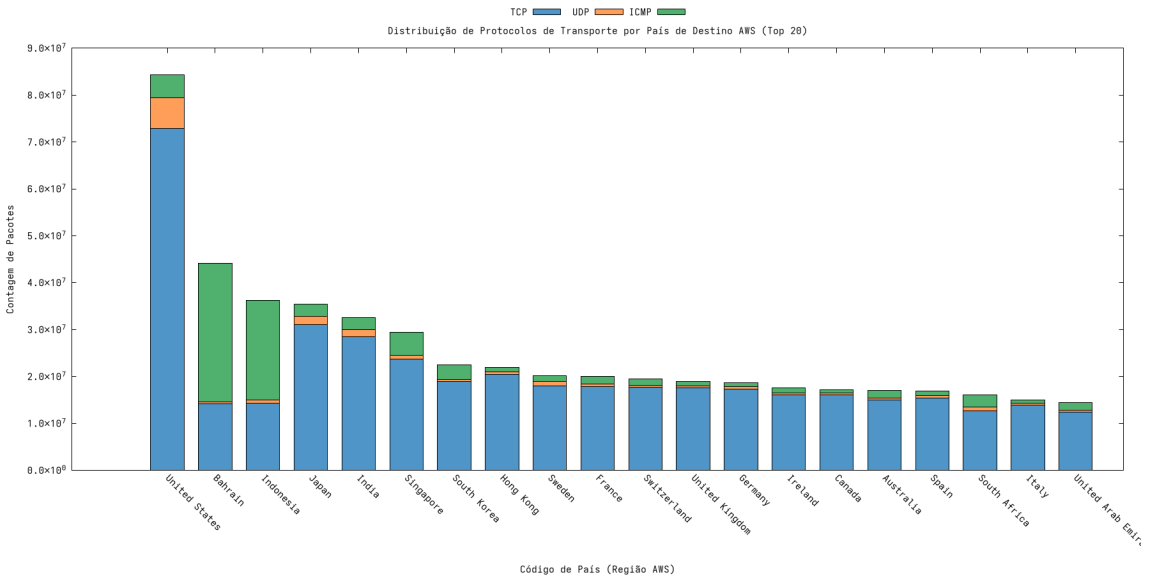



**Figura 47 –** Distribuição de protocolos de transporte por país de destino AWS (Top 20) em barras empilhadas no Dataset 3 completo. Fonte: Elaborado pelo autor.

Enquanto a Figura 45 facilita a comparação do volume de um mesmo protocolo entre países diferentes, por alinhar as barras de cada protocolo lado a lado sobre a mesma base, a Figura 47 facilita a leitura do volume total por país, a altura de cada barra empilhada, ao custo de dificultar a comparação direta de UDP e ICMP entre países, já que esses dois protocolos passam a ser lidos a partir de bases distintas dentro de cada barra. A concentração de ICMP em Barém e na Indonésia é mais evidente na Figura 47, onde o segmento verde ocupa mais da metade da altura total dessas duas barras, do que na Figura 45, onde a mesma leitura exige comparar barras de cores diferentes posicionadas lado a lado.

A Figura 48 detalha os destinos em granularidade de cidade.

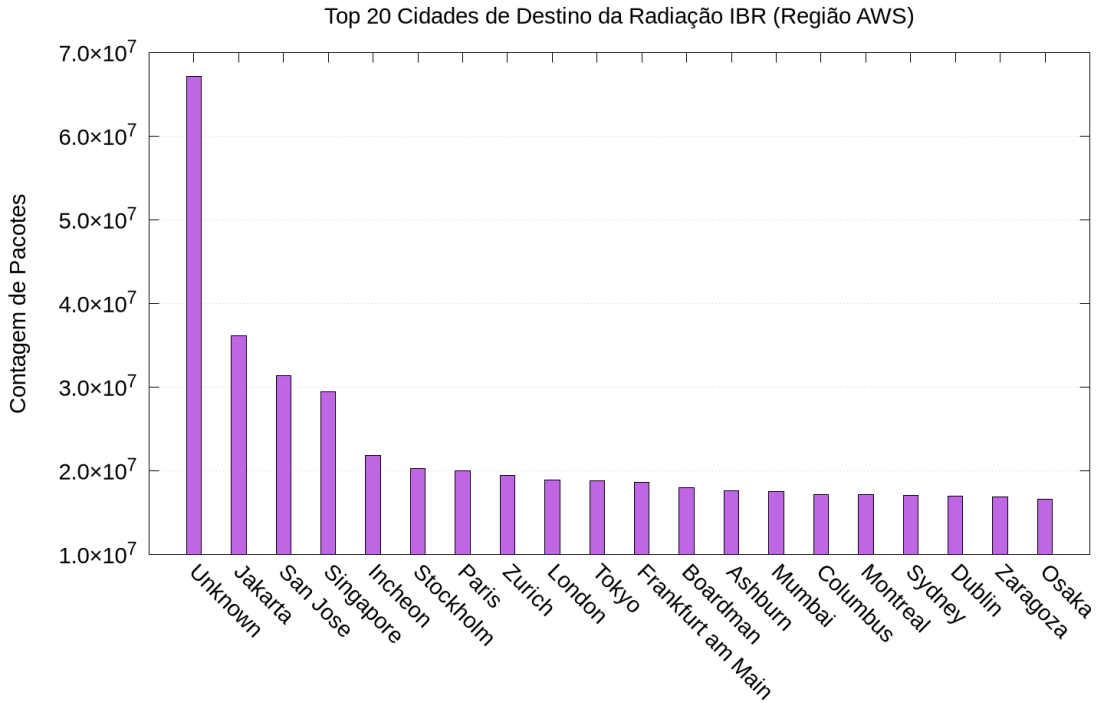



**Figura 48 –** Top 20 cidades de destino da radiação IBR na infraestrutura AWS no Dataset 3 completo. Fonte: Elaborado pelo autor.

Diferentemente da Seção 5.5.3, em que as cidades de origem refletem a geolocalização orgânica e dispersa dos IPs atacantes, as cidades listadas aqui correspondem, em grande parte, à localização física conhecida dos próprios *datacenters* da AWS: Boardman (Oregon, sede da região us-west-2), Ashburn (Virgínia, us-east-1) e Columbus (Ohio, us-east-2) ocupam posições de destaque não por serem alvos preferenciais de atacantes, mas por serem a localização geográfica do espaço de endereçamento monitorado, implantado nessas regiões pela infraestrutura de sensores em nuvem descrita por Beiler (2023). A categoria ”Unknown”volta a aparecer na liderança (67.228.425 pacotes), seguida por Jacarta (36.191.361) e San Jose (31.397.821), esta última associada à região us-west-1.

## 5.7 Concentração de Tráfego por Lei de Potência

As Figuras 49 e 50 apresentam, em escala log-log, a distribuição do volume de pacotes por IP de origem e por porta TCP de destino, respectivamente, ambas calculadas sobre faixas logarítmicas que cobrem a totalidade dos valores observados no Dataset 3 completo.

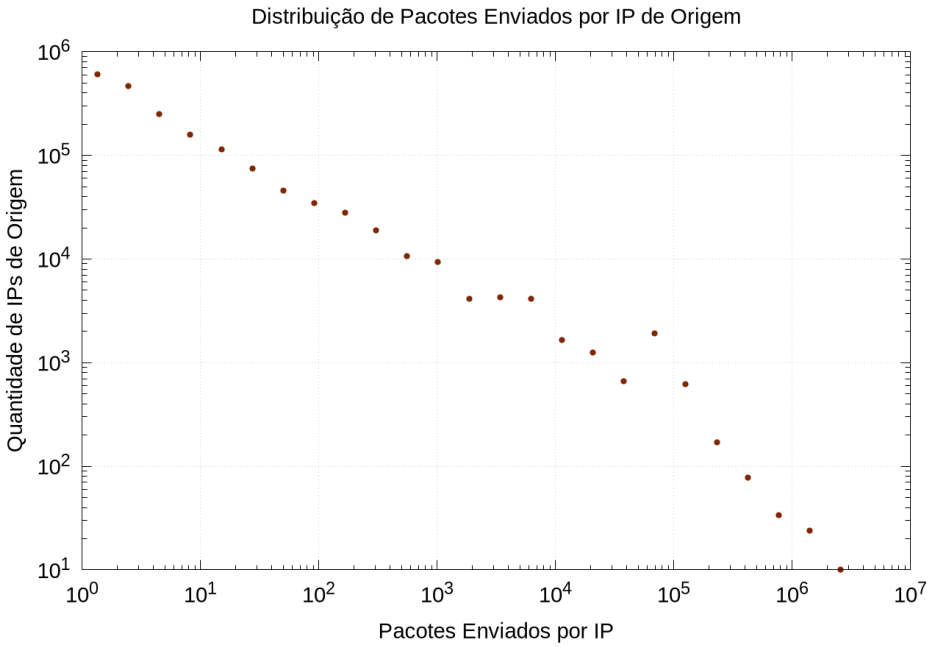



**Figura 49 –** Distribuição do número de pacotes enviados por IP de origem, em escala log-log, no Dataset 3 completo. Fonte: Elaborado pelo autor.

A Figura 49 agrupa os 1.834.887 IPs de origem únicos do Dataset 3 em 25 faixas logarítmicas cuja soma totaliza exatamente esse número de IPs. A grande maioria das fontes envia pouquíssimos pacotes: a faixa de menor volume concentra 604.218 IPs, aproximadamente 32,9% do total, e as cinco primeiras faixas (até cerca de 15 pacotes por IP) já somam 1.594.060 IPs, 86,9% do total. Na extremidade oposta, a faixa de maior volume (acima de 2,5 milhões de pacotes por IP) contém apenas 10 IPs.

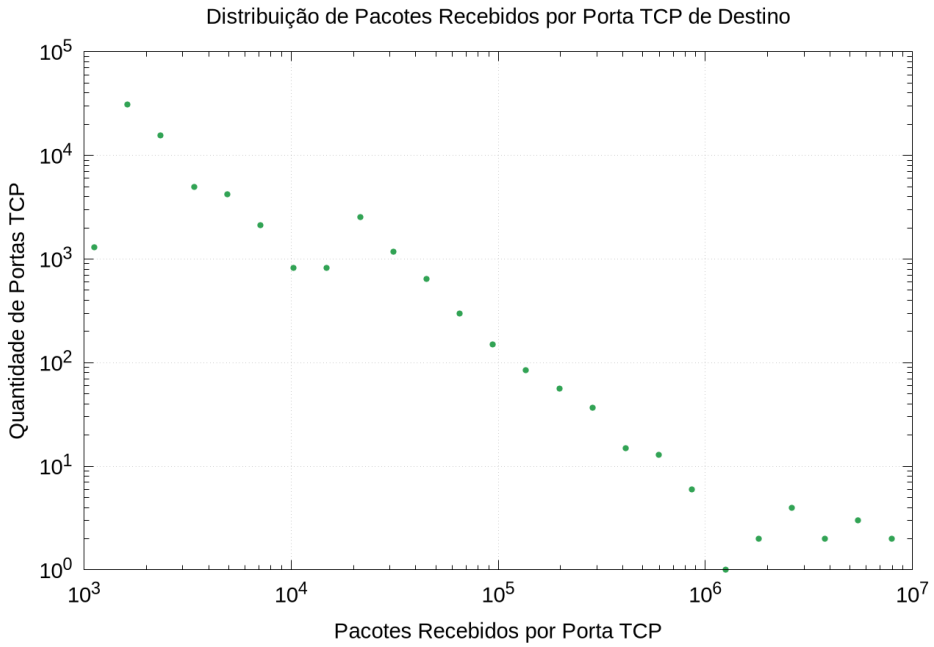



**Figura 50 –** Distribuição do número de pacotes recebidos por porta TCP de destino, em escala log-log, no Dataset 3 completo. Fonte: Elaborado pelo autor.

A Figura 50 repete a análise para o espaço de portas TCP de destino, cujas 25 faixas somam exatamente 65.535 portas, o espaço completo de portas TCP enumeráveis, evidenciando que a radiação do Dataset 3 atingiu potencialmente toda a faixa de portas possível, e não apenas um subconjunto restrito. Ao contrário da distribuição por IP de origem, que decresce monotonicamente a partir da primeira faixa, a distribuição por porta atinge seu pico na segunda faixa (30.759 portas), e só então passa a decrescer; a faixa de menor volume concentra apenas 1.303 portas, quantidade inferior à de faixas vizinhas de volume ligeiramente maior. O formato de cauda pesada observado em ambas as distribuições, poucas origens ou portas concentrando a maior parte do volume e uma longa cauda de baixo volume, é uma propriedade amplamente documentada na literatura de análise de tráfego de rede (Thakare; Pund, 2018).

Ao todo, este capítulo apresentou as 25 visualizações geradas de ponta a ponta pelo *pipeline* modificado sobre o Dataset 3 completo, sem qualquer intervenção manual, cobrindo padrões temporais, composição por protocolo de transporte, geografia de origem e de destino, portas e combinações de *flags* mais visadas, e a concentração de tráfego em lei de potência. Duas dessas visualizações, apresentadas na Seção 5.1.1, foram validadas numericamente frente a fontes elaboradas manualmente, uma planilha interna do grupo de pesquisa e uma tabela publicada na tese de Bortoluzzi (2025), confirmando a correção da automação proposta. O conjunto resulta do critério de seleção descrito na Seção 4.1.1, dentre o repositório mais amplo de estilos de visualização oferecidos pelo Gnuplot explorados ao longo do trabalho.

# 6 CONSIDERAÇÕES FINAIS

O presente trabalho propôs a integração do Gnuplot ao *pipeline* de análise do Cloud Telescope como solução para a ausência de uma camada de geração automatizada de visualizações no fluxo existente. Essa lacuna é relevante porque, embora o Cloud Telescope produza conjuntos de dados massivos sobre o tráfego de IBR capturado em múltiplas regiões da AWS, a ausência de uma etapa sistematizada de visualização impõe ao analista a tarefa manual de interpretar os dados brutos ou de recorrer a ferramentas interativas que exigem infraestrutura adicional. A proposta, portanto, buscou complementar o *pipeline* com uma ramificação dedicada à geração de gráficos reproduzíveis e automatizados.

Ao longo do TCC II, foram consolidados os fundamentos teóricos que embasam as escolhas de representação gráfica adotadas, com atenção às características do IBR que tornam determinados tipos de visualização mais informativos, como a distribuição temporal de pacotes, a origem geográfica do tráfego e o comportamento por protocolo. Paralelamente, realizou-se a revisão da literatura relevante sobre IBR e telescópios de rede, mapeando tanto os trabalhos que descrevem infraestruturas de captura quanto aqueles que tratam da análise e visualização dos dados resultantes. Esse levantamento forneceu o referencial necessário para situar a contribuição deste trabalho em relação ao estado da arte.

Além do embasamento teórico, foram concebidas e implementadas as adaptações ao *pipeline* de sumarização para suportar a nova ramificação de geração de gráficos. A metodologia adotada foi baseada na extensão incremental do *pipeline* existente com a inclusão de etapas de exportação JSON, geração de arquivos `.dat` e automação via *scripts* Gnuplot. Cada etapa foi projetada para ser executada de forma sequencial e desacoplada, permitindo que o conjunto de gráficos seja regenerado a qualquer momento a partir dos dados sumarizados, sem necessidade de reprocessar os arquivos de captura originais.

A abordagem de geração em lote diferenciou esta proposta das soluções interativas avaliadas em trabalhos paralelos do grupo de pesquisa. Enquanto a pilha ELK, avaliada por Prudêncio (2026), demanda a manutenção de uma infraestrutura de indexação ativa para viabilizar consultas e *dashboards*, e o Neo4j, investigado por Gubertt (2026), requer a carga do grafo de propriedades em memória para a execução de consultas Cypher, o Gnuplot opera diretamente sobre arquivos de texto sem qualquer serviço auxiliar em execução. Essa leveza operacional torna a solução proposta especialmente adequada para ambientes de análise *offline* e para a geração periódica e automatizada de relatórios visuais integrados ao *pipeline* existente.

As três abordagens, portanto, não concorrem entre si, mas atendem a necessidades analíticas distintas e complementares. A pilha ELK é indicada para a exploração interativa e investigação pontual de eventos; o Neo4j, para a descoberta de padrões relacionais e geopolíticos

de maior profundidade; e o Gnuplot, para a produção contínua e padronizada de visualizações estatísticas a cada novo ciclo de captura. Juntas, essas iniciativas compõem um ecossistema analítico diversificado para o grupo de pesquisa do Cloud Telescope, em que a contribuição deste trabalho ocupa a camada de observabilidade contínua e reprodutível do tráfego de IBR.

O desenvolvimento do *pipeline* modificado foi concluído ao longo do TCC III: as etapas de exportação JSON, geração de arquivos `.dat` e automação via Gnuplot foram implementadas e executadas de ponta a ponta sobre o Dataset 3 completo do Cloud Telescope (aproximadamente 90 GB, mais de 530 milhões de pacotes), produzindo as 25 visualizações discutidas em sua totalidade no Capítulo 5. Esse conjunto de 25 visualizações correspondeu ao resultado final alcançado com o *pipeline* modificado proposto neste trabalho, selecionado conforme o critério descrito na Seção 4.1.1: os gráficos elaborados manualmente pelo grupo de pesquisa, os padrões de visualização empregados pelos trabalhos relacionados apresentados no Capítulo 3 e as publicações de referência da IMC.

Nem todos os gráficos gerados, no entanto, têm o mesmo valor analítico. Entre os resultados mais interessantes estão aqueles que revelam padrões não triviais no tráfego de IBR: a dominância de apenas duas combinações de *flags* TCP (SYN isolado e RST isolado, juntas 99,2% de todo o tráfego TCP), a concentração extrema de pacotes ICMP em duas regiões AWS específicas e no tráfego originado da China, de Singapura e da Indonésia, e a identificação de uma campanha de varredura sincronizada nas portas 10000-10002, visível tanto na série temporal quanto no cruzamento por país de origem. Esses achados não eram conhecidos a priori pelo grupo de pesquisa e emergiram justamente da automação proposta: sem a geração sistemática de múltiplas perspectivas sobre os mesmos dados, padrões como esses dificilmente seriam notados em uma inspeção manual e pontual das tabelas sumarizadas. A reordenação completa do *ranking* de países de origem ao isolar apenas o protocolo ICMP, apresentada na Seção 5.1.1, reforçou a confiabilidade desse achado: os mesmos 20 países e as mesmas contagens já apareciam na Tabela 31 que o *pipeline* original, o mesmo `3_summarize_radiation.py` antes das modificações propostas neste trabalho, já produzia em formato tabular na tese de Bortoluzzi (2025), confirmando que a nova ramificação de geração gráfica não altera os valores já calculados pela etapa de sumarização existente, apenas lhes acrescenta uma representação visual automatizada.

Por outro lado, alguns gráficos têm valor analítico mais limitado para o grupo de pesquisa. Os *rankings* simples dos 20 principais países de origem e de destino da radiação, por exemplo, reproduzem um padrão de concentração geográfica já amplamente documentado na literatura de telescópios de rede (García-Peñas; Rodríguez-Gómez; Maciá-Fernández, 2025; Ismail *et al.*, 2025) e não revelam, por si só, nenhuma informação nova além da magnitude relativa entre os países: são gráficos úteis como contextualização, mas pouco informativos como achado. Outro caso identificado durante a revisão final do trabalho foi a representação em bolhas dos países de destino AWS (Figura 46): embora a área de cada círculo seja calculada corretamente como proporcional à contagem de pacotes, a percepção visual de diferenças de área é, por na-

tureza, menos precisa do que a percepção de diferenças de posição ou comprimento, um dos argumentos centrais discutidos na Seção 2.6. Como os valores do Top 20 variam numa faixa relativamente estreita (entre 14,4 e 84,3 milhões de pacotes, menos de uma ordem de magnitude de diferença), o tamanho dos círculos menores fica visualmente pouco distinguível entre si, mesmo com o raio corretamente escalado pela raiz quadrada do valor. A correção aplicada, acrescentar o valor numérico ao lado de cada círculo, resolveu o problema no nível do código sem comprometer a honestidade da escala de área, mas reforçou que nem todo estilo do repertório do Gnuplot é igualmente adequado a qualquer faixa de dados, uma lição prática que só a implementação exploratória tornou visível.

O resultado final confirmou a viabilidade da proposta original: o Gnuplot mostrou-se adequado para automatizar, de forma leve e reprodutível, uma etapa de visualização antes inexistente no *pipeline* original, como evidenciado pela dupla validação apresentada na Seção 5.1.1: frente ao gráfico de referência elaborado manualmente pelo orientador em planilha Excel, e frente a um *ranking* que o próprio *pipeline* original já calculava, mas apenas em formato tabular, publicado na tese de Bortoluzzi (2025). O caráter exploratório da implementação foi uma forma de mapear as capacidades e os limites da ferramenta diante de um conjunto de dados real de grande escala, resultando nas 25 visualizações documentadas neste trabalho, que podem orientar a seleção de estilos de visualização em trabalhos futuros do grupo de pesquisa sobre o Cloud Telescope.

# REFERÊNCIAS

BABU, A. S. Prajwal; B., Suma. Developing an ETL Pipeline for Data Analysis. **International Journal of Computer Applications Technology and Research**, v. 11, n. 8, p. 315–319, 2022. DOI: 10.7753/IJCATR1108.1004. Citado na página 27.

[*S. l.*]. **Proceedings of the 2025 ACM Internet Measurement Conference (IMC '25)**. Edição: Paul Barford, Aruna Balasubramanian e Alberto Dainotti. Madison, WI, USA: ACM, 2025. ISBN 979-8-4007-0628-8. DOI: 10.1145/3730567. Citado nas páginas 16, 46.

BEILER, Lucas Silvero. **Análise da radiação de fundo da internet por captura distribuída em telescópio de nuvem**. 2023. Monografia (Trabalho de Conclusão de Curso (Graduação em Ciência da Computação)) – Escola Politécnica, Universidade do Vale do Itajaí, Itajaí. Citado nas páginas 19, 23, 24, 42–44, 74.

BORTOLUZZI, Fabricio. **Cloud Telescope: An Ephemeral, Distributed, and Cloud-Native Architecture for Collecting Internet Background Radiation**. 2025. Tese (Doutorado) – Universidade Federal de Santa Catarina, Florianópolis, Brazil. Citado nas páginas 13, 14, 16, 21, 24–26, 33–37, 42, 56–58, 67, 70, 76, 78, 79.

FEW, Stephen. Data Visualization for Human Perception. *In:* SOEGAARD, Mads; DAM, Rikke Friis (ed.). **THE Encyclopedia of Human-Computer Interaction**. 2. ed. [*S. l.*]: Interaction Design Foundation, 2013. Disponível em: https://www.interaction-design.org/literature/book/the-encyclopedia-of-human-computer-interaction-2nd-ed/data-visualization-for-human-perception. Citado nas páginas 28, 29.

GARCÍA-PEÑAS, Rodolfo; RODRÍGUEZ-GÓMEZ, Rafael A.; MACIÁ-FERNÁNDEZ, Gabriel. Characterizing Internet Background Traffic from a Spain-Based Network Telescope. **Computers & Security**, v. 159, p. 104693, 2025. ISSN 0167-4048. DOI: 10.1016/j.cose.2025.104693. Disponível em: https://www.sciencedirect.com/science/article/pii/S0167404825003827. Citado nas páginas 20–22, 24, 38, 39, 44, 59, 61, 78.

GNUPLOT DEVELOPMENT TEAM. **Demos for gnuplot version 6.0**. [*S. l.: s. n.*], 2026. Galeria oficial de demonstrações; 152 exemplos distintos catalogados em consulta de 16 de setembro de 2026. Disponível em: https://gnuplot.sourceforge.net/demo_6.0/. Citado na página 50.

GNUPLOT DEVELOPMENT TEAM. **Gnuplot FAQ**. [*S. l.: s. n.*], 2023. FAQ version: December 2023. Describes gnuplot version 6. Disponível em: http://www.gnuplot.info/faq/faq.pdf. Citado na página 31.

GRIFFIOEN, Harm *et al.* Have you SYN me? Characterizing Ten Years of Internet Scanning. *In:* **PROCEEDINGS of the 2024 ACM Internet Measurement Conference (IMC '24)**. [*S. l.*]: ACM, 2024. p. 149–164. DOI: 10.1145/3646547.3688409. Citado nas páginas 22, 40, 41, 44, 46, 50, 55, 61, 70.

GUBERTT, João Pedro. **Avaliação do Neo4j como Backend para Expressão de Tráfego de Rede como Estrutura de Grafos**. 2026. Monografia (Trabalho de Conclusão de Curso (Graduação em Ciência da Computação)) – Escola Politécnica, Universidade do Vale do Itajaí, Itajaí. Citado nas páginas 43–45, 77.

IRWIN, Barry. **A Framework for the Application of Network Telescope Sensors in a Global IP Network**. 2011. Tese (Doutorado) – Rhodes University, Grahamstown, South Africa. Citado nas páginas 13, 21, 23.

ISMAIL, Shereen *et al.* **Merit Network Telescope: Processing and Initial Insights from Nearly 20 Years of Darknet Traffic for Cybersecurity Research**. [*S. l.: s. n.*], 2025. arXiv:2510.25050. Citado nas páginas 13, 21, 39, 40, 44, 50, 65, 78.

JANERT, Philipp K. **Gnuplot in Action: Understanding Data with Graphs**. 2. ed. Shelter Island: Manning, 2016. Citado nas páginas 14, 29–32.

KITCHENHAM, Barbara. **Procedures for Performing Systematic Reviews**. Keele, UK, 2004. Citado na página 16.

LAURITZEN, Matheus Baron. **ibr-gnuplot-pipeline: pipeline Gnuplot para visualização automatizada de Radiação de Fundo da Internet**. [*S. l.: s. n.*], 2026. Código-fonte do *pipeline* modificado desenvolvido neste trabalho. Acesso em: 29 out. 2026. Disponível em: https://github.com/matheus-lauri/ibr-gnuplot-pipeline. Citado na página 52.

MÄNNEL, Alexander *et al.* Lessons Learned from Operating a Large Network Telescope. *In:* **PROCEEDINGS of the ACM SIGCOMM 2025 Conference**. [*S. l.*]: ACM, 2025. p. 826–841. DOI: 10.1145/3718958.3754347. Citado nas páginas 13, 20, 24, 55, 66.

MELQUIOND, Guillaume. Plotting in a Formally Verified Way. *In:* **PROCEEDINGS of the 6th International Workshop on Formal Integrated Development Environment (F-IDE 2021)**. [*S. l.: s. n.*], 2021. p. 39–45. DOI: 10.4204/EPTCS.338.6. Citado na página 30.

MOORE, David *et al.* Inferring Internet Denial-of-Service Activity. **ACM Transactions on Computer Systems**, v. 24, n. 2, p. 115–139, maio 2006. DOI: 10.1145/1132026.1132027. Citado nas páginas 22, 60, 62, 63, 67.

MUNTEANU, Cristian *et al.* Attacks Come to Those Who Wait: Long-Term Observations in an SSH Honeynet. *In:* **PROCEEDINGS of the 2025 ACM Internet Measurement Conference (IMC '25)**. [*S. l.: s. n.*], 2025. p. 628–645. DOI: 10.1145/3730567.3764475. Citado nas páginas 21, 46.

PRUDÊNCIO, João Pedro. **Avaliação da Pilha ELK para Indexação e Visualização de Eventos na Radiação de Fundo da Internet**. 2026. Monografia (Trabalho de Conclusão de Curso (Graduação em Ciência da Computação)) – Escola Politécnica, Universidade do Vale do Itajaí, Itajaí. Citado nas páginas 43–45, 77.

SHYAMKUMAR, Nishanth *et al.* Patchwork: A Traffic Capture and Analysis Platform for Network Experiments on a Federated Testbed. *In:* **PROCEEDINGS of the 2025 ACM Internet Measurement Conference (IMC '25)**. [*S. l.*]: ACM, 2025. p. 677–691. DOI: 10.1145/3730567.3732916. Citado nas páginas 25, 46.

THAKARE, Sheetal; PUND, Anshuman. Network Traffic Analysis, Importance, Techniques: A Review. *In:* **PROCEEDINGS of the International Conference on Communication and Electronics Systems (ICCES)**. [*S. l.*]: IEEE, 2018. p. 1–6. DOI: 10.1109/CESYS.2018.8723932. Citado nas páginas 13, 20, 76.

[*S. l.*]. **Proceedings of the 2024 ACM Internet Measurement Conference (IMC '24)**. Edição: Narseo Vallina-Rodríguez. Madrid, Spain: ACM, 2024. ISBN 979-8-4007-0592-2. DOI: 10.1145/3646547. Citado nas páginas 16, 46.

VASSILIADIS, Panos. A Survey of Extract–Transform–Load Technology. **International Journal of Data Warehousing and Mining**, v. 5, n. 3, p. 1–27, 2009. DOI: 10.4018/jdwm.2009070101. Citado nas páginas 26, 27.

WAZLAWICK, Raul Sidnei. **Metodologia de Pesquisa para Ciência da Computação**. Rio de Janeiro: Elsevier, 2009. Citado na página 16.

WILD, C. J.; PFANNKUCH, M. Statistical Thinking in Empirical Enquiry. **International Statistical Review**, v. 67, n. 3, p. 223–265, 1999. DOI: 10.1111/j.1751-5823.1999.tb00442.x. Citado na página 28.

WILLIAMS, Thomas *et al.* **Gnuplot 6.0: An Interactive Plotting Program**. [*S. l.: s. n.*], 2025. Ferramenta de visualização de dados de código aberto, em desenvolvimento ativo desde 1986. Disponível em: http://www.gnuplot.info/. Citado nas páginas 29–33.